

Perception et adoption de l'intelligence artificielle générative en cabinet d'audit

Mémoire de fin d'année

Master CGAO

Parcours Audit Contrôle de gestion

(Big Data)

Année 2025 - 2026

Lydéric HENRY


Sous la direction de :

Aymen ABBADI, directeur de mémoire académique

Kévin OLEJNIK, Tuteur cabinet d'audit

L'Université de Lille n'entend donner aucune approbation ni improbation aux opinions émises dans le présent mémoire : ces opinions doivent être considérées comme propres à leur auteur

J'atteste sur l'honneur que le présent document est le fruit d'un travail personnel, et que les emprunts à des documents externes sont tous mentionnés, mention datée et signée

 Le 11/04/2026

Résumé

Ce mémoire examine comment la perception de l'intelligence artificielle générative (IAG) influence son utilisation au sein des cabinets d'audit français. Mobilisant le Technology Acceptance Model de Davis (1989), le scepticisme professionnel de Hurtt (2010) et le talent digital de Liang et al. (2025), six hypothèses ont été testées auprès de 67 auditeurs via questionnaire et trois entretiens semi-directifs (janvier-mars 2026). L'utilité perçue ne différencie plus les niveaux d'usage (H1 infirmée) ; l'intégration dans le flux de travail constitue le principal déterminant (H2 confirmée) et la responsabilité individuelle le frein majeur (H3 confirmée). La maîtrise fonctionnelle modère l'effet inhibiteur des risques (H4a confirmée), un biais d'automatisation est observé chez les utilisateurs intensifs (H4b infirmée), et la perception des risques renforce le scepticisme professionnel plutôt qu'elle ne l'érode (H4c infirmée).

Abstract

This dissertation examines how the perception of generative artificial intelligence (GAI) influences its use within French audit firms. Drawing on Davis's (1989) Technology Acceptance Model, Hurtt's (2010) professional scepticism model, and Liang et al.'s (2025) digital talent concept, six hypotheses were tested through a survey of 67 auditors and three semi-structured interviews (January-March 2026). Perceived usefulness no longer differentiates usage levels (H1 rejected); workflow integration is the primary driver (H2 supported) and individual accountability the main inhibitor (H3 supported). Functional competence moderates the inhibiting effect of risks (H4a supported), an automation bias is observed among intensive users (H4b rejected), and risk perception reinforces rather than erodes professional scepticism (H4c rejected).

Remerciements

Je remercie Aymen Abbadi et Kévin Olejnik pour leur encadrement académique et professionnel tout au long de cette année. Mes remerciements vont également aux trois interviewés et aux auditeurs ayant répondu au questionnaire, dont la contribution a rendu cette recherche possible, ainsi qu'aux personnes ayant bien voulu relire ce travail.

Sommaire paginé

Sommaire paginé.....	5
1. Introduction.....	6
PARTIE I : REVUE DE LITTÉRATURE CADRES THÉORIQUES ET ENJEUX DE L'IA GÉNÉRATIVE EN AUDIT.....	9
Chapitre 1 : Fondements techniques et cadres d'acceptation de l'IAG.....	9
1.1. De l'IA classique à l'IA générative (IAG).....	9
1.2. Le cadre théorique de l'acceptation technologique (TAM).....	15
Chapitre 2 : Défis normatifs, risques et responsabilité de la chaîne d'audit.....	22
2.1. Fondements du scepticisme professionnel en audit.....	22
2.2. Origines et manifestations des risques liés à l'IAG en audit.....	29
2.3. Enjeux conformité et responsabilité.....	34
Chapitre 3 : Développement des hypothèses.....	40
3.1. Synthèse de la revue de littérature et formulation des hypothèses.....	40
Partie II : Recherche Empirique.....	43
Chapitre 4 : Protocole méthodologique et dispositif de recherche.....	43
4.1. Positionnement épistémologique et choix de la méthode.....	43
4.2. Conception du questionnaire Google Form.....	44
4.3. Présentation du terrain et de l'échantillon.....	47
Chapitre 5 : Analyse des résultats et discussion.....	49
5.1. Profil de l'échantillon.....	49
5.2. Statistiques descriptives.....	54
5.3. Test des hypothèses.....	58
5.4. Analyses complémentaires.....	72
5.5. Discussion et entretiens semi-dirigés.....	77
Conclusion.....	88
Bibliographie.....	90
Revue professionnelle.....	90
Revue académique.....	90
Annexes.....	94
Annexe 1 : Liste des questions du google form.....	94
Annexe 2 : Questionnaire entretien semi-dirigé.....	98
Annexe 3 : Comptes rendus entretiens semi dirigés (Interviewés A,B,C).....	104
Liste paginée des tableaux et figures.....	112
Liste des tableaux.....	112
Liste des figures.....	112
Glossaire.....	114
Table des matières.....	116

1.Introduction

L'audit connaît actuellement une transformation profonde liée au développement rapide de l'intelligence artificielle générative. En effet, l'avènement de l'intelligence artificielle générative (IAG) n'est plus un sujet futur mais un sujet très concret désormais. À cet égard, Samiolo et al. (2024), dans leur article « Auditor judgment in the fourth industrial revolution », soulignent que l'intelligence artificielle transforme progressivement le jugement de l'auditeur, traditionnellement conçu comme un acte cognitif individuel, en un processus distribué et systémique. L'IA ne se limite plus à un rôle d'assistance technique, mais intervient directement dans l'évaluation de la performance, de la qualité de l'information et dans la prise de décision. Elle participe ainsi à des activités mentales complexes telles que l'analyse, la résolution de problèmes ou le raisonnement professionnel.

Cette intégration modifie en profondeur la nature du jugement d'audit. L'auditeur ne décide plus de manière strictement autonome, mais s'appuie sur des algorithmes et des recommandations issues de systèmes d'IA pour formuler ses conclusions. Si cette évolution peut améliorer l'efficacité et la cohérence des décisions, elle soulève également des enjeux majeurs, notamment en matière de dépendance cognitive et de conscience du rôle réel joué par l'IA dans le processus de jugement. L'absence de vigilance à cet égard pourrait conduire à une influence non maîtrisée de la technologie sur le jugement professionnel.

Cette transformation brutale s'explique par l'arrivée extrêmement rapide des Large Language Models (LLMs) accessibles au grand public. En 2018, on observait déjà les prémices de ces IAG. Le sujet s'est toutefois réellement développé à partir de 2020, comme le souligne le livret « Audit & Société : Propos et Débats n°6 » de la CNCC, publié en décembre 2024, avec la sortie de GPT-3 introduisant plus de 175 milliards de paramètres. Cette arrivée soudaine a forcé la profession et les régulateurs de l'audit à réagir dans l'urgence pour évaluer l'impact sur les métiers du commissariat aux comptes et de l'audit.

Les clients pensent également que l'IA va leur permettre d'améliorer leur contrôle interne, comme l'illustre Tan et al. (2025) avec « Effects of artificial intelligence in the modern business: Client artificial intelligence application and audit quality ». L'étude souligne également que plus le client est mature dans son contrôle interne, plus l'auditeur pourra avoir

recours à l'utilisation de l'IA pour son audit, ce qui constitue un point particulièrement intéressant à analyser.

Enfin, l'IA est vue comme un levier de productivité sur les tâches à faible valeur ajoutée ou répétitives, comme l'indique l'article « Is artificial intelligence improving the audit process? » de Fedyk et al. (2022). Ce dernier met également en avant une diminution du nombre de juniors alors que les postes de senior restent stables, ce qui pourrait témoigner des premières conséquences de l'utilisation de l'IA au sein des cabinets.

En dehors de cette promesse d'efficacité, la littérature soulève de nombreuses menaces et freins, avec principalement l'opacité algorithmique, aussi appelée « Black Box », qui empêche la validation des preuves d'audit selon les normes attendues (Gu et al., 2025). De plus, le cadre réglementaire actuel européen (EU AI Act) semble insuffisant et incomplet pour encadrer les risques spécifiques à l'intelligence artificielle générative : il reste trop généraliste et n'approfondit pas les risques liés aux hallucinations factuelles correspondant à une invention de faits par l'intelligence artificielle qui semblent plausibles (Jonnala et al., 2025).

Enfin, la littérature révèle également un écart important entre la capacité théorique des outils et la réalité perçue lorsque les auditeurs les utilisent concrètement. L'article « Exploring Large Language Models in external audits: Implications and ethical considerations » de Fotoh & Mugwira (2025) conclut notamment qu'un gain de temps significatif est observable sur les tâches simples, mais que l'IA ne permet pas un gain équivalent sur les tâches complexes.

Ainsi, la littérature aborde de nombreux aspects de l'intelligence artificielle, mais traite encore peu de l'impact de la perception individuelle des risques et des opportunités sur le comportement des auditeurs. Il n'existe pas vraiment d'étude portant sur l'impact concret de l'IA sur le métier d'auditeur. Il convient donc de se demander : comment, dans les faits, l'auditeur perçoit-il l'IA générative, et dans quelle mesure cette perception influence-t-elle son utilisation ?

Pour ce faire, il est possible d'analyser la perception de l'IA générative à l'aide du Technology Acceptance Model (TAM) proposé par Davis (1989). Ce modèle repose sur l'idée que l'adoption d'un outil ne dépend pas uniquement de ses performances ou de son efficience

objective, mais principalement de la perception qu'en ont les utilisateurs, notamment en termes d'utilité perçue et de facilité d'utilisation.

Cela peut créer des risques et des biais dans l'analyse de l'auditeur : s'il perçoit l'IA comme très performante, même lorsque ce n'est pas le cas, il risque de se reposer aveuglément sur ses résultats. Bien que l'IA générative soit actuellement perçue comme utile, elle pourrait dégrader la compétence principale de l'auditeur qui est son scepticisme professionnel et son jugement critique s'il adopte les résultats produits sans discernement et sans exercer une analyse critique suffisante.

Ainsi, la problématique à laquelle nous allons chercher à répondre dans ce mémoire est la suivante : « En quoi la perception de l'intelligence artificielle générative influence-t-elle son utilisation dans les cabinets d'audit ? »

L'intérêt est de comprendre si les auditeurs, notamment financiers, perçoivent et sont conscients des risques et des opportunités liés à l'usage de l'intelligence artificielle au sein des cabinets d'audit, et si cette prise de conscience influence leur utilisation. Cette recherche permettra également aux cabinets d'audit d'obtenir des pistes pour mieux gérer l'intégration de l'intelligence artificielle, d'appréhender la perception des auditeurs sur l'IA, les points de blocage ou les risques associés, et de mettre en place une supervision adéquate ainsi que des formations pour combler ces lacunes et exploiter les opportunités potentielles liées à l'IA. Cette étude permettra également de tester la validité du modèle d'acceptation TAM, afin de vérifier si la perception de l'IA générative a un impact sur son utilisation plus déterminant que son utilité et sa performance réelles.

Toutefois, cette étude se heurte à certaines contraintes. Le domaine de l'IA générative évolue à un rythme effréné, marqué par l'émergence mensuelle de multiples modèles de langage (LLMs) tels que ChatGPT, Gemini ou Deepseek. Par conséquent, nos travaux se concentrent spécifiquement sur la perception des auditeurs au début de l'année 2026 (Janvier - Mars).

De plus, le périmètre de cette recherche se limite exclusivement aux usages textuels portés par les LLMs, excluant ainsi les capacités de génération d'images, de vidéos ou de traitement audio offertes par d'autres formes d'intelligence artificielle générative. Par ailleurs, comme cette étude est limitée à la France, son application à d'autres pays ne serait envisageable que s'ils présentent un cadre légal (CNCC/EU AI Act) et culturel similaire ou proche.

L'étude couvre l'ensemble des métiers de l'audit au sein des cabinets français, avec un ancrage prioritaire sur l'audit financier dont les normes (NEP 200, scepticisme professionnel, responsabilité du CAC) constituent le cadre théorique central du mémoire.

Ce mémoire s'articule en deux parties. La première dresse un état de la littérature structuré en trois chapitres : le Chapitre 1 pose les fondements techniques de l'IAG et le cadre d'acceptation technologique (TAM), le Chapitre 2 analyse les défis normatifs, les risques cognitifs et les enjeux de responsabilité propres à l'audit, et le Chapitre 3 synthétise ces éléments pour formuler six hypothèses de recherche. La seconde partie mobilise ces hypothèses comme fil directeur de l'analyse empirique : le Chapitre 4 présente le protocole méthodologique retenu, et le Chapitre 5 expose les résultats de l'enquête conduite auprès de 67 auditeurs français entre janvier et mars 2026, enrichis de trois entretiens semi-directifs, avant d'en discuter les implications pour la profession.

PARTIE I : REVUE DE LITTÉRATURE CADRES THÉORIQUES ET ENJEUX DE L'IA GÉNÉRATIVE EN AUDIT

Chapitre 1 : Fondements techniques et cadres d'acceptation de l'IAG

1.1. De l'IA classique à l'IA générative (IAG)

L'intelligence artificielle n'est pas un concept nouveau : elle existe en réalité depuis les années 1950, avec notamment Alan Turing et son célèbre « Test de Turing », consistant à évaluer la capacité d'une machine à imiter la conversation humaine face à un être humain

.

La vraie nouveauté réside dans le développement des LLMs et l'avènement de l'intelligence artificielle générative (IAG). Cette avancée est rendue possible grâce aux progrès réalisés en matière de processeurs, aux capacités de calcul sans cesse croissantes, permettant d'effectuer des opérations à une vitesse inédite et de disposer d'une puissance de traitement sans

précédent. À travers ces nouveaux modèles de langage, l'intelligence artificielle semble désormais en mesure de traiter et d'interpréter l'information.

Nous différencierons d'abord les approches traditionnelles (algorithmes prédictifs et Big Data) de l'émergence des modèles de langage (LLMs) et des agents cognitifs, avant d'explorer la nature probabiliste de l'IAG pour évaluer comment elle transforme la pratique et le jugement de l'auditeur.

1.1.1. Distinction conceptuelle : Algorithmes prédictifs et Big Data vs Modèles de langage (LLMs) et agents cognitifs.

On distingue ainsi deux types d'intelligence artificielle : l'IA « classique » et les LLMs, ou IAG.

L'IA classique repose sur la recherche de motifs (ou « patterns » en anglais) au sein de bases de données massives, notion que l'on appelle également par le terme « Big Data », comme l'indiquent Dong et al. (2024). Concrètement, l'intelligence artificielle classique identifie des similitudes dans les données afin de les classer ou d'en isoler certaines informations ; elle opère par discrimination.

Par exemple, elle va décider si une donnée appartient à une catégorie dans un contexte professionnel, comme déterminer si une dépense est une charge ou un investissement, ou si une écriture comptable est correcte ou incorrecte. Dans ce contexte, il ne s'agit pas d'intelligence artificielle générative, mais d'intelligence artificielle classique, comme le souligne Euchner (2023).

Le système ne va rien créer de nouveau, il va extraire, catégoriser et prédire selon les données prédéfinies. Le fondement de l'IA classique repose sur des algorithmes d'apprentissage automatique.

À l'inverse, l'IA générative est entraînée pour générer du langage humain, des informations directement compréhensibles par l'Homme. L'arrivée de l'architecture Transformer en 2017 avec deux modèles principaux, BERT et GPT, marque le passage à l'IA générative moderne. BERT est essentiellement utilisé comme modèle dit « d'encodage », spécialisé pour comprendre, classer et extraire des données ; il serait davantage proche de l'IA classique « évoluée ». Au contraire, le modèle le plus connu aujourd'hui reste GPT, qui signifie

Generative Pre-trained Transformer, et représente l'IA générative telle qu'on la connaît, devenue référence incontournable en 2025.

Le mécanisme principal est celui d'auto-attention (ou « self-attention » en anglais), qui permet au modèle de comprendre le contexte en associant un poids d'importance à chaque mot par rapport aux autres au sein de la phrase. Cela permet à l'IA générative de simuler la compréhension de la phrase en utilisant les mots environnants. Le modèle ne se base pas sur des règles explicites, mais sur des milliards de micro-décisions statistiques (aussi appelées coefficients), comme l'indiquent Fotoh & Mugwira (2025). À titre indicatif, GPT-3 (2020) contenait 175 milliards de paramètres et GPT-4 (2023) est estimé à environ 1,76 trillion de paramètres, même si cette information n'a jamais été confirmée officiellement.

Un autre point intéressant est que ces modèles n'ont pas besoin d'avoir été entraînés à réaliser une tâche particulière. Ils peuvent effectuer ce que l'on appelle du « zéro-shot » : ils n'ont pas besoin d'exemples préalables, ou très peu, pour accomplir une tâche, ce qui les rend extrêmement polyvalents. Pour générer une réponse, GPT réalise une distribution probabiliste sur l'ensemble du vocabulaire afin de sélectionner le mot suivant le plus crédible et le plus logique. Chaque mot généré influence le suivant : c'est le modèle causal du langage, dans lequel le dernier mot « cause », au sens probabiliste, le suivant, permettant ainsi de se rapprocher d'une écriture humaine (Dong et al., 2024).

Dans l'illustration ci-dessous (figure 1), le modèle de langage calcule d'abord un score pour chaque mot possible. Ces scores sont ensuite transformés en probabilités. Le mot « coin » obtient ici un score élevé, ce qui lui donne une probabilité d'environ 20 %. Cela en fait l'un des mots les plus plausibles pour continuer la phrase. Le modèle ne choisit pas nécessairement le mot le plus probable : il en sélectionne un de manière aléatoire parmi les plus probables. Comme « coin » avait une probabilité significative, il a été retenu, mais l'IA aurait aussi pu choisir un autre mot.




Figure 1 : Illustration génération texte LLMs - Source [ASKAIBRAIN](#)

Cela montre cependant que l'IA ne recherche pas de fait et ne réfléchit pas réellement, elle se contente d'utiliser des modèles statistiques et mathématiques pour sélectionner le mot suivant le plus probable, selon Euchner (2023). On obtient donc un résultat de ce qui est probable d'être vrai mais pas forcément vrai. Cela peut donc mener à des hallucinations, ce qui est concrètement une génération plausible mais qui est factuellement fausse, une pure invention de l'IAG.

Enfin, Fotoh & Mugwira (2025) proposent, dans leur article de recherche « Classifying and Evaluating Large Language Models in External Audits », une taxonomie des LLMs en trois grandes catégories :

- Les LLMs externes qui sont des modèles d'usage général pour le grand public comme ChatGPT, Gemini, ou encore Mistral, où les utilisateurs n'ont pas ou peu de contrôle sur les données et fonctionnalités.
- Les LLMs semi-internes, qui sont issus d'un partenariat entre une firme et un prestataire de service, comme Azure OpenAI pour certains des Big 4 avec la conservation de la propriété des données, et des modèles qui sont ajustés pour leur besoins (également dits « fine-tunés »).

- Les LLMs internes qui sont développés par une entreprise, pour répondre à ses besoins spécifiques. Ils sont hébergés dans une infrastructure propre à la société et les données ne sont pas accessibles au public. On peut citer par exemple ChatPwC pour PwC ou EYQ pour EY.

Ainsi, les utilisateurs choisiront la catégorie qui leur convient le mieux selon leurs besoins et leurs moyens.

1.1.2. L'intelligence artificielle comme agent de jugement probabiliste

Comme vu précédemment, l'IA générative repose sur des calculs statistiques pour lui permettre de prédire la réponse la plus probable. Elle n'émet pas de jugement à proprement parler et ne sait pas réfléchir au sens où nous l'entendons.

L'IAG ne possède pas de compréhension des enjeux moraux et professionnels de l'audit. Elle repose sur l'optimisation de séquences de mots (tokens), l'objectif étant de produire l'agencement le plus probable possible afin de générer un raisonnement qui semble crédible.

Les travaux de Sun et al. (2025) ont analysé des entreprises cotées en Chine sur la période 2013-2023 afin de construire un score d'adoption de l'IA propre à chaque société. Pour mesurer l'intégration réelle de l'IA dans les processus internes, les chercheurs ont utilisé l'outil Word2Vec avec le modèle skip-gram, qui convertit les mots des rapports annuels en vecteurs et permet d'identifier ceux associés à un ensemble de mots-clés liés à l'IA. À partir de la fréquence de ces termes, ils construisent ainsi un indicateur d'adoption de l'IA pour chaque entreprise.

Ce score est ensuite combiné avec des données de sanctions pour fraude financière et intégré dans des modèles économétriques reliant niveau d'adoption de l'IA, probabilité de fraude et gravité des sanctions. Cette approche par analyse textuelle permet aux auteurs de montrer que plus le score d'adoption de l'IA est élevé, plus la probabilité et la gravité de la fraude financière sont réduites.

L'IA semble donc favoriser une transparence de l'information en traitant des volumes massifs de données impossibles à vérifier manuellement, tout en permettant une automatisation rigoureuse de la détection d'anomalies. Même si ces conclusions concernent l'intelligence artificielle au sens large, elles sont également transposables à l'IAG, qui est aussi efficace

pour repérer des incohérences (probabilistiquement) dans les flux d'informations textuels et financiers de l'entreprise.

L'IAG se positionne également comme un partenaire cognitif capable d'épauler l'auditeur, notamment en facilitant la synthèse de textes ou l'agrégation d'indicateurs complexes. À ce titre, les travaux de Lu et al. (2025) confirment l'aptitude de l'IAG à générer des informations cohérentes, simulant ainsi une forme d'expertise en audit. En faisant collaborer des modèles spécialisés (Moonshot pour l'analyse narrative et DeepSeek-R1 pour les données financières), ces recherches ont permis de prédire des opinions d'audit avec un taux de réussite de 89,30 %.

Toutefois, cette performance repose sur des mécanismes probabilistes. L'étude souligne d'ailleurs un point de vigilance essentiel : l'IAG peut produire des justifications très convaincantes qui créent une illusion d'expertise, un véritable « mirage de jugement professionnel ». À ce stade, l'auditeur doit donc faire preuve d'un scepticisme actif et ne pas considérer les productions de l'intelligence artificielle comme des résultats acquis d'avance.

Cependant, cette situation soulève un paradoxe car la capacité à superviser efficacement les résultats générés par l'IAG dépendra des connaissances et de l'expérience de l'auditeur. Mais si ce dernier a constamment eu recours à l'IAG, il y a un risque qu'il ne maîtrise pas suffisamment le sujet pour mener à bien cette supervision, en particulier chez les auditeurs juniors.

En se penchant sur les travaux de Samiolo et al. (2024), on retrouve cette analyse : les auteurs remettent en cause la distinction entre les tâches de « haut » et de « bas » niveau (collecte de données, vérifications de base), considérant que ces tâches sont essentielles pour permettre à l'auditeur d'acquérir son jugement professionnel et de développer sa capacité de « sense-making », c'est-à-dire d'interpréter les informations, de les relier au contexte et de leur donner un sens cohérent en vue de formuler une conclusion d'audit. Si on délègue ces tâches à l'IAG alors on ne supprime pas seulement la tâche répétitive mais aussi une étape clé durant laquelle l'auditeur peut s'entraîner, développer ses compétences et commencer à interpréter les données. Le risque étant qu'en automatisant ces tâches, l'auditeur ne puisse plus avoir de processus d'apprentissage alors qu'il s'agit d'un moment important dans sa formation. On risque de priver les professionnels de l'audit, notamment les juniors, de l'expérience nécessaire pour superviser et contester les résultats de l'IAG. Ils risquent donc de devenir

dépendants de l'IAG et d'être des utilisateurs passifs, qui se fieraient aveuglément à la machine sans exercer leur jugement professionnel. Il existe ainsi un risque à se fier à une boîte noire : le jugement serait délégué à une IAG qui repose sur des probabilités. En mettant de côté l'éthique et la responsabilité, l'IAG ne serait alors plus un outil d'aide à la décision, mais une boîte noire dont on accepterait les conclusions sans les analyser, ni les questionner, ni les remettre en cause.

1.2. Le cadre théorique de l'acceptation technologique (TAM)

Notre travail de recherche repose en grande partie sur le cadre théorique du « Technology Acceptance Model » (TAM) de Davis (1989). Cette théorie indique que l'adoption d'un outil numérique ne dépend pas de ses performances ou capacités réelles mais de la perception, forcément subjective, qu'en a l'utilisateur.

Le TAM définit deux variables principales, deux piliers, d'un côté, l'utilité perçue, soit la vision qu'a l'utilisateur de l'utilité de la technologie, et de l'autre, la facilité d'usage perçue, soit la simplicité d'utilisation et de prise en main de l'outil. Ces deux variables influencent l'utilisation effective de la technologie. Dans notre cas, elles modifient les perceptions de l'auditeur et contribuent à la formation d'une intention et d'une attitude, qui déterminent s'il utilisera ou non l'IAG.

Dans cette perspective, l'auditeur pourrait percevoir l'IAG comme un outil utile pour réaliser ses tests et ses contrôles, la juger facile à manier et à utiliser, et ainsi l'intégrer naturellement dans son travail. À l'inverse, il pourrait percevoir l'IAG comme peu performante, et difficile à utiliser et donc l'exclure de ses outils de travail. Il prendra également en compte les risques potentiels de l'utilisation de l'outil comme les hallucinations, ou la notion de boîte noire et son manque d'explicabilité.

C'est l'arbitrage entre ces deux situations qui définit, in fine, s'il utilise l'IAG. Ce modèle constitue donc notre point de départ pour comprendre pourquoi un auditeur décide ou non de recourir à l'IAG. Toutefois, cette adoption doit être nuancée par l'exercice du jugement professionnel et du scepticisme. En effet, même si l'outil apparaît très utile, il existe un risque de « biais d'automatisation » : l'auditeur pourrait accorder une confiance disproportionnée aux résultats fournis par la machine, au détriment de son esprit critique, ce qui serait susceptible de diminuer la qualité de son jugement professionnel.

1.2.1. L'utilité perçue et les opportunités opérationnelles

Afin de comprendre pourquoi les auditeurs adoptent l'IAG, nous nous concentrerons sur le principal critère de l'adoption, à savoir l'utilité perçue. Il s'agit d'identifier les opportunités opérationnelles et les cas d'usage concrets que l'IA générative permet de développer pour les auditeurs financiers.

On peut citer à titre d'exemple le cabinet Deloitte, qui a mis en place plusieurs outils d'IAG concrets en interne (« How we harness Generative AI for a smarter, digital audit », janvier 2024). Parmi eux, Paired est une IAG entraînée sur les données internes de Deloitte, à l'exclusion des données clients, et qui permet d'effectuer des recherches en langage naturel en interrogeant directement l'assistant IAG. Les auditeurs peuvent ainsi obtenir des réponses à des questions techniques sans avoir à consulter les manuels d'audit.

Deloitte a également mis en place DocAI pour automatiser le rapprochement entre les documents de preuves comme des contrats ou des factures avec les états financiers en extrayant automatiquement les clauses, les dates et les montants. En troisième exemple, on pourra citer la génération automatique de documentation avec leur outil ScribeAI, qui va permettre de transformer des prises de notes en documents structurés grâce à l'IA générative.

L'IAG permet également de traiter des données massives et de prévenir les risques plus efficacement. Ainsi, le cabinet KPMG affirme que son IA interne KPMG Clara, peut analyser jusqu'à 100% des transactions d'un jeu de données (dataset), dans son rapport « AI in financial reporting and audit: Navigating the new era », transformant l'audit d'une logique fondée sur le sondage vers une approche exhaustive, ce qui permet de réduire considérablement les risques. Bien qu'il s'agisse d'une IA dit « classique » on peut aisément transposer cette capacité à une IA générative.

Par exemple, sur un journal de paie, les auditeurs vont pouvoir analyser les transactions atypiques, avec des montants anormaux, ou des schémas (patterns) de fraude connus, grâce à des outils comme KPMG Clara ou RiskAI chez Deloitte.

Par ailleurs, le rapport « Auditing in the Age of Generative AI » d'avril 2024 du CAQ (Center for Audit Quality) donne d'autres exemples intéressants réalisables avec un LLM externe ou grand public : la rédaction assistée des annexes (par exemple pour le cycle immobilisations,

directement à partir des données du bilan) ou encore l'assistance au codage SQL, avec la génération de scripts d'extraction de données par l'IAG.

L'apport de l'IA dans l'audit s'appuie sur des études concrètes, comme celle de Fedyk et al. (2022), qui montre que l'investissement dans l'IA classique diminue la probabilité de retraitements comptables de 5 %. Cela s'explique par une capacité de détection de patterns d'erreurs très difficile à réaliser par une analyse manuelle humaine. Il convient de rappeler que l'IA ne connaît pas de limites de volume ou de temps et peut analyser l'ensemble des transactions, sans se limiter à un simple échantillonnage.

Toujours d'après Fedyk et al (2022), cette industrialisation de l'audit libère environ 30 à 40 % du temps qui était utilisé pour l'analyse manuelle des données, et pourrait désormais être utilisé sur des zones de risques critiques ou sur des hypothèses données par la direction. Cela permettrait aux auditeurs de disposer de davantage de temps pour exercer leur esprit critique et faire preuve de jugement professionnel.

Cependant, ces gains de productivité potentiels ont également des conséquences sur les effectifs. Dans la mesure où les tâches à faible valeur ajoutée ou répétitives peuvent être effectuées par l'IAG, telles que la saisie de données, la rédaction ou les rapprochements de documents, le volume d'auditeurs juniors au sein des cabinets diminue, jusqu'à 11,8 % après quatre années de mise en place d'outils d'IA.

À l'inverse, les postes plus avancés, comme ceux de seniors et de managers, semblent pour le moment épargnés par cette réduction des effectifs.

Les résultats de Fedyk et al. portent sur l'IA traditionnelle, mais ils sont transposables à l'IAG, dans la mesure où celle-ci est en capacité de reproduire la majorité des cas traités par l'IA classique, voire de les traiter de manière plus performante. En effet, là où l'IA classique repose sur des règles de détection figées, à savoir des termes exacts et des patterns statistiques codés en dur qui ne peuvent pas s'adapter en temps réel, l'IAG tente de comprendre le contexte, ce qui lui permet d'identifier des concepts similaires même lorsque leur formulation varie.

Cette capacité de détection d'anomalies est particulièrement appréciée par les entreprises dites « leaders », qui estiment à 71 % que cette fonctionnalité constitue le premier bénéfice de l'IA

classique et générative, contre 63 % pour les autres entreprises. Par ailleurs, 36 % des sociétés leaders estiment que l'IAG apportera une forte ou très haute valeur ajoutée, selon le rapport de KPMG (2024).

La maîtrise de l'IAG est aujourd'hui une vraie opportunité pour les auditeurs, 64 % des clients attendent désormais que les auditeurs soient capables d'évaluer et d'auditer leur propre environnement de contrôle interne sur l'IA, d'après le rapport de KPMG (2024). Il est également intéressant d'examiner les cinq principales technologies en cours d'utilisation par les entreprises dominantes, avec l'IA traditionnelle en tête (84 %) mais avec un changement dès l'année suivante avec désormais 47 % de ces mêmes entreprises qui vont prioriser en premier le développement de l'IAG, montrant un fort intérêt pour cette technologie. On peut aisément supposer que ce chiffre a fortement augmenté depuis la publication du rapport, au vu des avancées récentes de l'IAG.

Enfin, KPMG estime que d'ici 2027, 99 % des organisations prévoient d'intégrer l'intelligence artificielle générative, au moins de manière ciblée ou à l'échelle de l'ensemble de l'entreprise, dans leurs processus de reporting, ce qui laisse présager une accélération continue de son adoption.. Cette évolution ne se traduit pas nécessairement par une hausse globale des effectifs, mais plutôt par une transformation des compétences recherchées. Ainsi, selon ce même rapport, 47 % des managers d'audit considérés comme « leaders » estiment que l'IA et les technologies émergentes favoriseront le recrutement et l'attraction de talents d'ici trois ans, tandis que 36 % considèrent que cet effet est déjà observable. Il s'agit là d'un enjeu stratégique majeur pour les cabinets d'audit, qui doivent investir dans l'IAG afin de renforcer leur attractivité et de se positionner au niveau des grands cabinets.

Enfin, tous ces avantages doivent être mis en perspective avec les risques et notamment la maîtrise et la formation à l'IA générative. Il y a une nécessité de valider les sorties de l'IAG et de contrôler. Il ne faut pas oublier que l'humain reste un des piliers pour l'utilisation de l'IAG. Si l'auditeur n'en est pas conscient ou ne perçoit pas les risques associés, il risque de faire aveuglément confiance à l'IAG.

1.2.2. La Maîtrise fonctionnelle comme facteur d'adoption

Pour que les opportunités et les risques soient pleinement mesurés, les cabinets d'audit doivent former leurs collaborateurs à l'utilisation de l'IA générative ou recruter des profils

d'auditeurs déjà formés à cette technologie. La formation ne doit pas s'arrêter à la seule utilité de l'IAG mais également aux limites et aux risques que cette technologie comprend.

Pour l'aspect pratique, il existe deux grandes approches : les techniques de prompting et le « fine-tuning », deux méthodes très utilisées pour les LLMs, comme l'expliquent Anica-Popa et al. (2024).

Le fine-tuning est plus complexe et n'est pas forcément adapté à tous les profils d'utilisateurs, il s'agit de modifier le modèle en lui-même pour spécialiser le modèle dans l'exécution d'une tâche. Au contraire, l'art du prompting, c'est le fait d'entrer un prompt dans une IAG, c'est lui donner des instructions à effectuer, pour le guider vers le résultat que l'on souhaite obtenir. Pour le prompting, on peut utiliser plusieurs techniques, telles que :

- Le zéro-shot prompting consiste à demander à une IAG d'effectuer une tâche ou de résoudre un problème à partir d'une simple instruction, d'un simple prompt, sans fournir d'exemple sur cette tâche ni de démonstration spécifique.
- La scénarisation (role playing), qui consiste à donner un rôle spécifique à l'IAG, Par exemple : « Tu es un auditeur avec 5 ans d'expérience spécialiste en... ». Cette approche permet de guider l'IAG pour fournir le résultat attendu en restant dans le cadre demandé.
- Le COT (Chain-of-Thoughts) qui consiste à demander à l'IAG de fournir les étapes de raisonnement qu'elle effectue pour qu'elle structure sa réflexion et ainsi améliorer la qualité du raisonnement sur les tâches complexes.

Une autre compétence indispensable est celle du prompt engineering qui consiste à créer en amont les informations que l'on va donner à l'IAG, préparer et structurer au mieux son prompt, ses instructions en amont pour obtenir des résultats précis et pertinents. Ce travail peut demander plusieurs essais et ajustements pour affiner le prompt (d'où le terme « engineering ») pour permettre d'avoir des données en sortie de qualité. En cas de mauvais prompt, l'IAG peut produire des réponses peu pertinentes ou générer des hallucinations, ce qui nuit à la cohérence des résultats. À l'inverse, un prompt correctement formulé permet de limiter ces hallucinations et d'augmenter la probabilité d'obtenir une réponse cohérente.

L'utilisation des LLMs doit s'inscrire dans un processus itératif, en plusieurs étapes, les résultats fournis par l'IA générative ne doivent pas être acceptés tels quels, ils doivent être

validés, et si nécessaire, modifier le prompt pour relancer la génération, en expliquant pourquoi la réponse ne convient pas. Ainsi, en échangeant avec l'IAG on va pouvoir affiner sur plusieurs échanges et atteindre le résultat final, cela permet également de faire progresser l'auditeur sur son analyse et son travail tout en exerçant son jugement critique.

Ces techniques permettent aux auditeurs d'optimiser les résultats générés par les LLMs et d'obtenir les meilleures réponses.

La formation permet donc de maîtriser les risques comme les hallucinations, qui sont des réponses plausibles mais incorrectes générées par l'IAG. Cela permet aussi de comprendre les biais algorithmiques possibles comme les biais d'échantillonnage, d'étiquetage, de genre, etc qui sont causés par des sources de données biaisées, incomplètes ou incorrectes sur lesquelles les modèles ont été entraînés comme ChatGPT ou Gemini, d'après Anica-Popa et al. (2024).

Par exemple, un algorithme de détection de fraude entraîné uniquement ou principalement sur des données de grandes entreprises pourrait favoriser inconsciemment les schémas de fraude typiques de ces grandes structures et rendrait plus difficile la détection des fraudes dans les PME ou les TPE à risque égal, ce qui créerait donc un biais algorithmique.

Lorsque ces biais sont connus et compris par l'utilisateur cela réduit le risque, et permet aux auditeurs de comprendre et d'analyser les résultats. Le jugement professionnel est véritablement une compétence clé pour détecter les anomalies et les vulnérabilités dans les résultats fournis par l'IA générative. L'auditeur doit être en capacité de classer les résultats comme acceptables ou non. Il doit faire preuve d'esprit critique pour analyser les résultats.

Cette exigence de double compétence, à la fois technique et professionnelle, est au cœur de ce que Liang et al. (2025) désignent comme le talent d'audit numérique : « Digital audit talent encompasses individuals who possess both traditional auditing expertise and proficiency in digital technologies, including Big Data analytics, artificial intelligence, and blockchain. » Ce sont des auditeurs qui ont une double compétence, avec une expertise traditionnelle en audit, et une compétence sur les nouvelles technologies numériques. Ces auditeurs réduisent significativement le niveau du risque de non-détection, soit le risque qu'une anomalie existe et ne soit pas détectée par l'auditeur. Ils peuvent identifier plus facilement les risques cachés et les anomalies en analysant les transactions des clients et les accès aux systèmes. Ils

peuvent aussi mettre en place des workflows (suite d'étapes pour réaliser un processus) pour réduire l'intervention humaine, minimisant ainsi les risques d'erreurs.

Il convient néanmoins de souligner que, dans les petites organisations, le recrutement de talents numériques bénéficie significativement à l'audit, tandis que dans les grandes organisations, un alignement organisationnel préalable est nécessaire pour éviter des résistances structurelles.

Il apparaît que plus l'auditeur est formé et compétent, plus il réduit son incertitude perçue face aux résultats produits par l'IAG. Ils peuvent évaluer de manière plus critique les résultats. La compétence technique va, selon Anica-Popa et al. (2024), avoir un rôle protecteur contre les automatismes inconscients, l'auditeur formé aux technologies ne validera pas sans vérifier les résultats IAG mais exercera son jugement professionnel et sa pensée critique : « The response returned by the system will be subject to a content check and analysed by the person using it. Professional judgement will be the key competence to detect certain anomalies or vulnerabilities in the output. At this stage, the same set of profession-specific competencies will be called upon, coupled with others which fall within the sphere of personal cognitive skills, such as critical thinking. » Ces compétences de raisonnement professionnel seront indispensables pour ne pas devenir un utilisateur ou un consommateur passif des résultats de l'IAG.

Cette demande de talents numériques se manifeste dans les travaux de Ham et al. (2025). Après avoir étudié près de 55 000 offres d'emploi d'auditeurs de 2010 à 2019, ils montrent que la part des demandes de compétences cognitives (résolution de problèmes, analyse, recherche) est passée de 40 % à 66 %, tandis que celle des compétences sociales (communication, collaboration) est passée de 48 % à 83 %.

Cela démontre que les entreprises ont une forte tendance, depuis une dizaine d'années, à renforcer la demande sur les compétences nécessitant du jugement, même si les résultats restent à nuancer au vu de la période choisie (2010-2019). La proportion des postes mentionnant des compétences technologiques (IA, data analytics) avait aussi fortement augmenté, passant de 10 % en 2010 à 22 % en 2019, et il y a matière à se demander si ces chiffres n'ont pas encore augmenté depuis, proportionnellement au développement de l'IA.

Si ces résultats ne sont pas directement transférables à l'IAG, ils permettent d'identifier une tendance en cabinet d'audit en faveur des compétences cognitives, sociales et technologiques.

La Maitrise fonctionnelle apparaît comme un accélérateur pour l'adoption de l'IAG au sein des équipes d'audit, elle réduit les barrières psychologiques, que ce soit l'incertitude sur la fiabilité des résultats ou le manque de confiance dans l'outil. Elle permet une utilisation plus efficace grâce à la compréhension des LLMs et la conscience des limites et des risques. La formation permet de favoriser l'utilisation réfléchie et stratégique de l'IAG.

En conclusion, la Maitrise fonctionnelle constitue un levier permettant de mieux encadrer l'IAG, en transformant un outil potentiellement risqué en un instrument dont l'usage peut être plus contrôlé et ainsi contribuer à améliorer la qualité de l'audit.

Chapitre 2 : Défis normatifs, risques et responsabilité de la chaîne d'audit

2.1. Fondements du scepticisme professionnel en audit

Le scepticisme professionnel est une partie incontournable du métier d'auditeur. Il s'inscrit comme une exigence dans le cadre normatif international et français. Il s'agit d'une notion importante, mais complexe et difficile à mesurer ou à déterminer.

Le scepticisme professionnel ne consiste pas simplement à émettre des suspicions ou à douter systématiquement. En audit, c'est avoir une posture et une attitude vigilante, évaluer de manière critique l'élément collecté dans le cadre de la mission d'audit, faire preuve de vigilance face à l'information potentiellement contradictoire ou incohérente. Il faut questionner et analyser la fiabilité des éléments ou des informations obtenus afin de s'assurer qu'ils respectent la qualité attendue et les exigences professionnelles, ce qui revient à faire preuve d'esprit critique.

De plus, le scepticisme professionnel est étroitement lié à la qualité du jugement professionnel. Il convient donc de distinguer deux approches pour en analyser les fondements.

- La première, l'approche normative, encadre explicitement l'exercice du scepticisme à travers les obligations professionnelles du commissaire aux comptes (CAC), que ce soit par les normes d'audit, les normes d'exercice professionnel (NEP) ou le code de déontologie.

- La deuxième, l'approche théorique, va décomposer le concept en caractéristiques psychologiques et comportementales, pour mesurer le scepticisme professionnel et expliquer les mécanismes cognitifs, à travers le modèle de Hurtt (2010).

Ces deux approches vont nous permettre de comprendre les obligations qui s'imposent et les mécanismes psychologiques qui définissent ce scepticisme professionnel.

Nous allons donc détailler, dans les sections suivantes, le cadre normatif permettant de comprendre le comportement attendu des auditeurs, puis le modèle théorique de Hurtt pour appréhender les dimensions du scepticisme professionnel et les enjeux de l'IAG en audit.

2.1.1. Cadre normatif en France

Le cadre normatif français relatif au scepticisme professionnel en audit est développé, notamment à travers la NEP 200, qui présente les « Principes applicables à l'audit des comptes mis en œuvre dans le cadre de la certification des comptes ».

Elle précise notamment que le CAC « doit faire preuve d'esprit critique tout au long de son audit », qu'il doit « évaluer de façon critique la validité des éléments collectés » et « rester attentif aux informations qui contredisent ou remettent en cause la fiabilité des éléments obtenus ». D'après la NEP 200, le scepticisme professionnel doit dicter les décisions de l'auditeur à chaque étape de la mission d'audit, afin d'éviter le risque de non-détection d'une anomalie significative, l'objectif final étant de réduire le risque d'audit à un niveau suffisamment faible pour obtenir une assurance raisonnable sur la conformité des comptes.

Une deuxième NEP encadre la mission de l'auditeur en matière de scepticisme professionnel : la NEP 240, intitulée « Prise en considération de la possibilité de fraudes lors de l'audit des comptes ». Cette NEP permet à l'auditeur de distinguer l'erreur de la fraude, celle-ci étant par définition un acte intentionnel. L'auditeur doit ainsi exercer son jugement professionnel pour détecter la fraude, souvent accompagnée de manœuvres destinées à la dissimuler. La NEP 240 considère qu'il existe un risque de fraude par défaut, que l'auditeur doit prendre en compte dans son audit, notamment en « introduisant un élément d'imprévisibilité dans le choix de la nature, du calendrier et de l'étendue des procédures d'audit », ce qui permet de surprendre un fraudeur potentiel.

L'application de la NEP 240 peut être complétée par la notion de « triangle de la fraude », qui permet d'identifier les situations à risque lors des échanges au sein de l'équipe d'audit. Concrètement, on analyse trois éléments :

1. Les incitations et les pressions qui pourraient pousser la direction ou des employés à commettre une fraude.
2. Les opportunités, soit l'impression qu'il y a une faille dans le contrôle interne ou une situation qui offrirait une occasion favorable à la fraude
3. La rationalisation, qui est liée à la justification morale de l'acte par le fraudeur.



Figure 2 : Triangle de la fraude | Source : [ITESOFT](#)

En analysant ces trois dimensions, l'auditeur peut tenter de détecter des fraudes en faisant preuve de jugement et de scepticisme professionnel.

L'article 6 du code de déontologie impose également aux auditeurs d'adopter, dans toutes leurs activités professionnelles, une attitude marquée par l'esprit critique afin d'évaluer objectivement la validité et la cohérence des informations collectées montrant l'importance de cette notion pour la mission d'audit en France.

Enfin, le régulateur de la profession des CAC et des auditeurs, la H2A (Haute autorité de l'audit), anciennement H3C, définit la norme déontologique « Sécuriser les interventions du commissaire aux comptes - application des principes fondamentaux de comportement », applicable au 1er janvier 2024.

Elle définit quatre notions essentielles que l'auditeur doit garder à l'esprit lorsqu'il exerce son jugement professionnel :

1. La nature de la source des informations utilisées et la pertinence de celle-ci
2. L'ouverture d'esprit, l'auditeur devant rester ouvert à de nouveaux avis ou informations contredisant les précédentes, et nécessitant de nouveaux travaux ou la révision des conclusions initiales
3. La suffisance des informations collectées en termes de volume
4. L'adéquation des informations fournies et la cohérence globale

Ces quatre notions permettent d'affiner la définition normative du jugement professionnel et son application.

La CNCC teste et confronte ce cadre normatif aux défis de l'IAG dans le livret « Audit & Société : Propos et Débats n°6 » (décembre 2024), notamment à travers l'article d'Olivia Jouanen intitulé « L'intelligence artificielle peut-elle faire preuve d'esprit critique ? ».

L'objectif de l'article était de tester si le modèle ChatGPT-4o (version gratuite, capacités minimales) pouvait exercer un jugement professionnel authentique en appliquant la grille H2A lors de la détermination du seuil de signification. Le seuil de signification étant « le montant au-delà duquel les décisions économiques ou le jugement fondé sur les comptes sont susceptibles d'être influencés »..

La méthodologie comportait quatre prompts fournis à l'intelligence artificielle : le narratif (situation de la société), les données financières, un extrait de la NEP 320 (« Application de la notion de caractère significatif lors de la planification et de la réalisation d'un audit ») et la demande de décision finale. Cette méthodologie expérimentale a été testée sur trois scénarios différents (ALPHA, situation de base ; BETA, situation améliorée ; GAMMA, situation dégradée) à partir d'un cas pratique de start-up tech (risques élevés : frais à l'actif de R&D, faible contrôle interne, résultat négatif).

Les résultats montrent des succès partiels, mais surtout des échecs majeurs dans les configurations complexes. ChatGPT attribue un seuil de signification plus élevé à GAMMA (risques maximaux) qu'à BETA (risques minimaux), inversant totalement la logique professionnelle qui voudrait que le scénario avec un risque élevé obtienne un seuil de signification plus bas.

Cet exercice démontre que les LLMs sont capables de produire des pseudo-argumentations qui semblent plausibles et reprennent les éléments de langage propres à l'audit, mais qui reposent sur des algorithmes et des probabilités. L'utilisateur peut donc exploiter l'IAG pour enrichir les fondements et justifications de son jugement, mais cela ne saurait remplacer son esprit critique ni son jugement professionnel.

Finalement, les NEP, le code de déontologie et la H2A encadrent les auditeurs pour leur éviter de se satisfaire des apparences et ainsi limiter le risque de non-détection d'anomalies significatives et d'erreurs lors de la mission d'audit légal.

2.1.2. Modèle théorique de Hurtt et enjeux IAG

Le modèle de R. Kathy Hurtt (2010), issu de l'article « Development of a Scale to Measure Professional Skepticism », permet de mesurer les caractéristiques psychologiques et cognitives sous-jacentes (traits mentaux cachés, qui causent les comportements d'audit visibles) qui permettent à une personne d'exercer son scepticisme professionnel, dans notre cas, l'auditeur.

Hurtt considère que le scepticisme professionnel est multidimensionnel, avec des traits stables et des états temporaires influencés par le contexte de la mission. Cette notion est importante, car elle distingue bien les compétences techniques et la connaissance des normes des traits psychologiques nécessaires pour faire preuve de jugement professionnel.

Ainsi, Hurtt définit six caractéristiques psychologiques qui composent le scepticisme professionnel.

Les Fondations du Scepticisme Professionnel



Figure 3 : Les 6 dimensions du scepticisme professionnel | Source : Généré par Napkin AI

La première dimension est le « Questioning mind », ou esprit questionneur en français. Il s'agit de la disposition naturelle à interroger les informations reçues, sans acceptation passive. Hurrtt appuie cette dimension sur la philosophie du scepticisme : « Skeptics ask: "What do you mean?" seeking clarification, and "Why do you believe what you do?" ».

Cette dimension s'apparente à ce que l'on pourrait appeler de la curiosité intellectuelle, c'est une recherche de la vérité de l'information. Selon les auditeurs, cette dimension est plus ou moins respectée, avec des auditeurs qui vont naturellement poser des questions et d'autres qui vont devoir réaliser un effort pour poser des questions, cela ne leur vient pas naturellement.

La seconde dimension est la suspension du jugement (« Suspension of judgement ») : l'auditeur retient son jugement jusqu'à obtenir une accumulation suffisante de preuves, pour éviter les conclusions trop hâtives. L'acceptation de l'ambiguïté et du doute dans leurs conclusions varie selon les auditeurs, certains l'acceptent facilement tandis que d'autres exigent plus de preuves, et cette acceptation est mesurable.

La troisième dimension est appelée « Search for knowledge », soit la recherche de connaissance. L'auditeur va au-delà des informations évidentes pour approfondir son analyse. À la différence de la première dimension, il s'agit d'une curiosité proactive, c'est la recherche d'informations supplémentaires et non simplement d'une validation. C'est une qualité

indispensable à l'audit, car elle explique pourquoi l'auditeur va chercher d'autres sources d'informations pour les croiser et construire son opinion plutôt que de se contenter du premier document reçu.

La quatrième dimension est la compréhension interpersonnelle, ou « Interpersonal understanding ». L'auditeur doit comprendre les motivations humaines et les biais potentiels des acteurs audités (direction, comptables, responsables financiers). Hurtt soutient que ces acteurs vont présenter l'information de manière favorable à leurs intérêts, ainsi l'auditeur doit comprendre leurs motivations pour détecter des incohérences ou des mensonges, notamment à travers la lecture des signaux humains, non verbaux par exemple. Cela permet aux auditeurs d'aller plus loin que la simple application de leurs procédures et de détecter des signaux supplémentaires.

La cinquième dimension est la confiance en soi (« self-esteem » en anglais). L'auditeur doit avoir suffisamment confiance en lui pour challenger les réponses qu'il obtient, que ce soit de la direction ou d'autres experts. Un auditeur avec une faible estime de soi accepte trop facilement des arguments d'autorité, alors que celui qui a une bonne estime de soi sera en capacité de remettre en question les informations qu'il obtient.

Enfin, la sixième dimension est l'autonomie (« autonomy »). L'auditeur doit former ses propres conclusions et exercer son jugement de manière indépendante. Il doit être libre de prendre ses propres décisions sans subir l'influence ou la pression des autres.

Le modèle de Hurtt distingue ainsi deux composantes du scepticisme : les traits stables (les six dimensions) d'une part, et le contexte situationnel d'autre part. Ces deux éléments définissent, en fin de compte, les actions concrètes de l'auditeur. Ainsi, un auditeur aux traits faibles peut développer un fort scepticisme sur un dossier à contexte particulier (par exemple, une fraude probable), tandis qu'un auditeur aux traits forts peut voir son jugement professionnel s'éroder ou s'effacer sous l'effet d'un contexte décourageant (pression hiérarchique).

La difficulté étant que l'intelligence artificielle générative, si elle est capable de lire et d'intégrer les éléments de contexte qui lui sont fournis, ne sait pas pour autant en tirer le bon jugement professionnel. En effet, traiter mécaniquement une information contextuelle ne

suffit pas : encore faut-il disposer des six dimensions psychologiques des traits stables pour l'interpréter correctement. Or, c'est précisément sur ces six dimensions que l'IAG présente encore des manquements significatifs.

En effet, elle n'interroge pas les informations (esprit questionneur), produit des conclusions hâtives (suspension du jugement), se limite à répondre à la question posée sans rechercher activement la vérité (recherche de la connaissance), ne comprend pas les motivations humaines et ne perçoit pas les signaux comportementaux (compréhension interpersonnelle). Sa confiance en soi reste artificielle et ses réponses peuvent être facilement remises en question par de simples corrections (confiance en soi). Enfin, l'intelligence artificielle manque d'autonomie réelle, car son fonctionnement demeure strictement dépendant des instructions de l'utilisateur. En outre, sa propension à produire des réponses conformes aux attentes de l'interlocuteur (biais de complaisance) limite sa liberté de jugement et sa capacité à exercer une contradiction objective.

Ainsi, au stade actuel de l'évolution de l'intelligence artificielle générative, son utilisation doit être supervisée et s'inscrire dans une collaboration avec un auditeur qui possède les traits et qualités nécessaires à l'expression d'un réel jugement professionnel.

2.2. Origines et manifestations des risques liés à l'IAG en audit

L'intelligence artificielle générative, comme nous l'avons vu précédemment, imite le raisonnement humain, mais ne raisonne pas réellement ; elle est conçue pour simuler un raisonnement.

Reposant sur un modèle probabiliste, elle privilégie ainsi la forme sur le fond : la fluidité, la cohérence et la logique apparente du discours priment sur l'exactitude des faits. Cette manière de fonctionner crée une incertitude sur les sorties de l'IAG, qui s'oppose à l'exigence et aux besoins de l'auditeur d'obtenir des informations suffisantes, appropriées, sourçables et fiables.

Dans le domaine de l'audit, on attend des auditeurs un jugement professionnel irréprochable, une traçabilité du raisonnement à partir des preuves et une prise de responsabilité sur les travaux rendus. Cependant, on peut supposer que les gains d'efficacité et de productivité espérés, tant par les clients que par les auditeurs, vont fortement inciter ces derniers à utiliser

l'IAG. Cette utilisation ne doit cependant pas se faire à l'aveugle : l'auditeur doit impérativement maîtriser les risques, les biais et les limites techniques inhérents à ces outils.

Nous explorerons donc dans un premier temps les dérives potentielles de l'utilisation de l'IAG sur le plan cognitif, à travers la surconfiance et les biais qui y sont associés. Nous étudierons ensuite les risques techniques soulevés par la complexité et l'opacité des modèles, les hallucinations et le manque de contrôle sur les données. Cette analyse permettra de mieux comprendre les risques et biais susceptibles d'influencer la perception et l'utilisation de l'IAG par les auditeurs.

2.2.1. Risques cognitifs et biais

L'IAG est intégrée de manière croissante dans les processus d'audit, comme le montrent les informations recueillies par KPMG, dont une étude menée auprès de 1 800 responsables du reporting financier révèle que presque les trois quarts des entreprises utilisent déjà l'IA dans leurs processus, et Deloitte, qui décrit comment la genAI transforme concrètement la conduite de l'audit. Ce n'est pas simplement un nouveau logiciel ou un nouvel outil, elle modifie réellement la manière de faire de l'audit. Mais cette nouveauté technologique qu'est l'IAG introduit également de nouveaux risques, notamment cognitifs, qu'il faut maîtriser.

Munoko et al. (2020) ont identifié un risque majeur : le « biais d'automatisation ». Il s'agit d'une tendance cognitive amenant l'auditeur à privilégier les recommandations générées par la machine au détriment de son propre jugement ou d'informations contradictoires externes. Même si Munoko et al. (2020) traitent de l'IA au sens large et non spécifiquement de l'IAG, leurs analyses sur les biais cognitifs, la surconfiance et l'érosion des compétences restent parfaitement pertinentes, car ces mécanismes psychologiques fondamentaux s'appliquent à toute interaction auditeur-machine et sont même amplifiés par les nouvelles capacités conversationnelles de l'IAG.

Ainsi, l'usage de l'IA ou de l'IAG entraînerait une baisse de la vigilance et de l'esprit critique : l'auditeur devient un vérificateur passif, susceptible de commettre deux types d'erreurs. Une erreur d'omission, ce qui signifie qu'il ne va pas agir ou effectuer un contrôle car le système n'a pas signalé d'alerte, ou une erreur de commission, c'est-à-dire suivre une recommandation erronée du système.

Cette idée est renforcée par Fotoh & Mugwira (2025), qui indiquent que les modèles comme ChatGPT génèrent des réponses persuasives, fluides et qui ressemblent à l'argumentation humaine. Cela trompe l'auditeur en lui donnant l'impression d'avoir un expert en face de lui, alors qu'il doit avant tout faire confiance à son propre jugement professionnel.

Les travaux de Munoko et al. (2020) mettent également en avant le risque de « deskillling » (perte de compétences). Ce risque repose sur l'idée que l'expertise et l'intuition de l'auditeur se construisent principalement grâce aux tâches basiques réalisées en début de carrière, qui lui permettent de forger ses capacités cognitives et son jugement professionnel. En automatisant ces tâches via l'IA ou l'IAG, on risque que les auditeurs juniors ne parviennent pas à acquérir les compétences nécessaires pour superviser l'IA par la suite ou traiter des cas plus complexes que l'IAG ne parviendrait pas à appréhender. Il y a donc un risque de perte d'autonomie : l'auditeur serait incapable de valider le travail de la machine et en accepterait simplement les résultats sans pouvoir les contredire.

De plus, il existe de nombreux autres biais. On peut notamment citer le biais historique. En effet, Munoko et al. (2020) indiquent que les algorithmes ne sont pas forcément objectifs, car ils se basent sur des données historiques ; ainsi, si, par exemple, les données historiques des contrôles fiscaux ciblent fortement un certain secteur géographique sans justification de risque réel, l'algorithme risque d'apprendre ce biais et donc de le reproduire. Il y a également le biais d'objectivité, qui est l'illusion de l'objectivité de l'IA, car si elle a été entraînée sur des données biaisées, alors l'auditeur reproduira un jugement biaisé s'il s'en tient simplement aux conclusions de l'IA, mettant en cause sa propre objectivité.

Ces biais sont d'autant plus prononcés pour l'IAG puisque, comme le montrent les travaux de Fotoh et Mugwira (2025), les modèles ont été entraînés sur d'immenses sources de données issues d'internet et d'autres sources, qui peuvent contenir des inexactitudes, des opinions ou des informations dépassées, rejoignant l'idée du biais historique et l'amplifiant même. On peut aussi citer le biais de « plausibilité », comme vu précédemment : c'est le fait que les réponses soient argumentées et articulées de manière convaincante, même si elles peuvent contenir des informations incorrectes.

De plus, il existe également un biais de généralité : parfois, l'IAG ne parvient pas à saisir les spécificités d'un contexte ou d'une question et va donner des réponses génériques sans entrer dans les détails ; elle échouera à donner une réponse concrète et précise, adaptée à la question

et au contexte. Enfin, le dernier point que nous allons évoquer, qui est également une limite, est celui des hallucinations factuelles.

En effet, lorsque l'IAG n'a pas la réponse, elle aura tendance à inventer des faits ou des références pour renforcer la crédibilité de son argumentaire. Il convient toutefois de préciser que ces constats concernent principalement les modèles généralistes : les recherches sur les modèles fine-tunés sur des données d'audit ou utilisant le RAG, qui permettent d'ancrer les réponses sur des sources fiables et actualisées, restent encore insuffisantes pour conclure sur leur capacité à réduire ces biais dans un contexte d'audit.

2.2.2. Limites techniques de l'IAG

Au-delà des biais cognitifs, il existe d'autres limites susceptibles d'affecter la perception qu'ont les auditeurs de l'IAG.

La principale limite est la problématique de la « boîte noire », ou « Black-box issue » en anglais. Concrètement, on ne comprend pas exactement le fonctionnement interne de l'IAG et des modèles de langage (LLMs).

D'après Gu et al. (2025), la complexité du modèle est inversement proportionnelle à son interprétabilité : plus le modèle est performant et sophistiqué, plus il est complexe et inexplicable. Le problème ne réside pas dans la lisibilité du code, mais dans la nature même de l'apprentissage : les poids et paramètres du modèle sont déterminés statistiquement lors de l'entraînement pour minimiser les erreurs, sans que les développeurs eux-mêmes ne puissent expliquer pourquoi le modèle aboutit à tel ou tel résultat. L'IAG fonctionne donc comme une boîte noire, où seuls l'entrée et la sortie sont observables. C'est un défaut majeur pour un auditeur qui doit pouvoir expliquer et valider ses conclusions avec des preuves, une exigence rendue difficile par l'opacité des modèles actuels.

La deuxième limitation majeure est la tendance de l'IAG à générer des hallucinations, comme expliqué par Dong et al. (2024) : les IAG produisent des contenus convaincants mais qui sont factuellement inexacts ou complètement inventés. Les derniers modèles, comme GPT-3.5 et GPT-4 (à l'époque de l'étude), ont significativement réduit ces hallucinations, et GPT-5 ou, plus récemment encore, GPT-5.2 tendent à les faire disparaître, mais elles sont tout de même encore présentes pour le moment. On peut citer un cas concret récent avec un article des Échos du 8 octobre 2025 intitulé « En Australie, les hallucinations de l'IA mettent Deloitte

dans l'embarras », avec Deloitte qui a dû rembourser partiellement le gouvernement australien suite à un rapport qu'ils leur ont remis, rempli de fautes et d'hallucinations dues à une génération non supervisée par l'IA.

Un autre exemple peut être extrait des travaux d'Eisikovits et al. (2025), reprenant l'affaire d'avocats new-yorkais condamnés à une amende de 5 000 dollars pour avoir soumis, dans le cadre d'une affaire judiciaire, des citations de jurisprudence fictives entièrement inventées par ChatGPT lors d'hallucinations. Ces deux situations auraient pu être évitées si l'IAG avait été correctement supervisée et les résultats vérifiés avant utilisation.

Eisikovits et al. (2025) identifient également un autre risque, qui est celui de la donnée incorrecte en entrée. En effet, si une entreprise fournit intentionnellement ou par négligence des données incomplètes, inexactes ou trompeuses, le système d'IAG risque de ne pas les remettre en question et de produire des résultats faussés. Il faut donc s'assurer que les données saisies ou entrées dans l'intelligence artificielle générative soient correctes en amont pour éviter un souci de qualité des résultats en aval. Les travaux soulignent également que cette vulnérabilité est encore accentuée par le phénomène de dépendance aux données, car l'efficacité de tout système d'IAG dépend entièrement de la qualité des données d'entrée. Ce phénomène, souvent résumé par l'expression « garbage in, garbage out », signifie que la qualité des résultats produits par l'IAG est directement conditionnée par la qualité des données qui lui sont fournies en entrée.

La solution de l'IA explicable (XAI), étudiée dans les travaux de Gu et al. (2025), désigne un ensemble de méthodes visant à rendre les décisions des modèles d'IA compréhensibles et justifiables : contrairement à la boîte noire, elle cherche à expliquer pourquoi et comment le modèle est parvenu à un résultat donné. Deux approches existent : les méthodes post-hoc (LIME, SHAP), qui tentent d'expliquer les résultats après qu'ils aient été générés, et les méthodes ante hoc, généralement moins performantes car plus facilement explicables. En effet, comme on l'a vu au début de cette section, plus un modèle est performant, plus il est complexe.

La solution avec les méthodes post-hoc introduit également d'autres risques, avec des explications potentiellement trompeuses, car elles sont parfois trop simples et peuvent mener à des malentendus potentiels et donc créer une confiance dans l'IAG qui ne serait pas

légitime. De plus, selon les méthodes XAI utilisées, les explications des résultats divergent, ce qui peut donc créer un sentiment de non-fiabilité pour les auditeurs.

Enfin, ces modèles explicables sont parfois très lents et coûtent donc très cher, jusqu'à 800 heures pour traiter 344 593 enregistrements d'un jeu de données (dataset) contenant des revenus, d'après les travaux de Gu et al. (2025). En outre, les travaux précisent que pour utiliser l'XAI, il faut procéder à une double vérification : d'abord vérifier que le modèle d'IAG détecte bien les anomalies, puis, dans un second temps, vérifier que les explications de l'XAI sont correctes. Cette double vérification augmente le travail de l'auditeur et peut potentiellement annuler les gains de temps promis par l'utilisation de l'IAG.

Enfin, les modèles d'explications ne sont pas standardisés et il est difficile de définir une bonne explication, ce qui rend cette solution assez impraticable en réalité et explique l'absence d'adoption institutionnelle à ce jour, que ce soit au sein des cabinets d'audit ou des régulateurs.

Ces limites techniques et cognitives ne sont pas sans conséquences sur le plan juridique : elles soulèvent en effet des questions de responsabilité et de conformité auxquelles le cadre réglementaire tente, non sans difficultés, d'apporter des réponses.

2.3. Enjeux conformité et responsabilité

La section précédente a permis d'explicitier les risques liés à l'entraînement des modèles d'IAG, les risques cognitifs, les limites techniques ainsi que l'impact négatif que cela peut avoir sur la perception des auditeurs. La présente section aborde désormais l'impact du cadre juridique sur l'utilisation et la perception de l'intelligence artificielle générative.

Le cadre réglementaire encadrant l'IAG repose principalement sur l'EU AI Act, un règlement européen édicté en mars 2024. Fondé sur une approche basée sur le risque, ce texte demeure néanmoins insuffisant et imparfait : s'il pose un premier cadre légal pour la gouvernance de l'IAG, la traçabilité des données y est insuffisamment définie, tout comme la transparence algorithmique ou encore le traitement du phénomène des hallucinations, qui n'est pas directement abordé.

Un deuxième texte vient également encadrer son utilisation : le RGPD (Règlement général sur la protection des données), qui, bien qu'il ne cible pas directement l'IAG, régit l'utilisation des données personnelles et s'applique de fait à tout système traitant ce type d'informations.

De nombreux risques sont à prendre en compte, notamment sur la fuite potentielle des données que l'on entre dans une IAG, du fait que les modèles externes des LLMs ne sont pas sous le contrôle direct des cabinets d'audit et que les modèles internes ou semi-internes sont encore très peu développés en pratique. Les données entrées dans les machines d'IAG peuvent contenir des informations de clients à risque et confidentielles, comme des salaires, des données financières ou encore des données juridiques. Il faut donc s'assurer de respecter le cadre réglementaire lorsqu'on utilise l'IAG.

Au-delà de la conformité réglementaire, la question de la responsabilité constitue aussi un sujet très important pour l'utilisation de l'IAG. La question est de savoir qui est responsable en cas d'erreur ou encore en cas de fuite de données. L'auditeur est-il responsable de par son utilisation de l'outil, ou est-ce le cabinet d'audit qui a développé ou complété l'outil, ou encore le fournisseur du service ? La réponse demeure incertaine à ce jour.

Cette question est encore plus complexe en cabinet d'audit en raison de la chaîne de supervision hiérarchique très structurée, allant de l'auditeur junior jusqu'au commissaire aux comptes, en passant par le senior. Il est indispensable de définir clairement les responsabilités, notamment en ce qui concerne la supervision des résultats issus de l'IAG.

Nous développerons dans la section 2.3.1 la conformité réglementaire et les risques de fuite de données confidentielles, tandis que la section 2.3.2 analysera l'écart de responsabilité et la gouvernance interne à travers la supervision hiérarchique.

2.3.1. Confidentialité et conformité réglementaire

Les travaux de Jonnala et al. (2025), intitulés « EU AI Act Underrepresented and Insufficient », mettent en évidence les limites de l'EU AI Act dans le contexte de l'IAG. Si ce règlement repose bien sur une approche fondée sur le risque, il demeure trop généraliste pour appréhender les vulnérabilités spécifiques des systèmes d'IAG, telles que la traçabilité des données ou le phénomène des hallucinations. Par ailleurs, l'EU AI Act ne traite pas de

l'explicabilité des décisions produites par l'IAG, ni de l'insuffisance que cela engendre pour la validité des preuves d'audit.

Le RGPD constitue ainsi un second pilier réglementaire en matière de protection des données à caractère personnel. Bien qu'il ne soit pas spécifique à l'IAG, il impose notamment la confidentialité des données clients, une exigence que les cabinets d'audit peinent à garantir lorsqu'ils recourent à des modèles externes, comme le soulignent Munoko et al. (2020). En effet, le respect de ces obligations légales requiert un contrôle strict du traitement des données, techniquement difficile à assurer sans le recours à des modèles internes, ce qui génère un risque structurel inhérent à l'utilisation de l'IAG dans ce contexte.

Pourtant, de nombreuses données sensibles sont susceptibles de transiter via des IAG, telles que les données financières, salariales, juridiques ou encore stratégiques. Si ces données venaient à sortir lors d'une fuite de données ou étaient insuffisamment protégées lorsqu'elles sont entrées dans l'IAG, cela pourrait avoir des conséquences désastreuses : les concurrents pourraient s'en servir contre le client audité ou des données sensibles comme les salaires pourraient être publiées. Cela constituerait une violation du RGPD et pourrait ainsi engager la responsabilité civile ou pénale de l'auditeur ou du commissaire aux comptes.

Des incidents concrets ont déjà eu lieu, comme le rapportent Jonnala et al. (2025), avec une exposition de code source via ChatGPT en mai 2023, après que des ingénieurs de Samsung aient utilisé l'IAG pour faire du développement. Cela avait conduit Samsung à bannir l'utilisation de ChatGPT et d'autres IA pour tous ses employés afin d'éviter les risques de fuites de données sensibles. Ou encore, en mars 2023, avec le bannissement temporaire en Italie de ChatGPT suite à des fuites de données avec des informations d'utilisateurs qui étaient accessibles à d'autres utilisateurs.

Des solutions semblent s'esquisser pour lutter contre ces problèmes, notamment la conclusion de contrats de confidentialité entre le cabinet d'audit et le prestataire d'IAG (ChatGPT, Gemini). Cependant, il est très difficile de vérifier le respect technique de ces engagements : comment s'assurer que le fournisseur n'exploite pas les données insérées dans l'IAG ? Même lorsque des clauses de confidentialité sont inscrites dans les contrats, l'architecture opaque des LLMs crée une asymétrie d'information difficilement surmontable entre le client et le

prestataire. À ce jour, il n'existe pas de mécanisme d'audit permettant de tracer et de contrôler le traitement des données saisies dans le système d'IAG (principe de la boîte noire).

Les données peuvent, de toute manière, toujours être interceptées lorsqu'elles transitent par les serveurs, et l'éditeur reste susceptible de présenter des vulnérabilités exploitables par des attaques malveillantes, comme l'indique le rapport du CAQ (2024) : « The company's genAI technology is susceptible to cyber-attacks, including data poisoning, malicious prompt injections, or malicious overriding of prompts. »

Une autre solution envisageable, qui est directement applicable par les auditeurs, serait de faire une sélection plus stricte quant aux données entrées dans l'IAG.

En se limitant à des données non sensibles, ou à des données accessibles au public, ou encore en anonymisant les données lors de l'envoi dans une IAG, on peut limiter les conséquences en cas de fuite de données.

Ainsi, pour parvenir à respecter le cadre juridique et légal mis en place par l'EU AI Act et le RGPD quant au traitement des données, les cabinets d'audit doivent mettre en place de bonnes pratiques (anonymisation des données, limitation des données saisies), des contrats juridiques solides (clauses de confidentialité avec le prestataire) ou encore des solutions internes sans transit de données en ligne (modèles de LLM internes). L'ensemble de ces solutions doit permettre de limiter le risque lié aux fuites de données et au respect de la loi.

Cependant, la question de la responsabilité en cas de fuite de données ou d'erreurs imputables à l'IAG demeure complexe et sera approfondie dans la section suivante.

2.3.2. Responsabilité et supervision hiérarchique

L'introduction de l'IAG crée une zone grise dans l'attribution de la responsabilité en cas d'erreur en audit (hallucination, biais, fuite de données). Historiquement, l'audit repose sur une chaîne de supervision stricte : le junior réalise les tâches, le senior vérifie le travail effectué et le manager valide pour que l'associé puisse signer les travaux.

Cependant, l'IAG n'est pas directement responsable de ce qu'elle produit : elle ne peut pas rendre des comptes ni être tenue responsable d'une erreur, ce qui oblige l'auditeur à assumer la responsabilité d'un résultat qu'il n'a pas entièrement produit mais uniquement supervisé, sans pour autant en maîtriser pleinement les mécanismes. Il convient ici d'insister sur le

principe de la boîte noire, tel qu'expliqué par Munoko et al. (2020), qui constitue l'un des enjeux les plus structurants de l'utilisation de l'IAG en audit.

L'auditeur junior va donc produire des résultats dont il ne maîtrise pas le cheminement. Le problème est que l'auditeur senior va devoir valider le travail, alors que les justifications seront parfois cohérentes mais incorrectes, car elles peuvent être issues d'hallucinations ou d'erreurs de l'IAG. Comme le travail n'a pas été réalisé directement par l'auditeur junior, il est difficile, même avec les preuves et les sources de son travail, de s'assurer que la justification est réellement correcte. C'est le problème de l'explicabilité de l'IA évoqué précédemment. Le risque est alors d'aboutir à une supervision et une validation de « façade », dans laquelle la chaîne hiérarchique valide et appose sa signature sans être en mesure de vérifier réellement la qualité des travaux, une supervision qui s'apparenterait davantage à une formalité administrative. Ce danger est directement souligné par Li et Goel (2025), dont les travaux rappellent qu'en contexte d'audit : « when conducting an audit, [one needs] to know how this model does what it does. Like a black box is not acceptable [because] if the company has no documentation of how the system was built, it takes a really long time to audit [or becomes impossible] » .

De plus, en audit, la réalisation des tâches basiques est très importante, car elle permet, lorsqu'on monte en grade, de comprendre ce que l'on contrôle et valide, puisqu'on l'a déjà fait soi-même. Cette notion a déjà été évoquée dans la section sur l'IA et le jugement probabiliste, mais il s'agit d'un thème central. En effet, si les juniors ne pratiquent plus, ils ne peuvent plus apprendre en faisant et seront donc incapables de superviser et de porter la responsabilité de travaux qu'ils ne comprennent pas lorsqu'ils monteront en grade. Cette fragilisation de la chaîne hiérarchique est notamment expliquée dans l'étude de Vitali et Giuliani (2024), où une personne interrogée souligne que : « The classic pyramid can change, becoming more tapered and steeper as the people who carry out manual activities are replaced (...) gradually, by machines » (Vitali et Giuliani, 2024).

L'IAG peut aussi créer des tensions dans les grands cabinets d'audit (Big 4), car la stratégie de déploiement de l'IA y est centralisée. Le siège national, voire mondial, décide d'investir, de développer et valide l'utilisation des outils d'IA pour l'ensemble des cabinets, car cela coûte cher et nécessite de l'expertise ainsi qu'un contrôle des risques. Mais sur le terrain, la décision de déployer concrètement l'outil sur une mission précise reste locale : c'est l'associé

du bureau local qui décide s'il aura recours à l'IAG, puisque c'est lui qui signera le rapport final.

Les travaux de Law et Shen (2025) illustrent concrètement ce décalage à travers des entretiens avec des associés : « investment in AI is centralized at the national level, but the decision to deploy it often resides at the local audit office level ». Ils ajoutent que la mise en œuvre de l'IAG dépend fortement du terrain : « although the AI tools and technologies are primarily developed centrally, their implementation is decided primarily locally by the local audit offices ». La stratégie centralisée des Big 4 présente donc des avantages, mais elle doit être menée en concertation avec les associés des bureaux locaux. À défaut, ces derniers pourraient avoir l'impression de devoir assumer seuls la responsabilité de ce nouvel outil, qui n'est pas toujours maîtrisé, et le percevoir non pas comme une aide, mais comme une source d'insécurité, de risque juridique et professionnel.

Les conséquences concrètes de l'utilisation de l'IAG sont que les personnes supervisant les travaux deviennent le dernier rempart et seront probablement responsables juridiquement. Elles doivent donc s'assurer que l'IAG ne produit pas de réponses biaisées ou erronées. Le superviseur ne doit pas seulement vérifier que les réponses sont plausibles, car il existe un risque d'hallucination. Avant toute validation, il doit vérifier comment les résultats ont été obtenus, si l'utilisation de l'IAG respecte le code de déontologie, si le jugement professionnel de l'auditeur a bien été exercé et s'il ne s'est pas simplement reposé sur les premiers résultats proposés par l'IAG, comme l'indiquent Munoko et al. (2020).

Finalement, pour combler ce problème de responsabilité, la supervision en audit ne peut plus se contenter de ses mécanismes traditionnels et de la supervision hiérarchique classique.

Elle doit impérativement évoluer vers ce que l'on pourrait qualifier de supervision « augmentée » et « techno-lucide ». Cela implique que la légitimité du superviseur ne repose plus uniquement sur son expérience purement technique, mais également sur sa capacité à « auditer la machine » elle-même.

Pour valider ou signer en toute confiance les travaux réalisés, les responsables de mission, mais également les auditeurs, doivent acquérir ce que la littérature appelle l'« AI Readiness » : savoir challenger l'outil, exiger des pistes d'audit explicables (logs), tester les résultats générés et détecter d'éventuelles hallucinations. Comme le soulignent Li & Goel (2025), l'enjeu n'est pas de freiner l'adoption de l'IA, mais de s'assurer que l'auditeur conserve la

maîtrise du processus, afin que la responsabilité finale portée par l'humain reste pleine et entière, et non une simple validation administrative.

Chapitre 3 : Développement des hypothèses

3.1. Synthèse de la revue de littérature et formulation des hypothèses

La revue de littérature nous a permis de mettre en évidence la rupture technologique que représente l'IA générative, ses avantages et opportunités, mais également ses biais, ses limites techniques et les risques qui en découlent. Nous avons notamment rappelé que l'IAG est une machine qui « réfléchit » par probabilités (agent de jugement probabiliste), qu'elle choisit le token le plus probable, ce qui l'amène parfois à halluciner avec une apparente assurance, à reproduire des biais issus de ses données d'entraînement, ou encore à produire des argumentations convaincantes mais factuellement incorrectes (Fotoh & Mugwira, 2025 ; Dong et al., 2024). Cette dualité crée une tension entre la perception positive (des gains potentiels d'efficacité et d'opportunités opérationnelles) et la perception négative (les risques de responsabilité, les limites techniques), qui influence l'utilisation effective de l'IAG.

3.1.1 Modèle conceptuel : Adoption technologique et jugement professionnel

Notre modèle conceptuel repose sur trois cadres théoriques fondamentaux, qui sont :

Le TAM (Technology Acceptance Model, Davis 1989), qui permet d'analyser les raisons théoriques de l'adoption de l'IAG, à travers l'utilité perçue (Perceived Usefulness) et la facilité d'utilisation (Perceived Ease of Use). Appliqué à l'IAG, il permet d'expliquer pourquoi certains auditeurs adoptent activement ces outils tandis que d'autres les évitent, indépendamment de leur disponibilité au sein du cabinet.

Le modèle de Hurtt (2010), qui décompose le scepticisme professionnel en six dimensions cognitives et comportementales : l'esprit questionneur, la suspension du jugement, la recherche active de connaissance, la compréhension interpersonnelle, la confiance en soi et l'autonomie. Ces dimensions définissent la qualité du jugement de l'auditeur, et c'est précisément ce que l'IAG menace : le biais d'automatisation (Munoko et al., 2020) tend à éroder l'esprit questionneur, tandis que l'opacité algorithmique compromet l'autonomie de la

conclusion. Ce modèle nous permet ainsi de justifier que l'auditeur reste le seul superviseur légitime face aux risques de l'IAG, tout en formalisant l'hypothèse que cet usage peut, selon les conditions, affecter son jugement professionnel.

La notion de talent digital de Liang et al. (2025), qui désigne la capacité d'un auditeur à combiner expertise métier et Maîtrise fonctionnelle des outils numériques. Cette maîtrise, formation au prompting, capacité à identifier les hallucinations, compréhension des biais algorithmiques, agit comme un modérateur qui réduit l'incertitude face aux outputs de l'IAG. Elle constitue le lien entre les deux cadres précédents : c'est parce que l'auditeur maîtrise l'outil qu'il peut en tirer les bénéfices du TAM sans sacrifier le scepticisme que préconise Hurr.

3.1.2 Développement des hypothèses de recherche

Ce cadre théorique nous permet de formuler six hypothèses afin de structurer notre étude empirique :

H1 : L'utilité perçue de l'IA générative influence positivement son utilisation.

Cette hypothèse vise à vérifier si le modèle TAM s'applique effectivement à l'IAG, et si la perception d'un gain d'utilité par l'auditeur, qu'il s'agisse d'un gain de temps, d'une amélioration de la qualité des travaux ou d'une meilleure détection d'anomalies, a un impact positif sur son utilisation effective.

H2 : La facilité d'utilisation perçue de l'IAG influence positivement son adoption effective.

Elle suggère que la manière dont l'IAG est perçue, comme simple ou complexe à utiliser, influence directement son adoption par l'auditeur, indépendamment de l'utilité qu'il peut lui reconnaître par ailleurs.

H3 : La perception des risques influence négativement l'intention d'utiliser l'IA générative.

Cette hypothèse vise à analyser si la conscience des risques, des limites et des biais perçus de l'IAG, hallucinations, confidentialité des données, opacité algorithmique, risque de responsabilité individuelle, a un impact négatif sur son utilisation par l'auditeur, y compris chez ceux qui en reconnaissent l'utilité.

H4a : Le niveau de formation et de maîtrise fonctionnelle agit comme un modérateur positif sur la relation entre risques perçus et utilisation de l'IAG.

Cette hypothèse permettra d'examiner si la formation et la Maîtrise fonctionnelle de l'auditeur sont susceptibles d'atténuer l'effet inhibiteur des risques perçus. Un auditeur bien formé devrait être moins freiné par ses inquiétudes que son homologue sans formation, à niveau de risques perçus équivalent.

H4b : La maîtrise fonctionnelle de l'IAG est positivement associée au scepticisme professionnel de l'auditeur.

Cette hypothèse, directement ancrée dans le modèle de Hurtt (2010), part du principe que plus un auditeur maîtrise l'IAG, plus il conserve son esprit critique face à ses résultats. Un auditeur qui sait utiliser l'outil, formuler de bons prompts et détecter ses erreurs, devrait être mieux armé pour ne pas en accepter les conclusions sans les questionner.

H4c : La perception des risques liés à l'IAG est négativement associée au scepticisme professionnel de l'auditeur.

Cette hypothèse postule qu'un auditeur conscient des risques de l'IAG, mais incapable de les maîtriser, finit par perdre confiance en son propre jugement et délègue ses conclusions à la machine. Autrement dit, la conscience des risques, sans les moyens d'y répondre, éroderait l'esprit critique plutôt que de le stimuler.

H4b et H4c testent ainsi les deux faces d'une même question : qu'est-ce qui protège ou érode le jugement professionnel de l'auditeur face à l'IAG ?

Ces hypothèses définissent le cadre analytique de notre recherche. La seconde partie de ce mémoire sera consacrée à la présentation du protocole méthodologique retenu pour tester ces relations, ainsi qu'à l'analyse des résultats issus de notre enquête.

Partie II : Recherche Empirique

Chapitre 4 : Protocole méthodologique et dispositif de recherche

4.1. Positionnement épistémologique et choix de la méthode

Avant de présenter les résultats de notre enquête, il convient d'expliquer les choix méthodologiques qui ont guidé notre démarche de recherche. Notamment, pourquoi nous avons choisi cette méthode plutôt qu'une autre, et comment nous avons construit notre dispositif de collecte de données.

4.1.1. Ancrage épistémologique

Notre recherche adopte une démarche hypothético-déductive. Concrètement, cela signifie que nous sommes partis de la littérature académique pour formuler des hypothèses, que nous avons ensuite testées sur le terrain à travers une enquête auprès d'auditeurs en exercice.

De plus, cette démarche s'inscrit dans le paradigme explicatif (positiviste), dans lequel la réalité est considérée comme objective et les relations entre variables peuvent être mesurées et généralisées.

Ce cheminement est le fil conducteur de ce mémoire : la revue de littérature présentée en Partie I nous a permis de mobiliser des cadres théoriques reconnus, notamment le modèle TAM de Davis (1989) et le modèle de Hurt (2010), pour formuler nos six hypothèses de recherche, que nous cherchons désormais à confirmer ou à infirmer à partir des données collectées.

4.1.2. Justification du choix d'une approche quantitative

Pour tester ces hypothèses, nous avons opté pour une approche quantitative, c'est-à-dire la collecte et l'analyse de données chiffrées issues d'un questionnaire. Ce choix se justifie par la nature même de notre problématique : nous cherchons à mesurer des perceptions, à savoir l'utilité perçue, les risques perçus ou encore la facilité d'usage perçue de l'IAG, et à analyser dans quelle mesure ces perceptions influencent l'usage réel de l'outil par les auditeurs. Le questionnaire est l'outil le mieux adapté pour recueillir ces informations de manière structurée auprès d'un nombre significatif de répondants, et pour en tirer des conclusions généralisables à la profession.

Cette approche est également cohérente avec les études mobilisées dans notre revue de littérature, qui s'appuient elles aussi sur des données quantitatives pour analyser l'adoption des outils technologiques en cabinet d'audit, à l'image de Fedyk et al. (2022) ou de Munoko et al. (2020).

Le traitement statistique des données sera réalisé à l'aide de Microsoft Excel, retenu pour sa simplicité d'utilisation et sa flexibilité, en adéquation avec les objectifs de l'analyse. Ce choix méthodologique découle directement de la nature des données collectées : les réponses issues d'échelles de Likert traduisent des appréciations ordinales, assimilables à des rangs, et non à des mesures quantitatives continues.

Dès lors, le recours à des méthodes statistiques non paramétriques apparaît le plus pertinent. Contrairement aux méthodes classiques, elles ne supposent pas que les réponses suivent une courbe en cloche (loi normale), ce qui les rend plus fiables pour analyser des données issues d'échelles de Likert.

4.2. Conception du questionnaire Google Form

Afin de collecter les données nécessaires au test de nos six hypothèses, nous avons conçu un questionnaire de 36 questions diffusé via Google Form, structuré autour de six blocs thématiques. Il repose principalement sur des échelles de Likert à 7 ou 5 points, permettant de capturer des nuances dans les perceptions individuelles tout en produisant des données ordinales exploitables statistiquement. Le détail des questions utilisé est disponible en annexe 1.

4.2.1. Architecture et opérationnalisation du questionnaire

La variable dépendante centrale est la fréquence d'usage de l'IAG, mesurée principalement par la question Q1. Elle est toutefois enrichie par plusieurs questions complémentaires. Les questions Q2 et Q3 renseignent sur la nature et la diversité des outils utilisés, Q3 étant composée de neuf sous-items binaires permettant de calculer un score de diversité des outils. La question Q4 permet de qualifier le nombre et la nature des tâches réalisées avec l'IAG, en distinguant les tâches simples des tâches complexes, et est regroupée en trois niveaux pour les analyses statistiques. Enfin, la question Q5 précise si cet usage est volontaire,

recommandé ou imposé, une information essentielle afin de ne pas confondre une adoption réelle avec une simple conformité à une directive hiérarchique.

Le deuxième bloc couvre l'utilité perçue de l'IAG. La question Q6 mesure la perception de l'impact de l'IAG sur la productivité à travers dix sous-items, et la question Q7 mesure la perception de l'impact sur la qualité du travail d'audit à travers dix autres sous-items. La question Q8 mesure quant à elle la perception du gain de temps lié à l'usage de l'IAG. Ces trois questions constituent ensemble le Score d'Utilité Perçue (SUP), qui permet de tester l'hypothèse H1.

Le troisième bloc porte sur la facilité d'utilisation perçue. La question Q9 mesure la facilité de prise en main des outils IAG, la question Q10 évalue la facilité d'intégration de l'IAG au quotidien professionnel, directement dans les outils des répondants. Enfin, Q11, formulée en sens inverse, vient capter la perception du besoin de formation, une note élevée traduisant une difficulté perçue. Ces trois questions forment le Score de Facilité d'Usage (SFU), permettant de tester H2.

Le quatrième bloc est consacré à la perception des risques. Q12 mesure la conscience des hallucinations, Q13 le risque de confidentialité, Q14 le risque lié à l'opacité algorithmique dite boîte noire, et Q15 le risque de responsabilité en cas d'erreur. Ces quatre questions forment le Score de Risques Perçus (SRP), qui teste H3. Trois questions complémentaires viennent compléter ce bloc : Q16 demande aux répondants de hiérarchiser ces risques par ordre d'importance, Q17 teste directement si ces risques freinent l'intention d'augmenter l'usage de l'IAG, et Q18 adopte une logique inverse en demandant si l'usage augmenterait si les risques étaient éliminés.

Le cinquième bloc couvre les compétences et le jugement professionnel. Q19 mesure le niveau global de formation à l'IAG, Q20 le sentiment de maîtrise de l'outil, et Q21 la capacité à identifier les erreurs produites par l'IAG. Ces trois questions forment le Score de Maîtrise Fonctionnelle (SMF), qui permet de tester H4a et H4b. Les questions Q22 à Q26 mesurent le scepticisme professionnel de l'auditeur face à l'IAG : Q22 (inversée) mesure la tendance à se fier aux résultats sans vérifier, Q23 évalue la vérification active des sources, Q24 mesure si le jugement professionnel reste fort, Q25 (inversée) teste si l'auditeur se fie parfois plus à l'IAG qu'à son propre jugement, et Q26 (inversée) mesure la tendance à conclure avant d'avoir

obtenu tous les résultats. Ces cinq questions forment le Score de Scepticisme Professionnel (SSP), qui teste H4b et H4c.

Enfin, le sixième bloc porte sur les perspectives et le profil du répondant. Q27 mesure l'intention d'augmenter l'usage de l'IAG dans les six prochains mois. Q28 mesure la probabilité d'augmenter cet usage en cas de formation future, venant directement confirmer le lien testé par H4a. Q29 est une question piège dont la réponse attendue est « Neutre », utilisée comme dispositif de contrôle qualité. Q30 est une question de synthèse portant sur l'équilibre bénéfices/risques perçus de l'IAG en audit, utilisée en fin d'analyse pour vérifier la cohérence globale des réponses. Enfin, Q31 à Q36 renseignent le profil sociodémographique du répondant, à savoir l'âge, le genre, le grade hiérarchique, l'ancienneté, le type de mission et la taille du cabinet.

Les hypothèses sont testées à partir des cinq scores composites présentés dans le tableau suivant :

Tableau 1 Scores composites

Score	Signification	Questions	Variable mesurée	Hypothèse
SUP	Score d'Utilité Perçue	Q6 ($\times 10$ sous-items), Q7 ($\times 10$ sous-items), Q8 normalisée	Utilité perçue	H1
SFU	Score de Facilité d'Usage	Q9, Q10, Q11 inversée	Facilité d'usage perçue	H2
SRP	Score de Risques Perçus	Q12, Q13, Q14, Q15	Risques perçus	H3
SMF	Score de Maîtrise Fonctionnelle	Q19, Q20, Q21	Maîtrise fonctionnelle	H4a et H4b et H4c
SSP	Score de Scepticisme Professionnel	Q22 (inv.), Q23, Q24, Q25 (inv.), Q26 (inv.)	Scepticisme professionnel	H4b et H4c

Certaines questions dites « inversées » sont formulées dans le sens contraire des autres items du même score. Par exemple, Q26 (« Je conclus avant d'avoir obtenu tous les résultats ») va à l'encontre du scepticisme professionnel : un score élevé sur cette question traduit un faible esprit critique. Ces questions sont retournées selon la formule (8 - valeur déclarée) avant d'être intégrées au score. La question Q8, dont l'échelle est à 7 points, est quant à elle

ramenée à 5 points par normalisation afin d’être cohérente avec les autres questions du score SUP, selon la formule : $Q8_norm = (Q8 - 1) \times (4/6) + 1$.

4.2.2 Complément qualitatif : entretiens semi-dirigés

Afin de dépasser les limites d'une approche exclusivement quantitative et d'enrichir l'interprétation des résultats statistiques, trois entretiens semi-dirigés complémentaires ont été conduits, à la fois en visioconférence et en présentiel, entre mars et avril 2026 auprès de profils volontairement contrastés : (A) un auditeur IT passionné d'intelligence artificielle, utilisateur intensif et précoce des outils IAG ; (B) un auditeur financier senior exerçant en cabinet régional, offrant un contrepoint aux répondants majoritairement issus de structures internationales dans l'enquête quantitative et (C) un associé expérimenté, davantage concerné par les enjeux de supervision et de responsabilité professionnelle.

Ces entretiens, d'une durée de 45 à 90 minutes, suivent un guide semi-directif structuré autour des hypothèses H1 à H4c.

Les principaux chiffres de l'enquête sont présentés à l'interviewé afin de provoquer une réaction et de recueillir son interprétation, en le confrontant aux résultats obtenus dans l'enquête quantitative. L'objectif n'est pas de valider statistiquement les hypothèses, l'enquête quantitative y a déjà répondu mais de comprendre les mécanismes sous-jacents, de contextualiser les résultats et d'identifier d'éventuels phénomènes que le questionnaire n'a pas identifiés et de venir les tester. Le questionnaire figure en annexe, et les principaux résultats seront analysés dans la partie discussion.

4.3. Présentation du terrain et de l'échantillon

4.3.1. Collecte des données

La collecte des données a été réalisée entre janvier et mars 2026, auprès d'auditeurs en exercice dans des cabinets français. L'échantillonnage retenu est non probabiliste et délibéré : la diffusion a été volontairement orientée vers LinkedIn et d'autres canaux professionnels certifiés, de façon à cibler uniquement des répondants correspondant au profil recherché plutôt que de solliciter un public indifférencié. Le questionnaire a aussi fait l'objet d'un partage interne au sein de Forvis Mazars, ainsi que d'une diffusion par l'Ordre des experts-comptables des Hauts-de-France et par la CRCC des Hauts-de-France, que je remercie pour leur relais.

En parallèle, de nombreux contacts directs ont été pris auprès d'auditeurs via LinkedIn, les réseaux alumni et les contacts en cabinet, introduisant un effet de « boule de neige » : les premiers répondants ont pu à leur tour relayer le questionnaire à leurs pairs.

Le recours à un formulaire Google Forms anonyme a encouragé les répondants à s'exprimer plus librement, notamment sur des sujets potentiellement sensibles comme leur niveau réel de maîtrise fonctionnelle ou leur perception des risques.

Il convient toutefois de souligner que cette méthode d'échantillonnage non probabiliste ne permet pas de calculer une marge d'erreur statistique ni de garantir la représentativité de l'échantillon au sens strict. Les résultats obtenus devront donc être interprétés avec prudence et ne sauraient être généralisés à l'ensemble de la profession d'auditeurs.

4.3.2. Définition de la population cible

La population cible de cette étude est constituée des auditeurs notamment financiers des cabinets d'audit français, tous grades confondus, du niveau junior jusqu'aux associés et commissaires aux comptes. Le périmètre se limite aux cabinets exerçant en France, ce qui est cohérent avec le cadre normatif central de ce mémoire fondé sur les NEP, le code de déontologie de la H2A et l'EU AI Act.

La collecte a été réalisée entre janvier et mars 2026, afin de pouvoir analyser la perception des auditeurs à un moment précis d'une évolution technologique particulièrement rapide.

Le profil détaillé de cet échantillon, renseigné à travers les questions Q31 à Q36 portant sur le grade hiérarchique, l'ancienneté, la taille du cabinet et le genre, est présenté dans le chapitre suivant consacré à l'analyse des résultats.

Chapitre 5 : Analyse des résultats et discussion

5.1. Profil de l'échantillon

5.1.1. Constitution de l'échantillon analytique

La collecte de données s'est déroulée entre janvier et mars 2026 par diffusion en ligne du questionnaire auprès d'auditeurs exerçant dans des cabinets français. Quatre-vingt-cinq réponses ont été recueillies au total. Un protocole de filtrage séquentiel en trois étapes a permis de constituer l'échantillon final retenu pour l'analyse.

Tableau 2 Entonnoir de filtrage de l'échantillon

Étape	Critère d'exclusion	Exclus	Restants
0	Réponses brutes collectées		85
1	Q1 = « Jamais » non-utilisateurs	5	80
2	Q29 ≠ « Neutre » réponses inattentives	5	75
3	Q35 hors périmètre audit (EC pur, autre)	8	67
✓	Échantillon final retenu pour l'analyse	18	N = 67

La première étape exclut cinq répondants ayant déclaré n'utiliser jamais l'IAG (Q1 = « Jamais »). L'objet de la recherche portant sur les déterminants de l'intensité d'usage, l'analyse d'utilisateurs nuls aurait introduit un biais structurel dans les corrélations. La deuxième étape repose sur Q29, une question piège demandant aux répondants de cocher « Neutre » pour attester d'une lecture attentive du questionnaire ; les cinq répondants ayant sélectionné une autre option sont exclus. La troisième étape retire huit répondants dont le cœur de métier déclaré en Q35 est exclusivement l'expertise comptable ou d'autres fonctions sans lien direct avec l'audit, afin d'assurer l'homogénéité du périmètre professionnel étudié. Au total, 18 observations sont exclues sur 85, soit un taux de réponses exploitable de 78,8 %.

Note sur les quatre auditeurs non-utilisateurs

Parmi les cinq répondants ayant déclaré « Jamais » utiliser l'IAG dans leur travail, quatre sont des auditeurs financiers au sens strict du périmètre de cette étude, le cinquième étant un expert-comptable pur, exclu au titre de Q35 et non de Q1. Ces quatre auditeurs non-utilisateurs méritent un bref éclairage descriptif, non pour être réintégrés à l'analyse, leur

exclusion est méthodologiquement justifiée mais parce que leur profil renseigne sur les frontières de l'adoption.

Deux exercent dans des cabinets internationaux (Big4 ou assimilé), deux dans des cabinets locaux. Leur ancienneté est hétérogène : l'un a moins de deux ans d'expérience, deux se situent entre quatre et cinq ans, le dernier dépasse dix ans de carrière. Tous se déclarent en audit financier. Ce profil est notable à double titre : d'une part, l'ancienneté n'apparaît pas comme facteur déterminant du non-usage les non-utilisateurs ne se concentrent pas chez les seniors ; d'autre part, la taille du cabinet ne protège pas non plus contre le non-usage, deux d'entre eux exerçant dans des structures internationales qui déploient pourtant des outils dédiés (Copilot entreprise). La résistance individuelle au changement ou l'inadéquation perçue des outils aux tâches confiées pourraient expliquer davantage ce non-usage que le contexte organisationnel.

5.1.2. Caractéristiques sociodémographiques




Figure 4 Profil de l'échantillon (N = 67) : genre, âge, grade et taille du cabinet

L'échantillon de 67 répondants est composé de 45 hommes (67,2 %) et de 22 femmes (32,8 %). Cette surreprésentation masculine est cohérente avec la composition démographique de la profession en France, bien que le secteur soit en cours de rééquilibrage. Selon le baromètre CNCC 2024, la profession des commissaires aux comptes en France compte 76 % d'hommes et 24 % de femmes, un ratio qui correspond aux CAC inscrits, c'est-à-dire essentiellement des associés et signataires. La proportion de femmes dans notre échantillon (32,8 %) est donc supérieure à la moyenne nationale des CAC inscrits, ce qui s'explique par la composition de l'échantillon : celui-ci inclut des collaborateurs juniors et seniors en cabinet, où la féminisation est plus avancée que chez les signataires. Ce résultat est cohérent avec la tendance de rééquilibrage en cours dans la profession.

La structure par âge révèle une forte concentration sur les tranches les plus jeunes : 32 répondants (47,8 %) ont entre 18 et 25 ans, 17 (25,4 %) entre 26 et 35 ans, 9 (13,4 %) entre 36 et 45 ans, 5 (7,5 %) entre 46 et 55 ans, et 4 (6,0 %) au-delà de 55 ans. Cette distribution contraste nettement avec la structure démographique des CAC inscrits : l'âge moyen des commissaires aux comptes est de 52 ans en 2024, stable depuis 2018, les nouveaux inscrits en 2023 ont en moyenne 37 ans (CNCC, 2024).

La surreprésentation des 18-35 ans dans notre échantillon (73,2 %) est cohérente pour deux raisons. D'une part, elle reflète la structure pyramidale caractéristique des cabinets d'audit, que confirme la répartition par grade : les Juniors représentent 47,8 % de l'échantillon (N = 32), devant les Associés (N = 18, 26,9 %) et les Seniors-Managers (N = 17, 25,4 %). D'autre part, elle est alignée avec l'objet de la recherche : ce sont précisément ces jeunes collaborateurs qui sont en première ligne de l'adoption des outils IAG, et dont les perceptions constituent le signal le plus pertinent pour anticiper l'évolution des pratiques professionnelles.

Cette concentration sur les profils juniors ne signifie pas pour autant que l'échantillon manque de diversité. Les 18 Associés de l'échantillon apportent un contrepoint analytique très intéressant. Leur présence permet de confronter les perceptions des utilisateurs en début de carrière, plus exposés aux tâches répétitives désormais automatisables, à celles de praticiens expérimentés, davantage concernés par les enjeux de supervision, de responsabilité professionnelle et de jugement d'audit.

Cette lecture croisée âge-grade est confirmée par la distribution de l'ancienneté (Q34) : les moins de deux ans d'expérience constituent le groupe le plus important (N = 23, 34,3 %), immédiatement suivis par les plus de dix ans (N = 20, 29,9 %), puis les 2-3 ans (N = 13, 19,4 %), les 4-5 ans (N = 7, 10,4 %), les 6-7 ans (N = 3, 4,5 %) et les 8-10 ans (N = 1, 1,5 %). La distribution se concentre donc aux deux extrêmes, ce qui offre un contraste naturel entre des profils en phase d'apprentissage de l'IAG et des praticiens disposant d'un recul suffisant pour en évaluer les apports et les limites.

Du point de vue de la structure des cabinets (Q36), les cabinets internationaux concentrent une majorité de l'échantillon (N = 37, 55,2 %), devant les cabinets locaux (N = 19, 28,4 %), régionaux (N = 11, 16,4 %).

Le cœur de métier déclaré (Q35, réponses multiples autorisées) est dominé par l'audit financier : 62 répondants le citent (92,5 %), auxquels s'ajoutent 8 praticiens en audit interne (11,9 %), 7 en audit IT (10,4 %) et 3 en audit RSE (4,5 %).




Figure 5 Profil de l'échantillon (N = 67) : Cœur de métier

En conclusion cet échantillon ne prétend pas à la représentativité statistique de l'ensemble de la profession française, une telle représentativité supposerait un plan de sondage stratifié sur les 11 467 commissaires aux comptes inscrits (CNCC, 2024), ce qui dépasse le cadre de cette recherche. Il constitue en revanche un échantillon de convenance pertinent au regard de la problématique : les répondants sont majoritairement jeunes, en cabinet international et utilisateurs actifs de l'IAG, exactement le profil le plus exposé aux dynamiques d'adoption étudiées.

Trois limites de l'étude doivent néanmoins être explicitées. Premièrement, un biais de volontariat est probable : la diffusion du questionnaire par réseau professionnel et LinkedIn attire naturellement les auditeurs déjà sensibilisés à l'IAG, plus attiré par les nouvelles technologies que la moyenne de la profession. Les perceptions mesurées, notamment l'utilité perçue et la maîtrise fonctionnelle, sont donc susceptibles d'être surestimées par rapport à la population générale des auditeurs français. Deuxièmement, la surreprésentation des cabinets internationaux (55,2 %) et des profils juniors (47,8 %) limite la visibilité des pratiques dans les structures plus petites et plus traditionnelles, où les outils IAG dédiés pourraient être moins déployés et l'adhésion à ces technologies potentiellement plus faible. Troisièmement, le filtre d'inclusion appliqué en amont (exclusion des non-utilisateurs, N = 5) concentre l'analyse sur les utilisateurs actifs, laissant de côté la question des déterminants du non-usage.

Ces limites ne remettent pas en cause la validité des résultats, mais invitent à la prudence avant toute généralisation.

5.1.3. Caractéristiques d'usage des outils IAG (O2 à O5)

L'environnement d'usage privilégié (Q2) révèle que 33 répondants (49,3 %) utilisent principalement des outils fournis ou agréés par leur cabinet dans un environnement sécurisé, 21 (31,3 %) adoptent un usage mixte combinant outils dédiés et grand public, et 13 (19,4 %) s'appuient exclusivement sur des outils grand public comme ChatGPT ou Gemini.

Sur les outils utilisés (Q3), Copilot domine nettement avec 49 utilisateurs (73,1 %), devant ChatGPT (N = 36, 53,7 %), les outils spécifiques au cabinet (N = 20, 29,9 %), Gemini (N = 15, 22,4 %), Mistral (N = 9, 13,4 %), Claude (N = 8, 11,9 %), Perplexity (N = 7, 10,4 %), et Grok (N = 4, 6,0 %). La prédominance de Copilot est cohérente avec sa diffusion prioritaire dans les cabinets internationaux disposant de licences Microsoft 365 Entreprise.

Tableau 3 Outils IAG utilisés

[illegible]

Les tâches déclarées (Q4, réponses multiples autorisées) dessinent un usage concentré sur les activités rédactionnelles et documentaires, les trois premières tâches dépassant chacune 70 % des répondants. Les usages analytiques restent présents mais nettement moins fréquents, et la révision d'estimations comptables n'est citée que par 6 répondants (9,0 %), confirmant que les tâches à fort enjeu de jugement professionnel restent à l'écart des usages IAG actuels. Le détail complet est présenté dans le Tableau 4 ci-dessous.

Cette hiérarchie des usages confirme que l'IAG est aujourd'hui principalement mobilisée comme un outil de productivité sur les tâches à faible valeur ajoutée, et non comme un outil

de jugement professionnel, ce qui est cohérent avec les mises en garde de Samiolo et al. (2024) sur le risque de délégation progressive des tâches cognitives de bas niveau.

Tableau 4 Tâches réalisées avec l'IG

[illegible]

Sur le mode d'usage / raison d'utilisation de l'IAG (Q5), 46 répondants (68,7 %) déclarent utiliser l'IAG de manière volontaire, sans recommandation institutionnelle, contre 21 (31,3 %) sur recommandation ou encouragement de leur cabinet. Cette majorité d'adoptants spontanés renforce la pertinence d'étudier les perceptions individuelles utilité perçue, risques, maîtrise comme facteurs explicatifs de l'intensité d'usage, plutôt que les seules politiques organisationnelles.

5.2. Statistiques descriptives

5.2.1. Fréquence d'usage de l'IAG (Q1)

La variable dépendante Q1 mesure la fréquence d'usage de l'IAG dans le cadre du travail en audit sur une échelle ordinaire à six niveaux actifs (de « Très rarement » à « Très fréquemment ») après exclusion des personnes n'utilisant jamais l'IAG. Sur l'échantillon analytique de 67 répondants, la distribution est fortement orientée vers les modalités élevées.




Figure 6 Distribution de la fréquence d'usage de l'IAG (Q1, N = 67)

La modalité « Régulièrement (plusieurs fois par semaine) » est la plus fréquente : 26 répondants, soit 38,8 %. Suivent « Très fréquemment (plusieurs fois par jour) » avec 12 répondants (17,9 %) et « Quotidiennement » avec 9 répondants (13,4 %). En cumulé, 47 répondants (70,1 %) utilisent l'IAG à une fréquence au moins hebdomadaire. Les modalités d'usage peu fréquent « Très rarement » et « Rarement » concernent respectivement 3 (4,5 %) et 6 répondants (9,0 %). La moyenne est de 5,015/7 (médiane = 5 ; $\sigma = 1,343$).

La forte concentration sur les modalités 5, 6 et 7 indique une intégration réelle de l'IAG dans les routines professionnelles des répondants, et non un usage expérimental ou ponctuel. La variable dépendante Q1 présente ainsi une plage empirique restreinte (2-7), conséquence directe du filtre d'inclusion appliqué en amont (exclusion des non-utilisateurs). Ce phénomène de restriction de plage peut conduire à une sous-estimation des corrélations observées. Les associations entre variables seront testées par corrélation de rang de Spearman, un test non-paramétrique qui travaille sur les rangs des observations plutôt que sur leurs valeurs brutes, ce qui le rend insensible à ce type de contrainte. Le choix et les modalités de ce test sont détaillés en section 5.3.

5.2.2. Scores composites : statistiques descriptives et fiabilité interne

Cinq scores ont été créés pour mesurer les principaux concepts des hypothèses. Chaque score correspond à la moyenne des réponses aux questions associées.

Pour les questions formulées à l'envers (où être « fortement d'accord » indique en réalité un niveau plus faible du concept), les réponses ont été inversées avant calcul. Cela concerne les questions Q11, Q22, Q25 et Q26.

Pour vérifier que les questions regroupées dans un même score mesurent bien un concept cohérent, on utilise l'alpha de Cronbach, un indicateur compris entre 0 et 1. Plus les répondants répondent de façon similaire à l'ensemble des items d'un score, plus l'alpha est élevé. Le seuil conventionnellement retenu pour juger une échelle fiable est $\alpha \geq 0,70$. En dessous de ce seuil, les items mesurent des dimensions trop hétérogènes pour être agrégés sans précaution : il devient alors plus pertinent d'analyser chaque item séparément plutôt que de s'appuyer uniquement sur le score global.

Tableau 5 Statistiques descriptives et cohérence interne des scores composites (N = 67)

Score	Construit (hypothèse)	Échelle	k	Moyenne	Médiane	σ	Min	Max	α Cronbach
SUP	Utilité perçue (H1)	1-5	21	3,399	3,476	0,580	1,413	4,619	0,898 - Excellent
SFU	Facilité d'usage (H2)	1-7	3	4,766	4,667	0,962	2,667	6,667	0,663 ~ Limite
SRP	Risques perçus (H3)	1-7	4	5,537	5,500	0,883	3,500	7,000	0,316 Insuffisant
SMF	Maîtrise fonctionnelle (H4a/H4b/H4c)	1-7	3	4,781	4,667	0,879	2,333	7,000	0,452 Insuffisant
SSP	Scepticisme professionnel (H4b/H4c)	1-7	5	4,958	5,000	0,793	3,200	7,000	0,511 Insuffisant

Note : k = nombre d'items ; σ = écart-type. ✓ $\alpha \geq 0,85$; ~ $0,60 \leq \alpha < 0,70$; $\triangle$ $\alpha < 0,60$.

Seuil classique de fiabilité acceptable : $\alpha \geq 0,70$ (Nunnally, 1978).

Le score SUP présente un alpha de Cronbach de 0,898, indiquant une excellente cohérence interne entre ses 21 items (Q6, Q7 et Q8 normalisé). Sa moyenne de 3,399 sur 5 (68,0 % de l'échelle) traduit une utilité perçue élevée et peu dispersée ($\sigma = 0,580$). Cette faible variabilité aura des implications pour le test de H1 (voir section 5.3.1).

Le score SFU affiche un alpha de Cronbach de 0,663, se situant à la limite du seuil conventionnel de 0,70. Cette cohérence interne limitée s'explique par les fortes différences de ses trois items : Q9 (prise en main intuitive) et Q10 (intégration dans le flux de travail quotidien) obtiennent des moyennes élevées et proches, respectivement 5,388/7 et 5,403/7, tandis que Q11_inv (faible besoin de formation supplémentaire, inversé) n'atteint que 3,508/7. Les deux premiers items capturent la facilité d'usage immédiate, alors que le troisième reflète l'effort d'apprentissage perçu, deux dimensions suffisamment distinctes pour réduire la cohérence globale du score.

Les scores SRP ($\alpha = 0,316$), SMF ($\alpha = 0,452$) et SSP ($\alpha = 0,511$) présentent des alphas insuffisants. Ce résultat s'explique par le fait que chaque score regroupe des dimensions trop différentes les unes des autres : les quatre risques perçus (hallucinations, confidentialité, boîte noire, responsabilité) sont des phénomènes distincts que les répondants évaluent de façon indépendante ; de même, la maîtrise fonctionnelle et le scepticisme professionnel recouvrent des aspects peu liés entre eux. Ces scores sont donc utilisés avec précaution dans les tests globaux, et l'analyse question par question constitue l'approche principale pour interpréter les résultats relatifs à H3, H4a et H4b et H4c.

Ces scores seront néanmoins conservés, l'alpha de Cronbach mesurant l'homogénéité interne et non la validité conceptuelle d'un score. Ils sont toutefois mobilisés avec précaution, l'analyse par item constituant l'approche principale pour H3, H4a et H4b et H4c.




Figure 7 Scores composites : position sur l'échelle maximale et dispersion ($N = 67$)

5.2.3. Perception de l'équilibre bénéfices-risques (Q30)

La question Q30 mesure la perception globale de l'équilibre entre les bénéfices et les risques de l'IAG en audit sur une échelle de 1 à 7 (1 = les risques dominant totalement ; 7 = les bénéfices dominant totalement). La moyenne est de 5,136/7 (médiane = 5 ; $\sigma = 1,311$), ce qui traduit un penchant net en faveur des bénéfices. On a ici $N = 66$ car un répondant n'a pas renseigné la question Q30.




Figure 8 Perception de l'équilibre bénéfices-risques de l'IAG en audit (Q30, N = 66)

La distribution est fortement concentrée sur les modalités hautes : 25 répondants attribuent un score de 5 (37,9 %), 17 un score de 6 (25,8 %), et 9 un score de 7 (13,6 %). Seuls 15 répondants (22,7 %) attribuent un score inférieur ou égal à 4. La perception favorable domine donc largement, même dans un échantillon où les risques perçus sont élevés (SRP moyen = 5,537/7, soit 79,1 % de l'échelle). Cette apparente contradiction s'explique par la nature distincte des deux mesures : SRP évalue la perception de l'existence et de la gravité des risques, tandis que Q30 demande un jugement comparatif bénéfices-risques global. Un auditeur peut reconnaître l'existence de risques sérieux tout en estimant que les gains de productivité et de qualité l'emportent position qui définit précisément l'auditeur actif éclairé.

5.3. Test des hypothèses

L'ensemble des hypothèses est testé par corrélation de rang de Spearman (ρ), dont le choix est motivé par la nature ordinale des données issues d'échelles de Likert et l'absence de garantie de normalité des distributions. En effet, les réponses viennent d'échelles de type "de 1 à 5" ou "de 1 à 7" : ce sont des données ordonnées (on sait que $4 > 3 > 2$) mais on ne peut pas garantir que l'écart entre 1 et 2 est exactement le même qu'entre 2 et 3.

Pour cette raison, le coefficient de Spearman mesure l'association monotone entre deux variables sans hypothèse paramétrique. Au lieu de travailler sur les valeurs brutes, il les classe par rang (1er, 2ème, 3ème...) et mesure si quand une variable monte, l'autre monte aussi (ou descend), sans faire aucune hypothèse sur la forme des données. À partir de ρ , on

calcule également une t-stat (statistique de test), valeur intermédiaire qui permet d'en déduire la p-value.

Cette p-value représente la probabilité que le résultat soit dû au hasard. Pour la lire facilement, on utilise une notation en étoiles : (.) moins de 10 % de chances, * moins de 5 %, ** moins de 1 %, *** moins de 0,1 %. Un résultat sans étoile est noté NS (non significatif), signifiant qu'on ne peut pas exclure que la relation observée soit due au hasard.

Les calculs ont été réalisés sous Excel et vérifiés de manière indépendante via Python 3 (scipy.stats, pandas).

5.3.1. H1 Utilité perçue et fréquence d'usage

Hypothèse H1 : *Plus un auditeur perçoit l'IAG comme utile pour ses tâches professionnelles, plus il l'utilise fréquemment. Direction attendue : $\rho(SUP, Q1) > 0$.*

Le score d'utilité perçue (SUP) affiche une moyenne de 3,398/5 (médiane = 3,476 ; $\sigma = 0,580$). La corrélation de Spearman entre SUP et Q1 produit $\rho = 0,168$ (p-value = 0,174).

H1 est infirmée : l'utilité perçue ne constitue pas un prédicteur significatif de la fréquence d'usage dans cet échantillon.

Ce résultat surprend au premier abord, tant l'utilité perçue est le pilier fondateur du Technology Acceptance Model (TAM). Il s'explique par un effet de plafond. Avec une médiane à 3,476 sur 5 et un écart-type de seulement 0,580, la distribution de SUP est comprimée dans sa partie haute : la quasi-totalité des répondants perçoit l'IAG comme utile à très utile. Lorsqu'une variable présente si peu de dispersion, elle ne peut pas statistiquement distinguer les différents niveaux de comportement. Ce n'est pas que l'utilité soit sans importance ; c'est qu'elle est si largement reconnue par tous les répondants qu'elle ne permet plus de différencier ceux qui utilisent beaucoup l'IAG de ceux qui l'utilisent peu.




Figure 9 Répartition score d'utilité perçue (N = 67)

L'analyse désagrégée par items éclaire les nuances que le score global masque. Nous avons testé les 3 items dépassant 70% d'utilisation parmi les répondants, notamment l'extraction (recherche d'informations), la rédaction (rapports, synthèses) et le résumé (reformulation/traduction), en les corrélant individuellement avec Q1.




Figure 10 H1 : corrélations Spearman des items SUP avec Q1 (N = 67)

Tableau 6 H1 : corrélations item SUP → Q1 (N = 67)

Item	Moyenne	ρ Spearman	p-value	Significativité
SUP → Q1 (score global)	3,398	0,168	0,174	NS
Q6_Extraction → Q1	3,642	0,029	0,815	NS
Q6_Résumé → Q1	4,164	0,051	0,683	NS
Q6_Rédaction → Q1	4,328	0,230	0,062	(.) marginalement sig.
Q7_Extraction → Q1	3,716	0,088	0,477	NS
Q7_Résumé → Q1	4,015	0,094	0,450	NS
Q7_Rédaction → Q1	4,224	0,326	0,007	**
Q8_IAG_Gain_Temps → Q1	5,612/7	0,355	0,003	**

Q7_Rédaction « Dans quelle mesure l'IAG améliore-t-elle la qualité de vos rédactions ? » est le seul item significatif parmi les tâches indiquées par plus de 70% des répondants ($\rho = 0,326$, p-value = 0,007**). Q6_Rédaction atteint une significativité marginale ($\rho = 0,230$, p-value = 0,062). Aucun autre item extraction ou résumé n'est corrélé à l'usage.

Un test complémentaire sur Q8 « L'utilisation de l'IAG me fait gagner du temps » (échelle 1-7) produit également une corrélation significative : $\rho = 0,355$, p-value = 0,003**, avec une moyenne de 5,6/7 traduisant une adhésion très large à cette perception. Ce résultat nuance l'interprétation : ce ne sont pas une mais deux dimensions de l'utilité perçue qui prédisent l'usage intensif. Les auditeurs qui utilisent le plus fréquemment l'IAG sont ceux qui estiment à la fois qu'elle améliore la qualité de leur production écrite et qu'elle leur fait gagner du temps. La conviction d'un double bénéfice, gain de temps et qualité rédactionnelle, semble ainsi être ce que le score SUP global, trop comprimé, ne parvenait pas à révéler.

Il convient également de noter que l'item Q6_Développement (utilité perçue pour automatisation et scripts SQL/VBA), testé à titre exploratoire, produit une corrélation significative : $\rho = 0,407$, p-value = 0,001***, confirmée par son miroir Q7_Développement ($\rho = 0,350$, p-value = 0,004**). Cette association forte suggère qu'un segment restreint d'utilisateurs avancés maîtrisant la programmation et l'automatisation constitue le cœur de la population à usage très intensif.

Un test complémentaire par grade vient renforcer ce constat. On pouvait en effet supposer que la relation SUP → Q1 se manifesterait différemment selon le niveau hiérarchique : chez les juniors, la perception d'utilité devrait logiquement mieux prédire l'usage puisqu'ils adoptent l'outil de manière autonome et fonctionnelle, ce qui correspond au mécanisme central du TAM. À l'inverse, chez les grades supérieurs, d'autres facteurs pourraient dominer

comme la délégation des tâches répétitives, la pression des pairs ou des clients, ou encore une posture plus prudente vis-à-vis des risques professionnels.

Pourtant, la répartition par grade invalide cette hypothèse. Les juniors affichent une corrélation $\rho = 0,224$ (NS, p-value = 0,217), les Senior-Managers $\rho = 0,239$ (NS, p-value = 0,356), et les Associés $\rho = -0,054$ (NS, p-value = 0,830). Non seulement aucun sous-groupe n'atteint le seuil de significativité, mais la corrélation devient légèrement négative chez les Associés, ce qui suggère que chez les grades les plus élevés, une utilité perçue plus forte ne se traduit pas en usage plus intense, possiblement parce que l'usage est davantage contraint par des considérations externes que par la conviction personnelle.

Tableau 7 H1 : corrélations item SUP $\rightarrow$ Q1 par grade (N = 67)

Grade	Corrélation	N	ρ Spearman	p-value	Significativité
Junior	SUP $\rightarrow$ Q1	32	0,251	0,166	NS
Senior-Manager	SUP $\rightarrow$ Q1	17	0,148	0,570	NS
Associé	SUP $\rightarrow$ Q1	18	-0,076	0,765	NS

Ce résultat confirme donc que l'infirmité de H1 n'est pas un artefact lié à la composition de l'échantillon par grade : l'absence de relation entre utilité perçue et usage est commune à l'ensemble des niveaux hiérarchiques, ce qui pointe vers une saturation généralisée de la variable SUP plutôt qu'une hétérogénéité masquée.

Pour conclure, H1 est infirmée non par absence d'effet, mais par saturation de la variable : tous les répondants perçoivent déjà l'IAG comme utile.

5.3.2. H2 Facilité d'usage perçue et fréquence d'usage

Hypothèse H2 : *Plus un auditeur perçoit l'IAG comme facile à utiliser dans son travail quotidien, plus il l'utilise fréquemment. Direction attendue : $\rho(\text{SFU}, \text{Q1}) > 0$.*

Le score facilité d'usage (SFU) affiche une moyenne de 4,766/7 (médiane = 4,667 ; $\sigma = 0,962$). La corrélation de Spearman produit $\rho = 0,325$ (p-value = 0,007**).

H2 est confirmée : la facilité d'usage perçue est un prédicteur significatif et positif de la fréquence d'usage.

L'analyse désagrégée par items révèle que ce résultat global masque une hétérogénéité importante entre les trois composantes de SFU.




Figure 11 H2 : corrélations Spearman des items SFU avec Q1 (N = 67)

Tableau 8 H2 : corrélations item SFU → Q1 (N = 67)

Item	Moyenne	ρ Spearman	p-value	Significativité
SFU → Q1 (score global)	4,766	0,325	0,007	**
Q9 Prise en main intuitive	5,388	0,257	0,036	*
Q10 Intégration au workflow quotidien	5,403	0,492	< 0,001	*** Plus forte corrélation de l'étude
Q11_inv Faible besoin de formation	3,508	0,140	0,260	NS

L'item Q10 « L'intégration de l'IAG dans mon flux de travail quotidien est naturelle » produit la corrélation la plus élevée de toute l'étude : $\rho = 0,492$, p-value < 0,001***. De plus, Q9 (prise en main intuitive) est également significatif ($\rho = 0,257$, p-value = 0,036*), mais d'amplitude plus faible. En revanche, Q11_inv le besoin de formation supplémentaire inversé, indicateur de l'effort d'apprentissage initial n'est pas corrélé à l'usage ($\rho = 0,140$, p-value = 0,260, NS).

La distinction entre Q10 et Q11 est centrale. Elle établit que ce n'est pas la facilité d'apprentissage de l'outil qui détermine l'intensité d'usage, mais la fluidité de son insertion dans les habitudes de travail. Un auditeur ayant investi du temps en formation peut tout à fait atteindre un usage très intensif si l'outil s'est naturellement inscrit dans son flux d'activités quotidiennes. À l'inverse, un outil accessible en termes de courbe d'apprentissage mais peu adapté aux tâches d'audit restera à la périphérie des pratiques. Ce résultat déplace l'enjeu de l'adoption des interfaces vers l'intégration systémique : les cabinets gagneront davantage à

connecter les outils IAG aux logiciels d'audit et aux templates existants qu'à multiplier les sessions de prise en main.

5.3.3. H3 Risques perçus et usage effectif

Hypothèse H3 : *Plus un auditeur perçoit les risques liés à l'IAG, moins il l'utilise réellement.*
Direction attendue : $\rho(\text{SRP}, Q1) < 0$.

Le score des risques perçus (SRP) est le plus élevé de l'étude : 5,537/7 (médiane = 5,5 ; $\sigma = 0,883$), soit 79,1 % de l'échelle maximale. Ses quatre items révèlent une hiérarchie claire dans l'intensité des risques perçus : Q12 (hallucinations et informations inexactes) = 6,164/7 ; Q13 (risques de confidentialité) = 5,776/7 ; Q14 (opacité boîte noire) = 5,104/7 ; Q15 (responsabilité en cas d'erreur) = 5,104/7.

Le test donne comme résultat $\rho(\text{SRP}, Q1) = -0,231$ (p-value = 0,060 (. marginalement sig).

H3 est confirmée dans sa direction : les risques perçus réduisent la fréquence d'usage effectif, bien que le résultat n'atteigne pas le seuil conventionnel de 5 %.

À titre de vérification de cohérence, nous avons aussi testé $\rho(\text{SRP}, Q17) = 0,310$ (p-value = 0,011*) : ceux qui perçoivent le plus de risques déclarent aussi le plus s'en sentir freinés, ce qui valide la cohérence.

Tableau 9 H3 : Statistiques descriptives

Variable	Moyenne	Médiane	Écart-type
SRP (Score risques perçus)	5,537	5,500	0,878
Q17 (Frein déclaré)	4,269	4,000	1,720
Q12 (Hallucinations)	6,164	7,000	1,201
Q13 (Confidentialité)	5,776	6,000	1,565
Q14 (Boîte noire)	5,104	5,000	1,519
Q15 (Responsabilité)	5,104	5,000	1,819

La variable Q17 « Ces risques m'empêchent d'augmenter mon usage de l'IAG » affiche une moyenne de 4,269/7 (médiane = 4 ; $\sigma = 1,720$). Sa distribution est relativement symétrique autour de l'échelon central, indiquant que les répondants sont partagés entre ceux très freinés par les risques et ceux qui ne le sont pas.

L'analyse désagrégée par items de risque permet d'identifier lequel d'entre eux concentre l'essentiel de l'effet inhibiteur. On teste ici le lien entre chaque risque et le frein déclaré (Q17).




Figure 12 H3 : corrélations des items de risque avec Q17 (vérification de cohérence, $N = 67$)

Tableau 10 H3 : corrélations items de risque → Q17 (vérification de cohérence, $N = 67$)

Risque (item)	$\rho \rightarrow Q17$	p-value	Significativité
Q12 Hallucinations (infos inexactes)	0,233	0,057	(.) marginalement sig.
Q13 Confidentialité (fuite données)	0,109	0,382	NS
Q14 Boîte noire (opacité algorithmes)	0,237	0,054	(.) marginalement sig.
Q15 Responsabilité (erreurs de l'IA)	0,304	0,012	* Seul item sig.

Le risque de responsabilité (Q15 « Je m'inquiète d'être tenu pour responsable si l'IAG fait une erreur dans mon travail d'audit ») est le seul item individuellement et significativement corrélé au frein déclaré ($\rho = 0,304$, p-value = 0,012*). Q12 (hallucinations) et Q14 (boîte noire) atteignent une significativité marginale. Q13 (confidentialité) reste non significatif ($\rho = 0,109$, NS).

Ce résultat appelle une observation particulière. La confidentialité arrive en première position dans le classement d'importance perçue (Q16 : 4,433/5, voir section 5.4.1), devant les hallucinations (4,343/5). Elle est pourtant la moins corrélée au frein comportemental. Cette dissociation entre l'importance déclarée et l'impact effectif s'explique vraisemblablement par l'environnement d'usage : 33 répondants (49,3 %) utilisent principalement des outils agréés par leur cabinet Copilot dans un environnement Microsoft 365 sécurisé, outils internes propriétaires ce qui mitige en pratique le risque de fuite de données clients. Les auditeurs

percevant ce risque comme important en théorie, mais géré en pratique par leur organisation, le voient donc comme important mais non bloquant.

En revanche, le risque de responsabilité (Q15) échappe à toute mesure organisationnelle : quel que soit l'outil utilisé, l'associé signataire engage sa responsabilité professionnelle, civile et déontologique sur les conclusions de son rapport. Aucune politique de cabinet ne peut absorber cette exposition individuelle, ce qui en fait un frein structurellement plus lourd que les autres, que ce soit pour un junior ou un associé signataire.

5.3.4. H4 Maitrise fonctionnelle, modération des risques et scepticisme professionnel

5.3.4.1. H4a La Maitrise fonctionnelle comme modérateur de l'effet inhibiteur des risques

Hypothèse H4a : Le niveau de formation et de maîtrise fonctionnelle agit comme un modérateur positif sur la relation entre risques perçus et utilisation de l'IAG.

Plus un auditeur maîtrise les outils IAG, moins les risques perçus pèsent sur son comportement d'usage, l'effet inhibiteur étant nettement plus marqué chez les profils peu formés que chez les profils plus compétents.

Direction attendue : l'effet inhibiteur des risques sur l'usage (ρ négatif entre SRP et Q1) doit s'atténuer à mesure que le niveau de maîtrise fonctionnelle augmente.

Autrement dit, plus un utilisateur possède une bonne maîtrise des outils d'IAG, moins les risques perçus freinent son utilisation, tandis que les utilisateurs moins formés sont davantage dissuadés par ces risques.

H4a : tendance soutenue, direction conforme à la prédiction.

Le score de maîtrise fonctionnelle (SMF) affiche une moyenne de 4,781/7 (médiane = 4,667 ; $\sigma = 0,879$). La distribution de Q19 (niveau de formation auto-déclaré) révèle que la majorité des répondants se situent à des niveaux de formation modérés à moyens : 4 répondants (6,0 %) déclarent aucune formation, 12 (17,9 %) une formation très limitée, 12 (17,9 %) une formation faible, 18 (26,9 %) une formation moyenne d'environ une journée, 11 (16,4 %) une formation solide, 8 (11,9 %) une formation approfondie, et seulement 2 (3,0 %) un niveau expert. La grande majorité (68,7 %) n'a pas dépassé plus d'une journée de formation ou auto-formation cumulée selon les exemples de l'échelle proposée.

Pour analyser dans quelle mesure la maîtrise technique modère l'effet inhibiteur des risques sur l'usage, l'échantillon a été réparti en trois terciles selon le niveau de maîtrise : les auditeurs faiblement formés (SMF < 4,667), moyennement formés, et fortement formés (SMF > 5,000). La corrélation entre les risques perçus et l'usage a ensuite été calculée séparément pour chacun de ces trois groupes.

Tableau 11 H4a : corrélation SRP → Q1 stratifiée par tercile SMF

Tercile SMF	N	Moyenne SMF	Moyenne SRP	ρ (SRP → Q1)	p-value	Interprétation
Bas (SMF < 4,667)	21	3,841	5,631	-0,416	0,061 (.)	Effet inhibiteur fort
Moyen (4,667 ≤ SMF ≤ 5)	24	4,722	5,625	-0,274	0,195 (NS)	Effet atténué
Élevé (SMF > 5,00)	22	5,742	5,352	0,030	0,893 (NS)	Effet neutralisé ≈ 0

Le résultat est clair : chez les auditeurs peu formés, les risques perçus freinent fortement l'usage ($p = -0,416$). Cet effet s'atténue chez les auditeurs moyennement formés ($p = -0,274$), puis disparaît complètement chez les plus compétents ($p = 0,030$). Autrement dit, plus un auditeur maîtrise l'IAG, moins ses craintes freinent son utilisation.

Ce gradient teste directement H4a : si la maîtrise ne jouait aucun rôle, la corrélation risques/usage serait identique dans les trois groupes. Or elle diminue régulièrement et dans le sens attendu, ce qui montre que la maîtrise ne pousse pas simplement à utiliser plus l'IAG, elle neutralise progressivement l'effet bloquant des risques perçus. Les auditeurs très formés ne perçoivent pas moins de risques que leurs collègues (SRP comparable : 5,35 vs 5,63), mais ces risques ne les empêchent plus d'agir, parce qu'ils ont les compétences nécessaires pour les maîtriser.

Aucune des trois p-values n'atteint le seuil de 0,05 individuellement, ce qui s'explique par la taille réduite des sous-groupes (21 à 24 observations). Il s'agit d'un problème de puissance statistique et non d'absence d'effet, la cohérence du gradient suffit à valider la tendance prédite par H4a.




Figure 13 H4a : gradient $\rho(\text{SRP} \rightarrow \text{Q1})$ par tercile SMF ($N = 21, 24, 22$)

Pour confirmer ces résultats sans être limité par la taille des sous-groupes, les composantes du score SMF ont été corrélées directement à l'usage sur l'ensemble des 67 répondants.

Tableau 12 : Corrélations désagrégées - Maîtrise

Corrélation	ρ Spearman	p-value	Significativité
Q19 (Niveau de formation) $\rightarrow$ Q1	0,095	0,446	NS
Q20 (Orienter IAG) $\rightarrow$ Q1	0,379	0,002	**
Q21 (Détecter erreurs) $\rightarrow$ Q1	0,242	0,048	*
SMF (Maîtrise globale) $\rightarrow$ Q1	0,272	0,026	*

Le résultat le plus important de ce tableau est l'opposition entre Q19 et Q20. Le nombre de jours de formation reçue (Q19) n'est pas du tout corrélé à l'usage ($\rho = 0,095$, NS). En revanche, deux compétences très concrètes ressortent fortement : savoir piloter l'IAG via le prompting (Q20 : $\rho = 0,379^{**}$) et savoir détecter quand elle se trompe (Q21 : $\rho = 0,242^*$). Q20 produit d'ailleurs la deuxième corrélation la plus forte de toute l'étude, juste derrière Q10 (intégration au workflow).

Ce résultat déplace le débat de la quantité de formation vers la nature des compétences acquises. Ce n'est pas le fait d'avoir suivi une formation qui rend un auditeur utilisateur intensif de l'IAG, c'est le fait d'avoir développé deux réflexes opérationnels précis : savoir

construire un bon prompt pour obtenir un résultat utile, et savoir reconnaître une réponse incorrecte. Ce sont également ces deux compétences qui expliquent le gradient observé en H4a : chez les auditeurs qui les possèdent, les risques perçus ne constituent plus un frein.

À titre de confirmation, le niveau de formation auto-déclaré (Q19) est non significatif ($p = 0,095$, NS), ce qui établit que c'est la compétence opérationnelle acquise, et non la formation reçue, qui détermine l'intensité d'usage.

5.3.4.2. H4b et H4c Maîtrise fonctionnelle, risques perçus et scepticisme professionnel

Hypothèses H4b et H4c : La maîtrise fonctionnelle de l'IAG est positivement associée au scepticisme professionnel (H4b) ; la perception des risques y est négativement associée (H4c).

Ces deux hypothèses reposent sur un mécanisme en deux temps. D'un côté, la maîtrise technique devrait protéger le jugement critique en permettant à l'auditeur d'identifier les limites de l'outil (H4b). De l'autre, des risques perçus non maîtrisés pourraient au contraire fragiliser ce jugement par un glissement progressif vers une confiance aveugle dans l'outil (H4c). Ces deux dynamiques étant théoriquement distinctes, l'une liée à la compétence et l'autre à la perception du risque, elles font l'objet de tests séparés :

Hypothèse H4b : Plus un auditeur maîtrise techniquement l'IAG, plus il maintient un scepticisme professionnel élevé. Direction attendue : $\rho(\text{SMF}, \text{SSP}) > 0$.

Hypothèse H4c : Plus un auditeur perçoit de risques liés à l'IAG, plus son scepticisme professionnel s'érode. Direction attendue : $\rho(\text{SRP}, \text{SSP}) < 0$.

Le score SSP présente une moyenne de 4,961/7 (médiane = 5 ; $\sigma = 0,793$), soit 70,9 % de l'échelle maximale. Les statistiques descriptives de ses cinq items constitutifs sont présentées dans le Tableau 13. Un item se démarque nettement : Q25_inv (ne pas remettre en question son jugement face à l'IAG) n'atteint que 3,433/7. Une fois l'item formulé concrètement, les auditeurs reconnaissent remettre parfois en question leur propre jugement lorsque l'IAG suggère une conclusion différente. Ce signal isolé préfigure les résultats désagregés présentés plus bas.

Tableau 13 : Statistiques descriptives Scepticisme

Variable	Moyenne	Médiane	Écart-type
SSP (Score scepticisme)	4,961	5	0,793
Q22_inv (Ne pas se fier sans vérifier)	5,119	5	1,354
Q23 (Fréquence vérification sources)	5,478	6	1,159
Q24 (Jugement professionnel fort)	5,597	6	1,155
Q25_inv (Influence IAG inversée)	3,433	3	1,501

Q26_inv (Ne pas conclure avant preuve)	5,164	6	1,563
--	-------	---	-------

Les deux tests sont non significatifs : la maîtrise fonctionnelle n'est pas significativement associée au scepticisme professionnel ($\rho(\text{SMF}, \text{SSP}) = 0,190$, p-value = 0,124, NS), et la perception des risques ne l'érode pas davantage ($\rho(\text{SRP}, \text{SSP}) = 0,113$, p-value = 0,364, NS), cette dernière corrélation allant même dans le sens opposé à celui attendu sans toutefois atteindre la significativité..

H4b et H4c sont toutes deux infirmées.

L'infirmerie des hypothèses globales s'explique en partie par la faible variance du score SSP ($\sigma = 0,793$). Un score très peu dispersé offre peu de prise aux corrélations : presque tous les répondants se déclarent sceptiques à des niveaux comparables, il est statistiquement difficile de relier ce niveau de scepticisme à une autre variable. Ce phénomène est renforcé par la désirabilité sociale propre à la profession d'auditeur : admettre dans un questionnaire que l'IAG affecte son jugement critique va à l'encontre des normes déontologiques que l'auditeur doit incarner.

Les tests désagrégés sur les items individuels révèlent cependant un double signal, constitutif de ce que la littérature désigne comme un biais d'automatisation.




Figure 14 H4b et H4c : signaux du biais d'automatisation effets protecteurs et facteurs de risque (N = 67)[

Les tests désagrégés révèlent deux dynamiques opposées.

D'un côté, deux effets protecteurs : savoir détecter les erreurs de l'IAG (Q21) est corrélé à un scepticisme plus élevé ($\rho = 0,278$, p-value = 0,023*), et être conscient du risque

d'hallucinations (Q12) pousse à vérifier davantage les sources (Q23 : $\rho = 0,312$, p-value = 0,010*). Autrement dit, les auditeurs qui connaissent les limites de l'IAG restent plus vigilants.

De l'autre, deux signaux inquiétants : les utilisateurs les plus intensifs se déclarent plus confiants dans leur jugement professionnel (Q1 → Q24 : $\rho = 0,282$, p-value = 0,021*), mais reconnaissent également remettre plus souvent en question ce même jugement quand l'IAG suggère une conclusion différente (Q1 → Q25_inv : $\rho = -0,271$, p-value = 0,027*).

Se croire sceptique tout en cédant davantage à l'IAG : c'est exactement la définition du biais d'automatisation, une dérive cognitive progressive et non consciente, bien documentée chez les pilotes, les radiologues ou les traders confrontés à des outils de décision automatisée.

5.3.5. Tableau récapitulatif

Tableau 14 Récapitulatif des tests d'hypothèses (N = 67)

Hypothèse	Variables	ρ	p-value	Significativité	Verdict	Résultat principal
H1	SUP → Q1	0,168	0,174	NS	INFIRMÉE	Effet plafond SUP ; Q7_Rédaction sig. (**)
H2	SFU → Q1	0,325	0,007	**	CONFIRMÉE	Q10 intégration workflow : $\rho = 0,492^{***}$
H3	SRP → Q17	0,310	0,011	*	CONFIRMÉE	Q15 Responsabilité = frein principal
	SRP → Q1	-0,231	0,060	(.)	CONFIRMÉE	Risques réduisent aussi l'usage effectif
H4a ¹	SMF modère SRP→Q1	Gradient	NA	NA	CONFIRMÉE TENDANCE	Gradient -0,416 → -0,274 → 0,030 ; Q20 (**), Q21 (*)
H4b	SMF → SSP	0,190	0,124	NS	INFIRMÉE	Biais automatisation détecté par tests désagrégés

¹ H4a est évaluée par la cohérence du gradient et non par un test unique. Aucune des trois p-values individuelles n'atteint le seuil de 0,05, ce qui s'explique par la taille réduite des sous-groupes (21 à 24 observations). L'argument repose sur la régularité directionnelle du gradient : l'effet inhibiteur de SRP sur Q1 décroît de façon monotone avec le niveau de maîtrise (-0,416 → -0,274 → 0,030), conformément à la prédiction de H4a.

H4c	SRP → SSP	0,113	0,364	NS	INFIRMÉE	Direction contraire à l'attendu ; faible variance SSP
-----	-----------	-------	-------	----	----------	---

5.4. Analyses complémentaires

5.4.1. Classement des risques perçus par importance (Q16)

La question Q16 invitait les répondants à évaluer l'importance de quatre risques spécifiques pour leur pratique d'audit, sur une échelle de Likert de 1 à 5.




Figure 15 : Classement des risques par importance perçue (N = 67)

La confidentialité arrive en tête avec une moyenne de 4,433/5, portée par une concentration massive sur la note maximale : 46 répondants sur 67 (68,7 %) attribuent 5/5. Cette position s'explique par les obligations légales et professionnelles propres à l'audit, comme le secret professionnel, la RGPD, et la confidentialité des informations financières des entités auditées qui font du risque de divulgation une préoccupation naturellement intégrée au quotidien de l'auditeur.

Les hallucinations (4,343/5) arrivent en deuxième position, portées par leur forte visibilité dans les débats publics sur l'IA générative et par des expériences concrètes : tout auditeur ayant utilisé ChatGPT ou Copilot a probablement rencontré des résultats faux ou inventés. La responsabilité (3,881/5) et la boîte noire (3,642/5) sont jugées moins importantes, bien que toujours au-dessus du milieu de l'échelle.

Le résultat le plus instructif est l'écart entre l'importance perçue de la confidentialité (premier rang en Q16) et son absence d'effet significatif sur le frein déclaré (Q13 -> Q17 : $p = 0,109$, NS en section 5.3.3). À l'inverse, la responsabilité, troisième en importance, est le risque le plus lié au frein comportemental. L'importance perçue d'un risque ne détermine donc pas automatiquement son effet bloquant : c'est le degré de non-maîtrise individuelle qui compte. Un risque perçu comme géré par l'organisation (confidentialité) reste présent mais non bloquant ; un risque qui ne peut pas être transféré à l'organisation (responsabilité individuelle de l'auditeur) freine davantage le comportement.

5.4.2. Intentions d'usage futur et effet de levier d'une formation (Q27, Q28)

La question Q27 porte sur l'intention d'augmenter l'usage de l'IAG dans les six prochains mois : 39 répondants (58,2 %) répondent « Oui », 24 (35,8 %) « Non » et 4 (6,0 %) de façon conditionnelle. Ces 4 réponses conditionnelles se décomposent en : conditionné à la politique du cabinet, dépendant de la maîtrise future des outils, sans idée, et un répondant déclarant vouloir réduire son usage.

La question Q28 « Quelle est la probabilité que vous augmentiez votre usage de l'IAG si vous receviez une formation à l'avenir ? » (1 à 7) produit une distribution fortement orientée vers les modalités hautes : 18 répondants (26,9 %) attribuent la probabilité maximale de 7, 15 (22,4 %) la valeur 6, 17 (25,4 %) la valeur 5. La moyenne est de 5,194/7 (médiane = 5 ; $\sigma = 1,708$). Seuls 10 répondants (14,9 %) se situent à 3 ou en-dessous. Ce résultat constitue un signal intéressant : les trois quarts de l'échantillon expriment une intention favorable à un usage accru en cas de formation, bien qu'une intention déclarée ne préjuge pas nécessairement d'un changement de comportement effectif.

5.4.3. Les risques comme verrou réversible : corrélation Q17-Q18

La question Q18 « Si les risques étaient éliminés, j'utiliserais davantage l'IAG » (1 à 7) est corrélée au frein actuel (Q17) avec ρ de spearman = 0,310 (p -value = 0,011*). Cette corrélation positive indique que les répondants les plus freinés par les risques actuels sont aussi ceux qui déclarent le plus fort désir d'augmenter leur usage si ces risques disparaissaient.




Figure 16 Q17 (frein actuel) vs Q18 (intention si risques éliminés) $p = 0,310$, $p = 0,011^*$ ($N = 67$)

Les chiffres confirment cet écart. Q18 affiche une moyenne de 5,73/7 contre 4,27/7 pour Q17, soit près de 1,5 point de différence. Plus parlant encore : 28 répondants (41,8 %) mettent la note maximale de 7 sur Q18, contre seulement 6 (9,0 %) sur Q17.

Cela montre que les auditeurs ne rejettent pas l'IAG par principe. Ce sont les risques qui bloquent, pas l'outil. Si ces risques étaient levés par la formation, une meilleure clarification des responsabilités ou des environnements de travail plus sécurisés, l'usage décollerait rapidement, car l'envie est déjà là.

5.4.4. Comparaisons par grade hiérarchique

Les comparaisons par grade reposent sur le test de Kruskal-Wallis. Ce test vérifie si une variable diffère significativement entre trois groupes ou plus, ici Juniors, Seniors-Managers et Associés, sans supposer que les données suivent une loi normale. Il est particulièrement adapté aux données issues d'échelles de Likert. Il produit une statistique H : plus H est élevé, plus les groupes sont dissemblables. Les mêmes seuils de significativité que pour Spearman sont retenus : *** $p < 0,001$; ** $p < 0,01$; * $p < 0,05$; (.) $p < 0,10$.

Les résultats sont présentés dans le Tableau 15 ci-dessous.

Tableau 15 - Scores moyens par grade et tests de Kruskal-Wallis (N = 67)

Grade	N	SUP	SFU	SRP	SMF	SSP	Q1
Junior	32	3,317	4,906	5,352	4,615	4,806	4,938
Senior-Manager	17	3,356	5,078	5,544	5,176	5,082	5,235
Associé	18	3,584	4,222	5,861	4,704	5,111	4,944
H		2,64	9,56	3,63	5,47	1,85	0,67
p-value		0,267 NS	0,008 **	0,163 NS	0,065 (.)	0,396 NS	0,717 NS

Les tests révèlent deux résultats significatifs que l'analyse globale des hypothèses ne permettait pas d'identifier.

La facilité d'usage perçue SFU diffère significativement selon le grade (H = 9,56 ; p-value = 0,008**) : les Juniors (4,906) et les Seniors-Managers (5,078) perçoivent l'IAG comme nettement plus facile à intégrer dans leur quotidien que les Associés (4,222). Ce résultat est cohérent avec la nature des tâches propres à chaque grade : les Associés, davantage mobilisés sur des responsabilités de supervision, de revue et de relation client, trouvent l'intégration de l'IAG moins naturelle dans leur flux de travail que les grades dont les tâches sont plus directement automatisables. Ce résultat complète et nuance la confirmation de H2 : la facilité d'usage est bien un prédicteur global de l'usage, mais son niveau perçu varie structurellement selon la position hiérarchique.

La maîtrise fonctionnelle SMF présente une différence marginalement significative (H = 5,47 ; p-value = 0,065(.)) : les Seniors-Managers affichent la moyenne la plus élevée (5,176), tandis que les Associés (4,704) se rapprochent des Juniors (4,615). Ce profil suggère que ce sont les grades intermédiaires, plus directement impliqués dans l'exécution technique et la supervision opérationnelle, qui développent la maîtrise la plus fine des outils IAG.

Les quatre autres scores, SUP, SRP, SSP et Q1, ne présentent pas de différence significative entre grades. En particulier, l'absence de différence sur Q1 (H = 0,67 ; NS) confirme que l'intensité d'usage de l'IAG est homogène entre niveaux hiérarchiques, et que les facteurs individuels de perception identifiés dans les hypothèses H1 à H4 prévalent sur l'effet du

grade. SRP croît néanmoins de façon régulière avec la progression hiérarchique (5,352 → 5,544 → 5,861), traduisant une conscience croissante des risques professionnels sans que cette différence atteigne le seuil de significativité avec $N = 67$.

5.4.5. Comparaisons cabinets internationaux et autres

Le test de Mann-Whitney est un test non-paramétrique qui vérifie si les distributions d'une variable diffèrent significativement entre deux groupes indépendants sans supposer la normalité des données, ce qui le rend adapté aux échelles de Likert. Il produit une statistique U qui compte, pour chaque paire possible entre un auditeur du groupe A et un auditeur du groupe B, combien de fois l'auditeur A obtient un score plus élevé que l'auditeur B : si les deux groupes sont identiques, A et B gagnent à peu près autant de comparaisons ; si U s'éloigne fortement de cette valeur centrale, un groupe domine systématiquement l'autre. La p -value indique si cette asymétrie peut être attribuée au hasard, avec les mêmes seuils que pour Spearman et Kruskal-Wallis.

La comparaison porte sur les cabinets internationaux et Big4 ($N = 37$) d'un côté, et les autres cabinets (locaux, régionaux et en réseau, $N = 30$) de l'autre. Les résultats sont présentés dans le Tableau 16 ci-dessous.

Tableau 16 - Scores moyens et tests de Mann-Whitney par type de cabinet ($N = 67$)

Score	Moyenne Internationaux	Moyenne Autres	U	p-value
SUP	3,299	3,522	460	0,231 NS
SFU	4,937	4,556	694	0,077 (.)
SRP	5,338	5,783	412	0,069 (.)
SMF	4,721	4,856	510	0,572 NS
SSP	4,811	5,140	435	0,130 NS
Q1	5,054	4,967	578	0,773 NS

Aucune différence statistiquement significative n'est détectée entre les deux types de cabinets pour l'ensemble des scores.

Deux écarts approchent néanmoins la significativité.

L'écart sur SRP (p-value = 0,069) : les auditeurs des cabinets non-Big4 perçoivent davantage de risques liés à l'IAG que leurs homologues des cabinets internationaux. Cette tendance pourrait refléter un accès moins systématique aux environnements sécurisés dans les structures plus petites, où les outils grand public comme ChatGPT sont plus souvent utilisés en l'absence de solutions dédiées, exposant davantage les utilisateurs aux risques de confidentialité et de responsabilité.

L'écart sur SFU (p-value = 0,077) va dans le sens inverse : les auditeurs des cabinets internationaux perçoivent l'IAG comme plus facile à intégrer dans leur quotidien (4,937 vs 4,556), ce qui pourrait s'expliquer par une exposition plus précoce aux outils dédiés et par des formations internes plus structurées au sein des grandes structures.

Le résultat le plus notable est l'absence de différence sur Q1 (U = 578 ; p-value = 0,773 NS) : l'intensité d'usage de l'IAG est strictement comparable entre cabinets internationaux (5,054) et autres cabinets (4,967), ce qui confirme que l'adoption individuelle de l'IAG ne dépend pas de la taille ou des ressources du cabinet. La maîtrise fonctionnelle SMF est également quasi identique entre les deux groupes (4,721 contre 4,856 NS), indiquant que l'effort de formation individuelle est comparable quelle que soit la structure d'appartenance.

5.5. Discussion et entretiens semi-dirigés

5.5.1. Confrontation des résultats quantitatifs et qualitatifs

Comme présenté dans la section 4.2.2, trois entretiens semi-directifs ont été conduits entre mars et avril 2026 auprès de profils volontairement contrastés.

Le premier profil (interviewé A) correspond à un auditeur IT senior 2, relativement jeune, évoluant au sein d'un cabinet international, caractérisé par une forte appétence pour les outils numériques et une adoption précoce de l'IA. Son usage est à la fois intensif et exploratoire : il mobilise l'IA dans des tâches variées, allant de la recherche documentaire à la résolution de problématiques techniques, en passant par la génération de code ou l'assistance à la manipulation d'outils spécialisés. Cette appropriation autonome et pragmatique, construite en grande partie par expérimentation, en fait un profil typique d'utilisateur « avancé », pour qui l'IA constitue déjà un véritable levier de productivité.

Le deuxième profil (interviewé B) est celui d'un superviseur audit, (équivalent senior 2 d'un BIG 4) en cabinet régional-national, dont l'usage de l'IA apparaît plus encadré et plus prudent. Son recours à ces outils reste principalement limité à des tâches périphériques comme la recherche documentaire, la reformulation ou la traduction, en raison de contraintes organisationnelles fortes, notamment liées à la confidentialité des données et aux politiques internes du cabinet. Cette posture traduit une appropriation progressive, marquée par une tension entre le potentiel perçu de l'outil et les restrictions concrètes qui en limitent l'usage opérationnel. Elle illustre bien la situation d'un utilisateur convaincu de l'intérêt de l'IA, mais encore contraint dans sa mise en pratique.

Enfin, le troisième profil (interviewé C) correspond à un commissaire aux comptes signataire exerçant en cabinet indépendant, avec une quinzaine d'années d'expérience et une implication active dans les instances professionnelles. À la fois formateur à la CNCC et bêta-testeur d'un outil institutionnel d'IA, il adopte une posture singulière, mêlant curiosité technologique et forte conscience des enjeux déontologiques. Son utilisation de l'IA s'inscrit dans une logique stratégique, notamment pour le développement de son activité, la production de contenus ou la structuration de ses missions, tout en conservant un haut niveau d'esprit critique. Ce profil se distingue par une sensibilité accrue à la question de la responsabilité professionnelle, directement liée à son statut de signataire, ainsi que par une volonté d'anticiper les évolutions de la profession.

Ces trois profils permettent ainsi de couvrir différentes situations professionnelles en cabinet, en distinguant un utilisateur intensif en environnement international, un utilisateur contraint par des règles organisationnelles en structure intermédiaire, et un professionnel indépendant directement concerné par les enjeux liés à la signature et à la responsabilité.

5.5.2. Discussion des résultats par hypothèse

H1 et H2 : utilité perçue, intégration au workflow et adoption effective

L'infirmité de H1, liée à un effet de plafond sur le score d'utilité perçue ($SUP = 3,40/5$, $\sigma = 0,58$), est soutenue par les trois entretiens. Aucun des trois interviewés ne conteste l'utilité de l'IAG. Ce qui les différencie est le passage à l'usage effectif.

L'interviewé B (superviseur, cabinet régional) souligne ainsi que l'IAG « pourrait faire gagner beaucoup de temps », notamment pour automatiser certaines analyses ou produire des

comptes rendus à partir de documents existants, « beaucoup plus vite qu'un junior », mais que la politique restrictive de son cabinet sur l'injection de données empêche cette utilité théorique de se concrétiser.

L'interviewé C (CAC signataire, cabinet solo) partage ce constat en notant qu'il n'a « pas encore testé tout ce qu'il pouvait faire » et que le frein principal est le manque de connaissance des usages/cas pratiques possibles combiné à l'incertitude sur la confidentialité.

Enfin, l'interviewé A (auditeur IT, grand cabinet) apporte un éclairage complémentaire. Il explique que l'utilité de l'IAG est aujourd'hui largement admise, mais que son utilisation dépend davantage de facteurs pratiques comme l'efficacité perçue des outils disponibles ou l'habitude de travail. Il souligne notamment qu'au début, les résultats obtenus pouvaient être jugés peu fiables, ce qui freinait l'usage, même si cette perception évolue avec l'amélioration des outils.

Ces éléments montrent que lorsque l'utilité est unanimement reconnue, elle ne suffit plus à expliquer les différences d'usage, qui tiennent davantage à des facteurs contextuels.

La confirmation de H2 est, à l'inverse, fortement étayée. L'intégration dans le workflow (Q10, $\rho = 0,492^{***}$) apparaît comme un facteur déterminant dans les trois entretiens.

L'interviewé A (auditeur IT, grand cabinet) indique ainsi que l'IAG « n'est pas intégrée de façon fluide » dans son environnement de travail. Il souligne que, dans ce contexte, elle est peu utilisée sur les tâches « cœur de métier ». Selon lui, les auditeurs ont tendance à mobiliser l'IAG uniquement sur des tâches pour lesquelles ils se perçoivent comme moins compétents.

De plus, l'interviewé C (CAC signataire, cabinet solo) évoque un frein complémentaire, lié à l'absence d'outils intégrant directement l'IAG dans les logiciels d'audit. Il décrit l'intérêt qu'aurait un outil capable de générer automatiquement un programme de travail ou de structurer la documentation à partir de quelques indications, en lien avec les zones de risque identifiées. Il met également en perspective cette attente avec son expérience passée des outils d'audit, en évoquant notamment des solutions précédentes perçues comme peu adaptées ou contraignantes, qui ont pu freiner l'adoption de nouveaux outils. Cette expérience contribue à expliquer une certaine prudence vis-à-vis des solutions existantes et renforce l'intérêt pour des outils mieux intégrés et plus adaptés aux pratiques réelles des auditeurs.

Ces éléments montrent que l'enjeu ne porte pas uniquement sur la performance de l'outil, mais sur sa capacité à s'insérer concrètement dans les processus existants, en s'appuyant sur les pratiques de travail déjà en place et en facilitant la structuration des missions plutôt qu'en ajoutant une couche d'outillage supplémentaire.

Enfin, l'interviewé B (superviseur, cabinet régional) apporte une nuance en soulignant qu'une intégration trop poussée pourrait présenter des risques, notamment en termes de perte de compétences chez les juniors. Il évoque le risque que les nouvelles générations « s'abreuvent d'un compte-rendu sans vraiment comprendre comment il se construit », ce qui pourrait, selon lui, entraîner une perte de compétences à terme.

H3 : risques perçus et freins à l'usage

Les entretiens confirment l'hypothèse H3 et révèlent un décalage marqué entre l'importance accordée aux risques et leur influence réelle sur les pratiques.

L'interviewé A (auditeur IT, grand cabinet) reconnaît accorder relativement peu d'attention aux questions de conformité RGPD dans son usage quotidien, en partant du principe que les outils utilisés respectent ces contraintes. Il indique ainsi être « peu soucieux des questions RGPD » et se repose sur l'idée que « le logiciel respecte la RGPD », sans chercher à le vérifier.

Toutefois, cette posture présente des limites. Il précise qu'il n'utiliserait jamais l'IAG pour traiter des données sensibles telles que des données comptables, un grand livre ou un FEC, estimant que « la probabilité est faible mais l'impact est trop gros ». Cette situation illustre un cas où le risque de confidentialité est reconnu comme important, mais ne constitue pas un frein direct à l'usage tant que certaines limites, notamment l'absence de données sensibles, sont respectées.

Au contraire, l'interviewé B (superviseur, cabinet régional), se dit « très limité » par les risques de confidentialité et affirme que « si on était sûr de la confidentialité, ça m'inciterait à beaucoup plus utiliser l'IA ». Il explique que la politique du cabinet repose sur un principe strict de non-injection de données sensibles, ce qui restreint fortement les cas d'usage possibles. Il précise ainsi qu'il « n'injecte aucune donnée client » et qu'il se limite à des documents qu'il « est capable de retrouver sur le domaine public ». Ce profil correspond à

l'auditeur dont l'usage est effectivement freiné par les risques perçus, validant la direction de H3.

Enfin, l'interviewé C (CAC signataire, cabinet solo) apporte une perspective complémentaire liée à son rôle. Il souligne que les juniors « ne se posent pas de questions » sur la confidentialité car « ce n'est pas eux qui engagent leur responsabilité », décrivant le phénomène de « shadow IA » où des données confidentielles sont entrées dans l'IAG sans contrôle. Il insiste sur la nécessité d'une « charte d'usage de l'IA » et d'un code de bonne conduite intégrés aux procédures du cabinet. Il confirme également que « quand tu engages ta responsabilité, tu te poses plus de questions », ce qui valide directement le résultat quantitatif selon lequel la responsabilité individuelle (Q15) est le seul risque significativement corrélé au frein comportemental ($p = 0,304^*$).

H4a : maîtrise fonctionnelle comme modérateur

Le gradient observé en H4a, où l'effet des risques diminue avec le niveau de maîtrise (p passant de $-0,416$ à $0,030$), se retrouve bien dans les entretiens, même si les explications diffèrent selon les profils.

L'interviewé A (auditeur IT, grand cabinet), utilisateur intensif, décrit un usage avancé de l'IAG fondé sur une logique de vérification. Il explique qu'il ne se considère « meilleur sur aucune tâche » que l'outil, mais qu'il conserve un rôle de contrôle. Concrètement, il s'appuie sur sa maîtrise du prompting pour interroger l'IAG sur la manière dont les résultats ont été obtenus, puis confronte ces éléments à des sources externes afin de valider leur fiabilité.

Il souligne par ailleurs que les formations proposées par les cabinets sont souvent « très théoriques » et peu utiles dans la pratique, car elles ne permettent pas de développer les réflexes nécessaires à l'utilisation quotidienne de l'outil. Ce témoignage rejoint directement le résultat quantitatif observé en H4a, qui indique que ce n'est pas le nombre de jours de formation (Q19) qui distingue les utilisateurs intensifs, mais la compétence opérationnelle (Q20) réellement acquise.

Dans une logique assez proche, l'interviewé B (superviseur, cabinet régional) insiste lui aussi sur le rôle central de l'expérience dans la montée en compétence. Il indique ne pas avoir reçu de formation spécifique et avoir appris progressivement par la pratique.

Il décrit un usage structuré autour de plusieurs essais, avec la mise en place d'outils adaptés à ses besoins, comme des agents permettant notamment de mieux formuler les requêtes. Pour lui, l'enjeu principal reste la capacité à « contrôler le rendu » et à comprendre ce que produit l'outil, plutôt que la maîtrise théorique de son fonctionnement. Il souligne toutefois certaines limites techniques, notamment dans la construction des requêtes, qui peuvent freiner des usages plus avancés.

Pour terminer, l'interviewé C (CAC signataire, cabinet solo) nuance en observant que « l'IA est assez intuitive » et qu'une formation spécifique n'est pas nécessairement indispensable, mais que les fiches de la CNCC sur le prompting et la détection d'erreurs constituent une base déontologique essentielle. Il souligne également que cette capacité de vérification ne relève pas uniquement de compétences techniques, mais du jugement professionnel propre à l'auditeur. Selon lui, savoir identifier une réponse erronée ou inadaptée suppose avant tout de comprendre le fond du sujet, ce qui renvoie directement aux exigences déontologiques du métier.

Il apporte toutefois une nuance importante sur la dynamique de la montée en compétence. Il décrit une progression en trois temps, dans une logique proche de l'effet Dunning-Kruger : les auditeurs peu formés restent bloqués par les risques perçus, ceux qui commencent à se former tendent à surestimer leur niveau et à minimiser ces mêmes risques, et c'est seulement chez les utilisateurs les plus avancés que réapparaît une conscience des limites de l'outil. Cette lecture suggère que la maîtrise fonctionnelle ne réduit pas mécaniquement la perception des risques, mais qu'elle peut traverser une phase intermédiaire dangereuse, où la confiance dépasse la compétence réelle. Ce point nuance le gradient observé en H4a et invite à ne pas interpréter la réduction de l'effet inhibiteur des risques comme un signe systématique de maturité dans l'usage.

Ces trois témoignages convergent vers une recommandation pratique : les cabinets devraient privilégier des formations concrètes, centrées sur des cas d'usage réels avec des exercices de prompting et de détection d'hallucinations, plutôt que des formations théoriques généralistes. l'interviewé A (auditeur IT, grand cabinet) propose même d'« inclure l'IAG dans les formations existantes » plutôt que d'en faire une formation isolée, en l'intégrant par exemple dans la formation sur les capitaux propres ou sur les cycles d'audit.

H4b et H4c : scepticisme professionnel et biais d'automatisation

Les entretiens permettent de mieux comprendre les résultats obtenus sur H4b et H4c, en particulier le signal de biais d'automatisation mis en évidence dans l'analyse quantitative.

L'interviewé A (auditeur IT, grand cabinet) illustre directement ce paradoxe : il affirme que « plus j'utilise l'IAG, plus j'aurai de jugement professionnel, car je vais regarder les résultats », comparant l'IAG à un « junior qui fait le travail et que je vérifie ». Il reconnaît cependant avoir déjà suivi une conclusion de l'IAG, après vérification documentaire, en précisant toutefois que cela ne constitue pas nécessairement un biais d'automatisation : il peut s'agir simplement d'un avis contraire que l'on discute, ou d'une situation où l'on a soi-même mal compris le problème initialement. Il admet néanmoins que d'autres utilisateurs peuvent se contenter d'accepter les résultats sans ce travail de vérification, et estime que l'IAG pourrait à long terme éroder le jugement professionnel car on aura trop confiance. Ce témoignage nuance l'interprétation quantitative : le signal de biais d'automatisation observé dans l'enquête ne signifie pas que tout utilisateur intensif cède aveuglément à l'IAG, mais que le risque existe et varie selon les pratiques individuelles de vérification.

Dans une logique différente, l'interviewé B (superviseur, cabinet régional) adopte une posture plus prudente et plus encadrée. Ainsi, contrairement à A qui met en avant un usage intensif accompagné de vérifications, B insiste davantage sur la nécessité de garder une distance critique. Il indique avoir « plus confiance en [son] jugement professionnel » et mobilise l'IAG principalement comme un outil de confirmation, afin de « corroborer » certaines analyses.

Concrètement, il met en place des mécanismes de vérification simples mais systématiques, en confrontant les réponses de l'IAG aux sources proposées ou à d'autres références. Cette démarche s'apparente à une forme de vérification par sondage, où l'auditeur ne valide pas l'ensemble du contenu produit, mais en contrôle certains éléments afin d'en apprécier la fiabilité.

Ce contraste permet d'introduire l'apport de l'interviewé C (CAC signataire, cabinet solo), qui propose une lecture intéressante du phénomène. Il souligne que la perception des risques ne conduit pas nécessairement à une diminution du scepticisme, mais peut au contraire le renforcer. Comme il l'explique, « l'auditeur conscient des risques va justement remettre en

cause son jugement », tandis que « l’auditeur qui ne perçoit aucun risque est plus dangereux ».

Cette analyse permet d’interpréter directement le résultat quantitatif associé à H4c : contrairement à l’hypothèse initiale, la perception des risques n’érode pas le scepticisme professionnel, mais agit plutôt comme un mécanisme d’alerte. Elle incite l’auditeur à adopter une posture plus critique face aux résultats de l’IAG. L’interviewé C rappelle enfin que même un auditeur expérimenté peut être induit en erreur, ce qui renforce l’idée que le maintien du scepticisme repose avant tout sur une vigilance constante, indépendamment du niveau d’expérience.

L’interviewé C apporte un éclairage supplémentaire sur le risque spécifique aux profils juniors. Il estime que ces derniers ne détecteront pas facilement les hallucinations, précisément parce qu’un texte bien rédigé leur semblera plausible. Il relie ce risque à une tendance plus large qu’il observe dans les nouvelles générations, dont la maîtrise de la langue écrite s’affaiblit, ce qui réduit leur capacité à repérer les erreurs de formulation ou les incohérences de fond produites par l’IAG. Ce signal renforce le résultat quantitatif associé à H4b : le biais d’automatisation n’est pas uniforme, il est particulièrement prononcé chez les utilisateurs qui n’ont pas encore développé les repères professionnels nécessaires pour contester les outputs de l’outil.

5.5.3. Apports complémentaires des entretiens

Au-delà de la confrontation hypothèse par hypothèse, les entretiens mettent en évidence plusieurs phénomènes que l’enquête quantitative ne permettait pas d’identifier.

Premièrement, ils révèlent l’existence d’un usage informel de l’IAG, que l’interviewé C (CAC signataire, cabinet solo) rapproche d’un phénomène de « shadow IA ». Il décrit des situations où les outils sont utilisés en dehors de tout cadre formalisé, en particulier par des collaborateurs qui ne mesurent pas nécessairement les enjeux liés à la confidentialité. Ce phénomène, comparable au « shadow IT », constitue un angle mort des données déclaratives : un auditeur peut affirmer ne pas utiliser l’IAG sur des données sensibles tout en y ayant recours ponctuellement, sans encadrement ni traçabilité.

L'interviewé A (auditeur IT, grand cabinet) apporte un éclairage complémentaire en soulignant qu'« personne ne peut savoir ce que tu mets dans l'IA générative » et qu'il n'existe pas, en pratique, de mécanisme de contrôle direct. Cette absence de visibilité renforce le caractère difficilement mesurable de ces usages et pose des enjeux en matière de gouvernance.

Deuxièmement, la qualité perçue des outils mis à disposition par les cabinets apparaît comme un facteur déterminant de l'adoption. L'interviewé A (auditeur IT, grand cabinet) indique que la performance des solutions proposées influence directement son usage : il explique qu'un outil plus performant serait davantage utilisé, et que certaines expériences initiales peu concluantes ont pu freiner l'adoption, en générant un « manque d'envie » de réessayer chez certains utilisateurs.

L'interviewé C (CAC signataire, cabinet solo) partage ce constat à partir de son expérience passée, en évoquant un outil d'audit jugé peu efficace, qui lui avait fait perdre du temps malgré les gains attendus. Ces éléments suggèrent que les premières expériences d'utilisation jouent un rôle structurant dans la perception des outils et peuvent durablement influencer les comportements.

Troisièmement, les entretiens mettent en évidence des enjeux différenciés selon la taille des structures. L'interviewé C (CAC signataire, cabinet solo) souligne que, dans un cabinet de petite taille, l'IAG peut constituer un levier stratégique important, notamment en compensant l'absence de collaborateurs et en donnant accès à des capacités auparavant réservées aux grandes structures. Il indique ainsi que l'outil lui permet de réaliser certaines tâches de manière autonome, sans recourir à un assistant.

Il développe toutefois une lecture plus stratégique de la dynamique concurrentielle à venir. Selon lui, certains grands cabinets pourraient utiliser l'IAG dans un premier temps pour dominer par les coûts, en réduisant significativement le prix des missions d'audit de base, avant de repositionner leurs ressources libérées vers des missions à plus forte valeur ajoutée facturées à des tarifs plus élevés. Cette trajectoire en deux temps pourrait, à terme, accentuer les écarts entre structures plutôt que de les réduire. Ce point va au-delà du simple constat d'une différence de ressources et permet de nuancer le résultat quantitatif d'absence de différence d'usage entre types de cabinets : si les niveaux d'usage sont comparables à ce stade,

les logiques sous-jacentes et les enjeux compétitifs associés diffèrent sensiblement selon la taille de la structure.

5.5.4. Préconisations opérationnelles

La synthèse des résultats quantitatifs et qualitatifs permet de formuler quatre préconisations concrètes à destination des cabinets d'audit.

Premièrement, investir dans l'intégration systémique plutôt que dans la multiplication des formations généralistes. Le résultat le plus robuste de l'étude ($p = 0,492^{***}$) montre que l'intégration de l'IAG dans le flux de travail quotidien est le premier déterminant de l'usage. Les cabinets gagneraient à connecter les outils d'IAG directement aux logiciels d'audit, aux templates et aux bases documentaires existantes, afin de permettre une utilisation sans rupture dans les tâches quotidiennes, comme le suggèrent tant l'interviewé B (superviseur, cabinet régional) que l'interviewé C (CAC signataire, cabinet solo).

Deuxièmement, recentrer les formations sur des compétences opérationnelles, notamment le prompting et la détection d'erreurs. Le nombre de jours de formation n'est pas corrélé à l'usage (Q19, $p = 0,095$ NS), mais savoir piloter l'IAG ($p = 0,379^{**}$) et détecter ses erreurs ($p = 0,242^*$) sont les deux compétences qui distinguent les utilisateurs intensifs. Les trois interviewés convergent sur la nécessité de formations concrètes, avec des cas d'usage réels et des exercices pratiques, intégrées aux formations métiers existantes plutôt que dispensées de manière isolée.

Troisièmement, clarifier le cadre de responsabilité et mettre en place une charte d'usage de l'IAG. La responsabilité individuelle est le seul risque significativement corrélé au frein comportemental ($p = 0,304^*$). L'interviewé C (CAC signataire, cabinet solo) recommande l'élaboration d'un code de bonne conduite spécifiant les types de données autorisés, les conditions d'utilisation et les modalités de supervision des résultats produits. La CNCC s'inscrit dans cette direction avec ses fiches introductives et avancées sur l'IA, envoyées aux CAC début avril 2026.

Quatrièmement, surveiller le biais d'automatisation, en particulier chez les utilisateurs intensifs et les profils les plus juniors. Le signal observé dans l'enquête, combinant une confiance déclarée croissante et une tendance accrue à suivre les recommandations de l'IAG, suggère que les mécanismes de revue hiérarchique doivent évoluer vers une supervision plus

explicite de l'usage de ces outils, intégrant des vérifications de la démarche suivie par l'auditeur lorsqu'il a recours à l'IAG.

Cette vigilance est d'autant plus importante pour les auditeurs juniors, pour lesquels une intégration trop précoce de l'IAG dans les routines peut entraîner un risque de perte progressive de compétences, en particulier lorsque les résultats produits sont utilisés sans compréhension suffisante de leur construction. Comme le souligne l'interviewé A (auditeur IT, grand cabinet), « la compétence influence la prise de décision et la capacité à remettre en question l'IA » : « pour qu'un auditeur soit indépendant, il doit être compétent ».

Conclusion

Ce mémoire avait pour objectif de répondre à la problématique suivante : « En quoi la perception de l'intelligence artificielle générative influence-t-elle son utilisation dans les cabinets d'audit ? » Pour y répondre, nous avons mobilisé principalement trois cadres théoriques, le Technology Acceptance Model de Davis (1989), le modèle de scepticisme professionnel de Hurtt (2010) et la notion de talent digital de Liang et al. (2025), afin de formuler six hypothèses testées auprès de 67 auditeurs français par voie quantitative, puis enrichies par trois entretiens semi-directifs conduits auprès de profils contrastés.

Les résultats révèlent un niveau d'adoption plus complexe que ne le suggère le TAM classique. L'utilité perçue de l'IAG, bien qu'unaniment reconnue par les répondants (SUP = 3,40/5), ne constitue plus un facteur différenciant de l'usage (H1 infirmée) : elle apparaît comme une condition nécessaire mais non suffisante. En revanche, l'intégration fluide de l'IAG dans le flux de travail quotidien s'impose comme le principal déterminant de l'usage effectif (Q10, $\rho = 0,492^{***}$, H2 confirmée). Les risques perçus freinent significativement l'usage (H3 confirmée), mais selon une logique différenciée : la confidentialité, bien que fortement perçue, est relativement peu contraignante en pratique, tandis que la responsabilité individuelle constitue le principal frein comportemental ($\rho = 0,304^*$).

L'analyse met également en évidence le rôle central de la maîtrise fonctionnelle. Ce n'est pas le volume de formation reçue qui distingue les utilisateurs intensifs, mais la capacité à utiliser concrètement l'outil et à en évaluer les résultats. Les compétences de formulation des requêtes ($\rho = 0,379^{**}$) et de détection des erreurs ($\rho = 0,242^*$) permettent de réduire progressivement l'effet des risques perçus (H4a). Par ailleurs, les résultats suggèrent l'existence d'un biais d'automatisation : les utilisateurs les plus intensifs se déclarent plus confiants dans leur jugement tout en étant plus enclins à suivre les réponses de l'IAG lorsqu'elles diffèrent de leur analyse initiale (H4b). Enfin, la perception des risques ne semble pas diminuer le scepticisme professionnel, mais au contraire encourager une posture plus prudente, ce qui conduit à infirmer H4c.

Au total, les hypothèses testées mettent en évidence une dynamique contrastée : si l'utilité perçue (H1) ne permet plus d'expliquer les différences d'usage, l'intégration dans le workflow (H2) et la responsabilité individuelle (H3) apparaissent comme des facteurs déterminants. La maîtrise fonctionnelle (H4a) joue un rôle clé dans la gestion des risques,

tandis que les effets liés au biais d'automatisation (H4b) et à la perception des risques (H4c) montrent que la relation entre perception et usage ne peut pas être interprétée de manière linéaire.

Les apports de cette recherche sont de trois ordres. Sur le plan théorique, elle montre que le TAM doit être complété par des variables liées à l'intégration des outils et à la perception des risques. Sur le plan empirique, elle met en évidence le rôle de la maîtrise fonctionnelle dans l'usage de l'IAG. Sur le plan professionnel, elle identifie plusieurs leviers d'action pour les cabinets : intégration des outils dans les logiciels existants, développement de compétences opérationnelles, clarification des responsabilités et encadrement de l'usage.

Cette recherche présente toutefois plusieurs limites. Premièrement, l'échantillon de 67 répondants, bien que pertinent au regard de la problématique, ne permet pas de généraliser les résultats à l'ensemble des commissaires aux comptes en France. Le biais de volontariat est probable, les auditeurs les plus sensibilisés à l'IAG étant plus enclins à répondre. Deuxièmement, la faible cohérence interne de certains scores a conduit à privilégier une analyse par item, ce qui limite la portée des conclusions associées aux construits. Troisièmement, l'exclusion des non-utilisateurs concentre l'analyse sur les adoptants, sans permettre d'étudier les déterminants du non-usage. Enfin, les résultats doivent être replacés dans un contexte technologique en évolution rapide, susceptible de modifier rapidement les perceptions et les usages.

Plusieurs pistes de recherche peuvent être envisagées. Une étude sur le long terme permettrait d'observer l'évolution des usages dans le temps. Une approche expérimentale pourrait mesurer l'impact de l'IAG sur la qualité des décisions d'audit. Enfin, une extension à d'autres contextes nationaux permettrait de tester la robustesse des résultats dans des environnements réglementaires différents.

En conclusion, l'utilisation de l'IAG en audit dépendra ainsi avant tout des conditions dans lesquelles elle est mise en œuvre.

Bibliographie

Revues professionnelles

CNCC (Compagnie Nationale des Commissaires aux Comptes). (2024, décembre). *Audit & Société : Propos et Débats n°6 - L'intelligence artificielle*. CNCC. Consulté sur <https://cdn.cncc.fr/download/cncc-livret-auditsociete-n69-web.pdf>

Deloitte. (2024, janvier). *How we harness Generative AI for a smarter, digital audit*. Deloitte. Consulté sur <https://www2.deloitte.com/content/dam/Deloitte/se/Documents/audit/AI%20presentation%20for%20the%20Audit%20Committee%20-%20Second%20draft.pdf>

KPMG International. (2024, mai). *AI in financial reporting and audit: Navigating the new era*. KPMG. Consulté sur <https://assets.kpmg.com/content/dam/kpmgsites/dk/pdf/dk-2024/dk-ai-in-financial-reporting-and-audit-web.pdf.coredownload.inline.pdf>

CAQ (Center for Audit Quality). (2024, avril). *Auditing in the Age of Generative AI*. The CAQ. Consulté sur https://www.thecaq.org/wp-content/uploads/2024/04/caq_auditing-in-the-age-of-generative-ai_2024-04.pdf

Revues académiques

Anica-Popa, I.-F., Vrîncianu, M., Anica-Popa, L., Cișmașu, I.-D., & Tudor, C.-G. (2024). Framework for Integrating Generative AI in Developing Competencies for Accounting and Audit Professionals. *Electronics*, 13(13), 2621. <https://doi.org/10.3390/electronics13132621>

Davis, F. D. (1989). Perceived Usefulness, Perceived Ease of Use, and User Acceptance of Information Technology. *MIS Quarterly*, 13(3), 319-340.

<https://doi.org/10.2307/249008>

Dong, M. M., Stratopoulos, T. C., & Wang, V. X. (2024). A scoping review of ChatGPT research in accounting and finance. *International Journal of Accounting Information Systems*, 55, Article 100715.

<https://doi.org/10.1016/j.accinf.2024.100715>

Eisikovits, N., Johnson, W. C., & Markelevich, A. (2025). Should Accountants Be Afraid of AI? Risks and Opportunities of Incorporating Artificial Intelligence into Accounting and Auditing. *Accounting Horizons*, 39(2), 117-123.

<https://doi.org/10.2308/HORIZONS-2023-042>

Estep, C., Griffith, E. E., & MacKenzie, N. L. (2024). How do financial executives respond to the use of artificial intelligence in financial reporting and auditing? *Review of Accounting Studies*, 29(3), 2798-2831.

<https://doi.org/10.1007/s11142-023-09771-y>

Euchner, J. (2023). Generative AI. *Research Technology Management*, 66(3), 71-74.

<https://doi.org/10.1080/08956308.2023.2188861>

Fedyk, A., Hodson, J., Khimich, N., & Fedyk, T. (2022). Is artificial intelligence improving the audit process? *Review of Accounting Studies*, 27(3), 938-985.

<https://doi.org/10.1007/s11142-022-09697-x>

Fotoh, L. E., & Mugwira, T. (2025). Exploring Large Language Models in external audits: Implications and ethical considerations. *International Journal of Accounting Information Systems*, 56, Article 100748.

<https://doi.org/10.1016/j.accinf.2025.100748>

Gu, H., Duan, H. K., & Vasarhelyi, M. A. (2025). Challenges for Leveraging Explainable Artificial Intelligence in Audit Procedures. *Journal of Emerging Technologies in Accounting*, 1-12.

<https://doi.org/10.2308/JETA-2023-044>

Ham, C., Hann, R. N., Rabier, M., & Wang, W. (2025). Auditor Skill Demands and Audit Quality: Evidence from Job Postings. *Management Science*, 71(7), 5805-5829.

<https://doi.org/10.1287/mnsc.2022.01640>

Hurtt, R. K. (2010). Development of a Scale to Measure Professional Skepticism. *Auditing: A Journal of Practice and Theory*, 29(1), 149-171.

<https://doi.org/10.2308/aud.2010.29.1.149>

Jonnala, S., Parida, P. K., & Thomas, N. M. (2025). EU AI Act Underrepresented and Insufficient to Address the Risk and Vulnerabilities of Generative AI. *International Journal of Business Analytics (IJBAN)*, 12(1), 1-27.

<https://doi.org/10.4018/IJBAN.388757>

Law, K. K. F., & Shen, M. (2025). How Does Artificial Intelligence Shape Audit Firms? *Management Science*, 71(5), 3641-3666.

<https://doi.org/10.1287/mnsc.2022.04040>

Li, Y., & Goel, S. (2025). Artificial intelligence auditability and auditor readiness for auditing artificial intelligence systems. *International Journal of Accounting Information Systems*, 56, Article 100739.

<https://doi.org/10.1016/j.accinf.2025.100739>

Liang, L., Dai, T., Cui, L., & Song, M. (2025). Digital audit talent's impact on audit digitization and detection risk. *Scientific Reports*, 15(1), Article 31222.

<https://doi.org/10.1038/s41598-025-16444-0>

Lu, Y., Hao, J., & Tang, X. (2025). Dual-model synergy for audit opinion prediction: A collaborative LLM agent framework approach. *International Review of Economics & Finance*, 104, Article 104642.

<https://doi.org/10.1016/j.iref.2025.104642>

Munoko, I., Brown-Liburd, H. L., & Vasarhelyi, M. (2020). The Ethical Implications of Using Artificial Intelligence in Auditing. *Journal of Business Ethics*, 167(2), 209-234.

<https://doi.org/10.1007/s10551-019-04407-1>

Samiolo, R., Spence, C., & Toh, D. (2024). Auditor judgment in the fourth industrial revolution. *Contemporary Accounting Research*, 41(1), 498-528.

<https://doi.org/10.1111/1911-3846.12901>

Sun, G., Ling, Z., Li, Y., & Xie, C. (2025). Artificial intelligence and financial fraud. *Pacific-Basin Finance Journal*, 93, Article 102830.

<https://doi.org/10.1016/j.pacfin.2025.102830>

Tan, J., Chang, S., Zheng, Y., & Chan, K. C. (2025). Effects of artificial intelligence in the modern business: Client artificial intelligence application and audit quality. *International Review of Financial Analysis*, 104, Article 104271.

<https://doi.org/10.1016/j.irfa.2025.104271>

Vitali, S., & Giuliani, M. (2024). Emerging digital technologies and auditing firms: Opportunities and challenges. *International Journal of Accounting Information Systems*, 53, Article 100676.

<https://doi.org/10.1016/j.accinf.2024.100676>

Annexes

Annexe 1 : Liste des questions du google form

N°	Libellé de la question	Échelle	Rôle
Bloc 1 Usage et adoption de l'IAG (variable dépendante)			
Q1	Fréquence d'usage de l'IAG dans votre travail quotidien	Likert 7	Variable dépendante principale
Q2	Type d'outil IAG principalement utilisé (grand public / semi-interne / interne)	Nominale	Contexte / sous-analyses
Q3	Outils IAG utilisés (9 sous-items binaires : ChatGPT, Gemini, outil interne...)	Binaire ×9	Score de diversité des outils
Q4	Nombre et nature des tâches réalisées avec l'IAG (tâches simples vs complexes)	Ordinale regroupée	Mesure comportementale complémentaire
Q5	Contexte d'usage : volontaire / recommandé / imposé	Nominale	Qualification de l'adoption
Bloc 2 Utilité perçue (score SUP H1)			
Q6	Perception de l'impact de l'IAG sur la productivité (10 sous-items)	Likert 5 ×10	Score SUP sous-score productivité
Q7	Perception de l'impact de l'IAG sur la qualité du travail d'audit (10 sous-items)	Likert 5 ×10	Score SUP sous-score qualité

Q8	Perception du gain de temps lié à l'usage de l'IAG	Likert 7 (normalisé e à 5)	Score SUP
Bloc 3 Facilité d'utilisation perçue (score SFU H2)			
Q9	Facilité de prise en main des outils IAG	Likert 7	Score SFU
Q10	Facilité d'intégration de l'IAG au quotidien professionnel	Likert 7	Score SFU
Q11	L'IAG requiert une formation spécifique (INVERSÉE)	Likert 7	Score SFU inversée (8 - Q11)
Bloc 4 Perception des risques (score SRP H3)			
Q12	Conscience du risque d'hallucinations (informations inventées par l'IAG)	Likert 7	Score SRP
Q13	Conscience du risque de confidentialité des données	Likert 7	Score SRP
Q14	Conscience du risque lié à l'opacité algorithmique (boîte noire)	Likert 7	Score SRP
Q15	Conscience du risque de responsabilité en cas d'erreur de l'IAG	Likert 7	Score SRP
Q16	Classement des quatre risques ci-dessus par ordre d'importance (4 sous-items)	Rang ×4	Analyse dimensionnelle H3
Q17	Ces risques m'empêchent d'augmenter mon usage de l'IAG	Likert 7	Variable complémentaire H3

Q18	Si les risques étaient éliminés, j'utiliserais davantage l'IAG	Likert 7	Variable contrefactuelle H3
Bloc 5 Compétences et jugement professionnel (scores SMF et SSP H4a, H4b, H4c)			
Q19	Niveau global de formation à l'IAG (interne ou auto-apprentissage)	Likert 7	Score SMF modérateur principal H4a
Q20	Sentiment de maîtrise de l'IAG (orienter les réponses)	Likert 7	Score SMF
Q21	Capacité à identifier les erreurs produites par l'IAG	Likert 7	Score SMF
Q22	Je me fie aux résultats de l'IAG sans vérifier (INVERSÉE)	Likert 7	Score SSP inversée (8 Q22)
Q23	Je vérifie les sources utilisées par l'IAG	Likert 7	Score SSP
Q24	Mon jugement professionnel reste fort même quand j'utilise l'IAG	Likert 7	Score SSP
Q25	Je me fie parfois plus à l'IAG qu'à mon propre jugement (INVERSÉE)	Likert 7	Score SSP inversée (8 Q25)
Q26	Je conclus avant d'avoir obtenu tous les résultats (INVERSÉE)	Likert 7	Score SSP inversée (8 Q26)
Bloc 6 Perspectives et profil du répondant			
Q27	Prévoyez-vous d'augmenter votre usage de l'IAG dans les 6 prochains mois ?	Binaire Oui/Non	Variable complémentaire TAM / validation H1 H2

Q28	Probabilité d'augmenter votre usage si vous receviez une formation	Likert 7	Variable complémentaire H4a
Q29	Question piège d'attention (réponse attendue : Neutre)	Likert 7	Contrôle qualité filtre d'exclusion
Q30	Perception globale de l'équilibre bénéfices/risques de l'IAG en audit	Likert 7	Question de synthèse validité convergente
Q31	Tranche d'âge	Nominale	Profil répondant sous-analyses
Q32	Genre	Nominale	Profil répondant sous-analyses
Q33	Niveau hiérarchique (Junior / Senior / Manager / Associé / CAC)	Nominale	Profil répondant sous-analyses
Q34	Ancienneté dans la profession	Ordinale	Profil répondant sous-analyses
Q35	Type de mission principale (CAC / audit contractuel / autre)	Nominale	Profil répondant sous-analyses
Q36	Taille du cabinet (régional / national / Big 4)	Nominale	Profil répondant sous-analyses

Annexe 2 : Questionnaire entretien semi-dirigé

Perception et adoption de l'IA générative en cabinet d'audit - M2 CGAO - Lydéric HENRY

Durée estimée	30 à 45 minutes
Format	Semi-directif, enregistré avec accord préalable
Profil cible	Auditeur(trice) en cabinet - tous grades
Objectif	Approfondir et nuancer les résultats de l'enquête quantitative (N = 67)
Confidentialité	Données anonymisées. Enregistrement détruit après retranscription.

Rappel synthétique des résultats

Présenter brièvement à l'interviewé avant de commencer.

H1	Plus l'IA paraît utile → plus on l'utilise	✗ Infirmée
H2	Plus l'IA s'intègre au workflow → plus on l'utilise	✓ Confirmée
H3	Plus on perçoit des risques → moins on l'utilise	✓ Confirmée
H4a	Mieux on maîtrise l'IA → moins les risques freinent	≈ Tendance
H4b	Mieux on maîtrise l'IA → plus on reste sceptique	✗ Infirmée

H4c	Plus on perçoit des risques non maîtrisés → plus le scepticisme s'érode	X Infirmée
------------	---	-------------------

Thème 0 - Ouverture et profil (5-8 min)

Objectif : mettre en confiance et comprendre le contexte d'usage de l'interviewé.

Q0	Pouvez-vous vous présenter : votre poste, votre ancienneté, et le type de missions sur lesquelles vous travaillez principalement ? ↳ Êtes-vous plutôt en audit financier, IT, interne ? ↳ Dans quel type de cabinet exercez-vous - Big 4, cabinet régional, local ?
Q1	Utilisez-vous l'IA générative dans votre travail ? Si oui, sur quelles tâches concrètement, et depuis combien de temps ? <i>74,6 % des auditeurs interrogés l'utilisent principalement pour reformulation/traduction - 9 % seulement pour des tâches à fort enjeu professionnel.</i> ↳ Est-ce que votre cabinet vous a fourni un outil, ou utilisez-vous ChatGPT / Claude de votre propre initiative ? ↳ Avez-vous été formé, ou vous êtes-vous débrouillé seul ?

Thème 1 - Utilité et intégration au workflow (H1 & H2)

Ce qu'on cherche à comprendre : pourquoi est-ce que trouver l'IA utile ne suffit pas à l'utiliser, et ce qui fait vraiment qu'elle s'installe dans les habitudes.

Q2	Dans notre enquête, presque tous les auditeurs trouvent l'IA utile - mais ce n'est pas ce qui explique qu'ils l'utilisent vraiment. Qu'est-ce qui vous semble expliquer cet écart ? <i>Score moyen d'utilité perçue : 3,40/5 - quasiment tout le monde est en haut de l'échelle, il n'y a plus de différences entre répondants.</i> ↳ Avez-vous déjà trouvé l'outil utile en théorie mais ne l'avez pas utilisé ? Pourquoi ? ↳ Qu'est-ce qui vous a décidé à l'intégrer - ou qu'est-ce qui vous a freiné ?
-----------	---

Q3	Le facteur qui prédit le mieux l'usage dans notre étude, c'est que l'outil s'intègre naturellement dans le flux de travail - pas qu'il soit facile à apprendre. Comment ça se passe pour vous concrètement ? $\rho = 0,492^{***}$ - « L'IAG s'intègre naturellement à mon workflow quotidien » - corrélation la plus forte de toute l'étude avec l'usage réel. ↳ Sur quelles tâches l'IAG s'est-elle glissée naturellement dans vos habitudes, et sur lesquelles ça n'a pas fonctionné ? ↳ Votre cabinet facilite-t-il cette intégration, ou c'est à votre initiative personnelle ? ↳ L'item qui ressort le plus dans nos données : « L'IAG améliore la qualité de mes rédactions ». Est-ce que ça résonne avec votre vécu ?
----	---

Thème 2 - Risques perçus et freins à l'usage (H3)

Ce qu'on cherche à comprendre : quels risques freinent vraiment l'usage - et pourquoi la confidentialité, jugée la plus importante, ne bloque pas autant que la responsabilité individuelle.

Q4	Dans notre enquête, la confidentialité est le risque jugé le plus important par les auditeurs - mais c'est celui qui freine le moins leur usage. C'est la responsabilité individuelle qui bloque davantage. Est-ce que ça vous surprend ? 68,7 % jugent la confidentialité comme le risque le plus important - mais $\rho = 0,109$ NS sur le frein comportemental. La responsabilité individuelle, 3e en importance, est le seul frein significatif ($\rho = 0,304^*$). ↳ La confidentialité est-elle gérée par votre cabinet - outils agréés, environnement sécurisé ? Ça vous rassure vraiment, ou c'est flou ? ↳ Avez-vous déjà hésité à utiliser l'IAG par crainte d'engager votre responsabilité si elle fait une erreur ? ↳ Y a-t-il des tâches sur lesquelles vous vous interdisez d'utiliser l'IAG ? Pourquoi celles-là ?
Q5	41 % disent qu'ils utiliseraient beaucoup plus l'IAG si les risques disparaissaient - mais seulement 9 % se déclarent très freinés aujourd'hui. Les risques vous semblent-ils un vrai obstacle, ou plutôt quelque chose qu'on invoque sans vraiment se sentir bloqué ? 41,8 % utiliseraient davantage l'IAG si les risques étaient levés (Q18, moy. = 5,73/7) - contre 9 % très freinés aujourd'hui. ↳ Qu'est-ce qui permettrait concrètement de lever ce frein - formation, clarification des responsabilités, outils mieux encadrés ? ↳ Votre cabinet communique-t-il clairement sur les limites de responsabilité en cas d'erreur de l'IAG ?

Thème 3 - Maîtrise fonctionnelle et compétences-clés (H4a)

Ce qu'on cherche à comprendre : pourquoi ce ne sont pas les heures de formation qui comptent, mais deux compétences très concrètes - prompter et détecter les erreurs.

Q6	Nos résultats montrent que ce n'est pas le nombre de jours de formation reçue qui distingue les gros utilisateurs de l'IAG. Ce sont deux compétences concrètes : savoir formuler de bons prompts, et savoir détecter quand l'IA se trompe. Est-ce que ça correspond à ce que vous observez ? $\rho = 0,379^{**}$ vs $\rho = 0,095$ NS - « Savoir prompter » est fortement corrélé à l'usage ; « avoir reçu une formation » ne l'est pas du tout. ↳ Comment avez-vous développé votre maîtrise du prompting - essais-erreurs, collègues, tutoriels ? ↳ Avez-vous un exemple où vous avez détecté une erreur de l'IAG ? Comment vous en êtes-vous rendu compte ? ↳ Parmi vos collègues, est-ce que ceux qui utilisent le plus l'IAG se démarquent par ces compétences-là ?
Q7	Chez les auditeurs peu formés, les risques freinent beaucoup l'usage. Chez les très formés, ils ne freinent plus du tout. Est-ce que ça résonne - le fait que la compétence protège contre la peur du risque ? Gradient $-0,416 \rightarrow 0,000$ - l'effet des risques sur l'usage : fort chez les peu formés, complètement neutralisé chez les très formés. ↳ Est-ce que vous avez l'impression que votre rapport aux risques de l'IAG a changé au fur et à mesure que vous l'utilisez ? ↳ Y a-t-il des risques que vous avez cessé de percevoir comme problématiques une fois que vous avez mieux maîtrisé l'outil ?
Q8	75 % des répondants augmenteraient leur usage avec une bonne formation. Mais la formation reçue ne prédit pas l'usage - c'est la compétence opérationnelle acquise qui compte. Quel type de formation serait vraiment efficace selon vous ? 75 % augmenteraient leur usage si une formation crédible leur était proposée (Q28, moy. = 5,19/7). ↳ Formation générale sur l'IA, ou accompagnement ciblé sur des tâches d'audit concrètes ? ↳ Qu'est-ce qui ne fonctionne pas dans les formations que vous avez vues - trop théoriques, trop génériques ? ↳ Qui doit porter cette montée en compétences : le cabinet, l'individu, ou l'université ?

Thème 4 - Scepticisme professionnel et biais d'automatisation (H4b / H4c)

Ce qu'on cherche à comprendre : est-ce que l'IAG érode le jugement professionnel - pourquoi les gros utilisateurs se croient plus sceptiques alors qu'ils cèdent davantage (H4b), et si des risques perçus mais non maîtrisés fragilisent le scepticisme plutôt que de le renforcer (H4c).

Q9	Dans notre enquête, les auditeurs qui utilisent le plus l'IAG se déclarent plus confiants dans leur jugement - mais ils reconnaissent aussi remettre plus souvent en question ce jugement quand l'IA propose une conclusion différente. Est-ce que ce paradoxe vous parle ? <i>Score moyen Q25 : 3,48/7 - « je mets en question mon jugement quand l'IAG suggère autre chose » - signal de dépendance progressive.</i> ↳ Vous est-il déjà arrivé de suivre une conclusion de l'IAG même si elle vous semblait surprenante ? Pourquoi ? ↳ Comment vérifiez-vous concrètement les outputs de l'IAG avant de les intégrer à votre travail ? ↳ Pensez-vous que l'IAG peut, à long terme, éroder le scepticisme professionnel des auditeurs - surtout les juniors ?
Q10	Le risque d'hallucinations est noté 6,16/7 - le plus grave de toute l'étude. Comment gérez-vous ce risque en pratique ? Avez-vous développé des réflexes ? <i>6,16/7 - score moyen du risque d'hallucinations - risque perçu comme le plus grave, devant confidentialité et responsabilité.</i> ↳ Faites-vous confiance aux outils agréés par votre cabinet, ou restez-vous méfiant de toute façon ? ↳ Les juniors ont-ils selon vous les réflexes pour détecter ces erreurs, ou c'est un angle mort ?
Q10b	Notre hypothèse H4c prédisait que des risques perçus élevés éroderaient le scepticisme professionnel - l'auditeur, destabilisé par des limites qu'il ne maîtrise pas, déléguerait son jugement à la machine. Or, dans nos données, ce lien n'existe pas : percevoir beaucoup de risques ne rend pas moins sceptique. Est-ce que cela vous parle ? <i>$\rho(\text{SRP}, \text{SSP}) = 0,113$ (NS) - direction même contraire à l'attendu : les auditeurs qui perçoivent le plus de risques ne sont pas moins sceptiques, ils le sont légèrement plus.</i> ↳ Pensez-vous que le fait d'être conscient des risques vous pousse justement à être plus vigilant - plutôt qu'à baisser les bras ? ↳ Un auditeur qui ne perçoit aucun risque serait-il selon vous plus dangereux qu'un auditeur très conscient des limites de l'outil ? ↳ Avez-vous observé des collègues qui, au contraire, se sentent tellement dépassés par les risques qu'ils utilisent l'IAG « en aveugle » car ils renoncent à comprendre ?

Thème 5 - Différences selon le grade et la taille du cabinet

Ce qu'on cherche à comprendre : pourquoi les Associés intègrent moins bien l'IAG, et pourquoi la taille du cabinet ne change rien à l'adoption individuelle.

Q11	Dans nos données, les Associés trouvent l'IAG nettement moins facile à intégrer dans leur quotidien que les Seniors et Managers - alors que l'usage réel est identique entre tous les grades. Comment vous expliquez ça ? <i>4,21 vs 5,08/7 - facilité d'usage perçue : Associés vs Seniors-Managers. Écart significatif (p-value = 0,006**), mais usage réel identique entre grades.</i> ↳ <i>Est-ce lié à la nature des tâches des Associés - supervision, relation client, signature - qui se prêtent moins à l'automatisation ?</i> ↳ <i>Autour de vous, est-ce que les Associés utilisent l'IAG différemment des juniors et seniors ?</i>
Q12	Nos résultats montrent que l'usage de l'IAG est exactement le même dans les Big 4 et dans les cabinets locaux - la taille du cabinet ne change rien. Est-ce que ça vous surprend ? <i>p-value = 0,773 NS - aucune différence d'usage entre Big 4 et cabinets locaux.</i> ↳ <i>Pensez-vous que c'est la motivation individuelle qui compte plus que les ressources du cabinet ?</i> ↳ <i>Les cabinets locaux que vous connaissez ont-ils accès aux mêmes outils, ou s'organisent-ils autrement ?</i>

Clôture (5 min)

Q13	En résumé, quel est selon vous le principal obstacle à une adoption plus large et plus éclairée de l'IA générative en cabinet d'audit aujourd'hui ? ↳ <i>Obstacle organisationnel, réglementaire, humain, ou autre ?</i> ↳ <i>Qu'est-ce que les cabinets pourraient faire concrètement pour lever cet obstacle ?</i>
Q14	Y a-t-il quelque chose d'important que nos questions ne vous ont pas permis d'aborder ?

Lydéric HENRY - M2 CGAO, Parcours Audit Contrôle de Gestion - Université de Lille - 2025-2026

Sous la direction de Aymen ABBADI (académique) et Kévin OLEJNIK (cabinet d'audit)

Annexe 3 : Comptes rendus entretiens semi dirigés (Interviewés A,B,C)

Interviewé A

Profil

Poste : Auditeur IT et data, senior

Cabinet : Grand cabinet international

Ancienneté : 4 ans, dont 1 an en audit financier

Date : 20 Mars 2026

Format : Présentiel, Entretien semi-directif, notes en direct

Profil : utilisateur intensif et précoce de l'IAG, auto-formé, forte appétence technologique.

H1 & H2 - Utilité perçue et intégration au workflow

Il n'est pas surpris par l'écart entre utilité reconnue et usage effectif. Il explique qu'il y a deux ans, les outils produisaient beaucoup d'erreurs, ce qui freinait l'adoption. Il estime aujourd'hui ne pas être meilleur que l'IAG sur aucune tâche. Il souligne que la performance perçue de l'outil mis à disposition par le cabinet joue un rôle majeur : si Copilot est imposé mais jugé inférieur à Claude, cela freine l'usage, même chez les utilisateurs motivés. Il note que les auditeurs utilisent l'IAG principalement sur les tâches où ils se jugent moins compétents, et conservent les tâches métier pour eux-mêmes.

L'IAG n'est pas intégrée de façon fluide dans son environnement. Il utilise l'outil en dehors des logiciels d'audit, sur des tâches variées : recherche documentaire, résolution de problèmes techniques, génération de code, manipulation d'outils spécialisés (Alteryx, Python), traduction et reformulation ponctuelle. Il précise qu'il n'utilise pas l'IAG pour de la dataprep ou du rapprochement, et qu'il préfère conserver la rédaction client car « ce sont ses mots qui ont été choisis ».

H3 - Risques perçus et freins à l'usage

Il se déclare peu soucieux des questions de conformité RGPD au quotidien, considérant que l'outil mis à disposition respecte ces contraintes par défaut. Il repose sur cette hypothèse sans la vérifier. Il note cependant une contradiction dans la politique de son cabinet : l'outil officiel est Copilot, mais le discours interne est de ne rien y injecter. Cette ambiguïté réduit l'effet dissuasif de la confidentialité en pratique.

Il trace lui-même une limite claire : il n'utilisera jamais l'IAG pour traiter des données comptables, un grand livre ou un FEC, estimant que « la probabilité est faible mais l'impact est trop gros ». Il souligne également qu'il n'existe aucun mécanisme de contrôle réel sur ce que les auditeurs injectent dans l'outil : « personne ne peut savoir ce que tu mets dans l'IA générative ». La responsabilité individuelle ne le préoccupe pas directement, car il vérifie systématiquement les outputs produits.

H4a - Maîtrise fonctionnelle

Il est auto-formé et n'a reçu aucune formation spécifique de son cabinet. Il juge les formations proposées « très théoriques » et inadaptées au développement de réflexes opérationnels. Il distingue clairement la formation reçue de la compétence réellement acquise par la pratique. Il insiste sur deux compétences concrètes : savoir prompter pour interroger l'IAG sur la façon dont elle a obtenu ses résultats, et savoir détecter les erreurs en confrontant les réponses à des sources externes. Il recommande d'intégrer l'IAG dans les formations existantes (sur les capitaux propres, les cycles d'audit) plutôt que d'en faire un module isolé.

H4b & H4c - Scepticisme et biais d'automatisation

Il affirme que plus il utilise l'IAG, plus il développe son jugement professionnel, comparant l'outil à un junior dont il vérifie le travail. Il a déjà suivi une conclusion de l'IAG après vérification documentaire, mais nuance : cela peut simplement correspondre à un avis contraire discuté ou à une situation où il avait lui-même mal compris le problème. Il reconnaît que d'autres utilisateurs peuvent accepter les résultats sans vérification, ce qui constitue un vrai risque. Il estime que l'IAG pourrait éroder le jugement professionnel à long terme « car on aura trop confiance », et que la compétence est une condition de l'indépendance de l'auditeur.

Apports complémentaires

Il souligne que les juniors risquent de ne pas détecter les hallucinations, car ils leur feront confiance par défaut. Il note que si l'outil proposé par le cabinet est peu performant et génère de mauvaises premières expériences, les utilisateurs perdent l'envie d'y revenir, même quand l'outil s'améliore. Il insiste sur le fait que les cabinets devraient mieux accompagner l'intégration des outils dans les pratiques réelles plutôt que de laisser chaque auditeur se former seul.

Interviewé B

Profil

Poste : Superviseur audit (niveau senior 2 / manager)

Cabinet : Cabinet régional-national

Ancienneté : 7 ans d'audit, depuis 2019

Missions : 95 % audit financier - secteurs associatif, médico-social, sociétés commerciales, gestion déléguée

Date : 9 avril 2026

Format : Visioconférence, Entretien semi-directif enregistré, retranscription intégrale disponible

Profil : utilisateur convaincu mais contraint par les politiques internes du cabinet, usage encadré et prudent.

H1 & H2 - Utilité perçue et intégration au workflow

Il reconnaît sans réserve l'utilité de l'IAG, en particulier pour les tâches à fort potentiel de gain de temps : revue des écritures comptables, production de comptes rendus à partir de documents existants, application automatisée d'analyses (loi de Benford, rapprochements de factures). Il estime que l'IAG peut réaliser certaines de ces tâches « beaucoup plus vite qu'un junior ». Cependant, la politique stricte de son cabinet sur la non-injection de données clients empêche cette utilité théorique de se concrétiser en pratique.

En termes d'intégration, il souligne que l'IAG n'est pas directement connectée aux outils d'audit du cabinet. Il utilise Copilot Entreprise (Microsoft 365) pour des tâches périphériques : recherche documentaire via un agent paramétré, reformulation, synthèse de prises de parole, traduction, aide aux formules Excel. Il a créé plusieurs agents Copilot pour structurer ses requêtes et limiter les sources consultées. Il aspire à une intégration plus poussée : un agent capable d'analyser ses mails, de suivre ses suspens et de gérer son calendrier. Il soulève le risque d'une intégration trop précoce pour les juniors, qui pourraient « s'abreuver d'un compte rendu sans comprendre comment il se construit ».

H3 - Risques perçus et freins à l'usage

Il se dit « très limité » par les risques de confidentialité et affirme que la levée de cette contrainte l'inciterait à utiliser l'IAG bien davantage. La politique du cabinet repose sur un principe de non-injection de données sensibles : il n'injecte que des documents disponibles dans le domaine public. Il précise que même dans Copilot Entreprise, la protection des données reste floue dans les faits. Il n'hésite pas à l'usage pour des raisons de responsabilité individuelle, estimant que celle-ci n'a pas fondamentalement changé avec l'IAG, à condition de vérifier les outputs.

Il souligne que les risques constituent un véritable obstacle opérationnel, pas seulement psychologique, dans la mesure où ils limitent directement les cas d'usage possibles. Une meilleure clarification des conditions d'usage par le cabinet et une sécurisation plus explicite des outils lui permettraient d'utiliser l'IAG sur des tâches à plus fort enjeu.

H4a - Maîtrise fonctionnelle

Auto-formé par la pratique, sans formation formelle de son cabinet. Il a progressivement structuré son usage autour de plusieurs essais et de la mise en place d'agents adaptés à ses besoins. Il insiste sur la capacité à « contrôler le rendu » et à comprendre ce que produit l'outil, plutôt que sur la maîtrise théorique. Il reconnaît des limites dans la construction des requêtes, notamment pour des usages plus avancés. Il confirme que les formations proposées par le cabinet sont peu adaptées au développement de réflexes opérationnels concrets.

H4b & H4c - Scepticisme et biais d'automatisation

Il déclare avoir plus confiance en son propre jugement professionnel qu'en les outputs de l'IAG, qu'il utilise avant tout pour corroborer ses analyses. Il met en place des vérifications

systematiques par sondage : il confronte les réponses de l'IAG aux sources proposées ou à d'autres références, sans valider l'ensemble du contenu produit. Il estime comprendre les résultats en les regardant, ce qui lui permet d'identifier les erreurs éventuelles.

Apports complémentaires

Il évoque le risque de perte de compétences chez les juniors si l'IAG est intégrée trop tôt dans les routines : la dernière génération à avoir fait des rapprochements à la main représente, selon lui, une « période transitoire » essentielle. Il imagine une période transitoire sans IAG pour les juniors afin de préserver leur capacité à comprendre et à contester les outputs. Il souligne également le rôle structurant des premières expériences : des débuts peu concluants avec Copilot ont généré un manque d'envie de réessayer chez certains collègues, même maintenant que l'outil s'est amélioré.

Interviewé C

Profil

Poste : Commissaire aux comptes signataire, associé fondateur

Cabinet : STARK Audit (cabinet indépendant, créé ex nihilo en 2022)

Ancienneté : 15 ans d'expérience (6 mois KPMG, 14 ans PKF Audit Conseil)

Missions : 15 mandats CAC, 2 missions expertise comptable - PME, associations, fonds de dotation

Activités annexes : Formateur à la CNCC, bêta-testeur Sidonie Assist (en partenariat avec Dust), mentor HackAudit

Date : 3 avril 2026

Format : Visioconférence, entretien semi-directif enregistré, retranscription intégrale disponible

Profil : adoptant stratégique et engagé, forte conscience déontologique, posture de pionnier dans l'intégration de l'IAG en audit.

H1 & H2 - Utilité perçue et intégration au workflow

Il reconnaît l'IAG comme un outil extraordinaire mais précise qu'il n'a pas encore exploré tous les usages possibles. Son frein principal est le manque de connaissance des cas d'usage combiné à l'incertitude sur la confidentialité. Il a reçu le jour même de l'entretien un mail de la CNCC présentant de nouveaux outils à destination des CAC (fiches IA introductive et avancée, instructions sur la création d'agents), signe d'une professionnalisation en cours.

Ses usages actuels via Sidonie Assist et Dust : recherche documentaire normative (NEP, ESRS, VSME), développement d'activité (test des règles de communication CAC), génération de contenu pour son site internet et LinkedIn, rédaction de plans de mission et programmes de travail (bonne base, à retravailler), amélioration de la documentation et des questionnaires, formules Excel. Il n'utilise pas l'IAG pour l'analyse de données ou l'automatisation de rapprochements. Il voit dans l'IAG un substitut partiel à l'embauche d'un assistant, ce qui lui permet de maintenir son autonomie avec un budget limité.

Il aspire à un logiciel d'audit intégrant directement l'IAG, capable de générer un programme de travail personnalisé à partir de quelques indications et de faire le lien entre zones de risque et documentation de la mission. Son expérience négative avec Auditsoft (lenteur, incompatibilité multi-documents, perte de temps) l'a durablement rendu prudent vis-à-vis des outils intégrés.

H3 - Risques perçus et freins à l'usage

Il distingue nettement la situation du collaborateur et celle du signataire. Les juniors ne se posent pas de questions sur la confidentialité car ce n'est pas eux qui engagent leur responsabilité : c'est le phénomène de « shadow IA », directement comparable au shadow IT. Il décrit des situations où des données confidentielles (FEC, grand livre, données de salaires incluant des noms de salariés) sont injectées dans l'IAG sans encadrement ni traçabilité. Il recommande la mise en place d'une charte d'usage de l'IA et d'un code de bonne conduite intégré aux procédures du cabinet.

De son côté, il n'hésite pas à utiliser l'IAG par crainte de responsabilité, car il utilise Sidonie Assist dans l'objectif explicite de détecter les erreurs qu'elle produit. Il confirme que « quand tu engages ta responsabilité, tu te poses plus de questions », ce qui valide directement le résultat quantitatif sur la responsabilité individuelle comme principal frein comportemental.

H4a - Maîtrise fonctionnelle

Il juge l'IAG assez intuitive et estime qu'une formation spécifique n'est pas indispensable pour démarrer. Il appuie néanmoins son usage sur les fiches de la CNCC (prompting, détection d'erreurs), qu'il considère comme une base déontologique essentielle. Il insiste sur le fait que la détection des erreurs relève avant tout du jugement professionnel et non de compétences purement techniques : savoir identifier une réponse incorrecte suppose de comprendre le fond du sujet.

Il développe une lecture en trois temps de la relation entre formation et conscience des risques, proche de l'effet Dunning-Kruger : les peu formés restent freinés par les risques perçus ; ceux qui commencent à se former tendent à sous-estimer ces risques par excès de confiance ; les utilisateurs les plus avancés retrouvent une conscience accrue des limites de l'outil. Il appelle à des formations pratiques centrées sur des cas d'usage réels et des exercices de prompting, plutôt que sur des formations théoriques généralistes.

H4b & H4c - Scepticisme et biais d'automatisation

Il souligne que la perception des risques renforce le scepticisme professionnel plutôt qu'elle ne l'érode : « l'auditeur conscient des risques va justement remettre en cause son jugement », tandis que « l'auditeur qui ne perçoit aucun risque est plus dangereux ». Cette lecture explique le résultat de H4c : la perception des risques agit comme un mécanisme d'alerte plutôt que comme un facteur d'érosion du scepticisme.

Il reconnaît avec humilité que même un auditeur expérimenté peut être induit en erreur par des outputs plausibles mais factuellement faux. Il est particulièrement préoccupé par le risque pour les juniors, estimant qu'ils feront confiance à un texte bien rédigé sans en questionner la fiabilité, d'autant plus que leur maîtrise de la langue écrite s'affaiblit, ce qui réduit leur capacité à repérer les incohérences de fond.

Apports complémentaires

Il développe une vision stratégique de la dynamique concurrentielle à venir : certains grands cabinets pourraient utiliser l'IAG pour dominer par les coûts dans un premier temps, en réduisant le prix des missions de base, avant de repositionner leurs ressources vers des missions à plus forte valeur ajoutée. Cette trajectoire pourrait accentuer les inégalités entre

structures plutôt que les réduire. Il note toutefois que les petits cabinets bénéficient d'un avantage de souplesse et de proximité client que les grands ne peuvent pas reproduire.

Il évoque également les biais de genre identifiés dans les données d'entraînement des LLMs, présentés lors d'une conférence juridique, et le risque que l'habitude d'usage réduise progressivement la vigilance face aux risques, selon un mécanisme comparable à l'accoutumance au risque lors de l'apprentissage de la conduite.

Liste paginée des tableaux et figures

Liste des tableaux

Tableau 1 : Scores composites - Page 46

Tableau 2 : Entonnoir de filtrage de l'échantillon - Page 49

Tableau 3 : Outils IAG utilisés - Page 53

Tableau 4 : Tâches réalisées avec l'IAG - Page 54

Tableau 5 : Statistiques descriptives et cohérence interne des scores composites (N = 67) - Page 56

Tableau 6 : H1 : corrélations item SUP → Q1 (N = 67) - Page 61

Tableau 7 : H1 : corrélations item SUP → Q1 par grade (N = 67) - Page 62

Tableau 8 : H2 : corrélations item SFU → Q1 (N = 67) - Page 63

Tableau 9 : H3 : Statistiques descriptives - Page 64

Tableau 10 : H3 : corrélations items de risque → Q17 (vérification de cohérence, N = 67) - Page 65

Tableau 11 : H4a : corrélation SRP → Q1 stratifiée par tercile SMF - Page 67

Tableau 12 : Corrélations désagrégées - Maîtrise - Page 68

Tableau 13 : Statistiques descriptives Scepticisme - Page 69

Tableau 14 : Récapitulatif des tests d'hypothèses (N = 67) - Page 71

Tableau 15 : Scores moyens par grade et tests de Kruskal-Wallis (N = 67) - Page 75

Tableau 16 : Scores moyens et tests de Mann-Whitney par type de cabinet (N = 67) - Page 76

Liste des figures

Figure 1 : Illustration génération texte LLMs - Source ASKAIBRAIN - Page 12

Figure 2 : Triangle de la fraude | Source : ITESOFT - Page 24

Figure 3 : Les 6 dimensions du scepticisme professionnel | Source : Napkin AI - Page 27

Figure 4 : Profil de l'échantillon (N = 67) : genre, âge, grade et taille du cabinet - Page 50

Figure 5 : Profil de l'échantillon (N = 67) : Cœur de métier - Page 52

Figure 6 : Distribution de la fréquence d'usage de l'IAG (Q1, N = 67) - Page 55

Figure 7 : Scores composites : position sur l'échelle maximale et dispersion (N = 67) - Page 57

Figure 8 : Perception de l'équilibre bénéfices-risques de l'IAG en audit (Q30, N = 66) - Page 58

Figure 9 : Répartition score d'utilité perçue (N = 67) - Page 60

Figure 10 : H1 : corrélations Spearman des items SUP avec Q1 (N = 67) - Page 60

Figure 11 : H2 : corrélations Spearman des items SFU avec Q1 (N = 67) - Page 63

Figure 12 : H3 : corrélations des items de risque avec Q17 (vérification de cohérence, N = 67) - Page 65

Figure 13 : H4a : gradient $\rho(\text{SRP} \rightarrow \text{Q1})$ par tercile SMF (N = 21, 24, 22) - Page 68

Figure 14 : H4b et H4c : signaux du biais d'automatisation effets protecteurs et facteurs de risque (N = 67) - Page 70

Figure 15 : Classement des risques par importance perçue (N = 67) - Page 72

Figure 16 : Q17 (frein actuel) vs Q18 (intention si risques éliminés) - Page 74

Glossaire

Algorithmes prédictifs / IA classique : Systèmes d'intelligence artificielle qui opèrent par discrimination en recherchant des motifs (*patterns*) au sein de bases de données massives (*Big Data*) pour classer ou catégoriser des données existantes.

Architecture Transformer : Structure technique apparue en 2017 (ex : modèles BERT et GPT) permettant le passage à l'IA générative moderne grâce à des capacités accrues de compréhension du contexte.

Auto-attention (Self-attention) : Mécanisme probabiliste permettant à un modèle de langage d'associer un poids d'importance à chaque mot par rapport aux autres au sein d'une phrase pour simuler la compréhension du contexte.

Biais d'automatisation : Tendance cognitive incitant l'auditeur à privilégier les recommandations de la machine et à réduire sa vigilance critique, au risque de suivre des conclusions erronées par passivité.

Boîte noire (Black-box) : Problématique liée à l'opacité des modèles de langage dont le fonctionnement interne et les paramètres statistiques sont trop complexes pour être explicités, même par leurs concepteurs.

Chain-of-Thoughts (COT) : Technique de *prompting* consistant à demander à l'IA de détailler les étapes de son raisonnement afin d'améliorer la qualité et la structure de sa réflexion sur des tâches complexes.

Deskilling (Perte de compétences) : Risque que l'automatisation systématique des tâches répétitives empêche les auditeurs, notamment les juniors, de forger l'expérience nécessaire au développement de leur jugement professionnel.

Fine-tuning : Méthode consistant à ajuster ou spécialiser un modèle de langage pré-entraîné sur des données spécifiques pour répondre aux besoins précis d'une organisation ou d'un métier.

Hallucinations factuelles : Phénomène de génération de contenus plausibles et convaincants par l'IA générative qui sont pourtant factuellement faux ou totalement inventés.

Intelligence Artificielle Générative (IAG) : Forme d'IA entraînée pour générer du langage ou des informations compréhensibles par l'Homme, capable de simuler des activités mentales comme l'analyse ou le raisonnement professionnel.

Large Language Models (LLMs) : Modèles de langage à grande échelle utilisant des milliards de paramètres statistiques pour sélectionner le mot suivant le plus probable et simuler une écriture humaine.

Prompt engineering : Art de préparer, structurer et affiner les instructions fournies à l'IA pour maximiser la pertinence et la qualité des résultats obtenus.

Scepticisme professionnel : Attitude vigilante et esprit critique exigés de l'auditeur pour évaluer la fiabilité des éléments collectés et rester attentif aux informations potentiellement contradictoires.

Sense-making : Processus intellectuel consistant à interpréter des informations disparates et à les relier à leur contexte pour leur donner un sens cohérent en vue d'une conclusion d'audit.

Seuil de signification : Montant au-delà duquel une erreur ou une anomalie est considérée comme susceptible d'influencer les décisions économiques des utilisateurs des comptes.

Technology Acceptance Model (TAM) : Cadre théorique postulant que l'adoption d'un outil numérique dépend principalement de la perception subjective de son utilité et de sa facilité d'usage par l'utilisateur.

XAI (Explainable AI) : Ensemble de méthodes visant à rendre les décisions des modèles d'IA justifiables et compréhensibles pour l'humain.

Zéro-shot prompting : Capacité d'un modèle à accomplir une tâche à partir d'une simple instruction, sans avoir besoin d'exemples ou d'entraînement préalable spécifique.

Table des matières

Sommaire paginé

1. Introduction

PARTIE I : REVUE DE LITTÉRATURE CADRES THÉORIQUES ET ENJEUX DE L'IA GÉNÉRATIVE EN AUDIT

Chapitre 1 : Fondements techniques et cadres d'acceptation de l'IAG

1.1. De l'IA classique à l'IA générative (IAG)

1.1.1. Distinction conceptuelle : Algorithmes prédictifs et Big Data vs Modèles de langage (LLMs) et agents cognitifs.

1.1.2. L'intelligence artificielle comme agent de jugement probabiliste

1.2. Le cadre théorique de l'acceptation technologique (TAM)

1.2.1. L'utilité perçue et les opportunités opérationnelles

1.2.2. La Maîtrise fonctionnelle comme facteur d'adoption

Chapitre 2 : Défis normatifs, risques et responsabilité de la chaîne d'audit

2.1. Fondements du scepticisme professionnel en audit

2.1.1. Cadre normatif en France

2.1.2. Modèle théorique de Hurtt et enjeux IAG

2.2. Origines et manifestations des risques liés à l'IAG en audit

2.2.1. Risques cognitifs et biais

2.2.2. Limites techniques de l'IAG

2.3. Enjeux conformité et responsabilité

2.3.1. Confidentialité et conformité réglementaire

2.3.2. Responsabilité et supervision hiérarchique

Chapitre 3 : Développement des hypothèses

3.1. Synthèse de la revue de littérature et formulation des hypothèses

3.1.1 Modèle conceptuel : Adoption technologique et jugement professionnel

3.1.2 Développement des hypothèses de recherche

Partie II : Recherche Empirique

Chapitre 4 : Protocole méthodologique et dispositif de recherche

4.1. Positionnement épistémologique et choix de la méthode

4.1.1. Ancrage épistémologique

4.1.2. Justification du choix d'une approche quantitative

4.2. Conception du questionnaire Google Form

4.2.1. Architecture et opérationnalisation du questionnaire

4.2.2 Complément qualitatif : entretiens semi-dirigés

4.3. Présentation du terrain et de l'échantillon

4.3.1. Collecte des données

4.3.2. Définition de la population cible

Chapitre 5 : Analyse des résultats et discussion

5.1. Profil de l'échantillon

- 5.1.1. Constitution de l'échantillon analytique
- 5.1.2. Caractéristiques sociodémographiques
- 5.1.3. Caractéristiques d'usage des outils IAG (Q2 à Q5)
- 5.2. Statistiques descriptives
 - 5.2.1. Fréquence d'usage de l'IAG (Q1)
 - 5.2.2. Scores composites : statistiques descriptives et fiabilité interne
 - 5.2.3. Perception de l'équilibre bénéfices-risques (Q30)
- 5.3. Test des hypothèses
 - 5.3.1. H1 Utilité perçue et fréquence d'usage
 - 5.3.2. H2 Facilité d'usage perçue et fréquence d'usage
 - 5.3.3. H3 Risques perçus et usage effectif
 - 5.3.4. H4 Maîtrise fonctionnelle, modération des risques et scepticisme professionnel
 - 5.3.4.1. H4a La Maîtrise fonctionnelle comme modérateur de l'effet inhibiteur des risques
 - 5.3.4.2. H4b et H4c Maîtrise fonctionnelle, risques perçus et scepticisme professionnel
 - 5.3.5. Tableau récapitulatif
- 5.4. Analyses complémentaires
 - 5.4.1. Classement des risques perçus par importance (Q16)
 - 5.4.2. Intentions d'usage futur et effet de levier d'une formation (Q27, Q28)
 - 5.4.3. Les risques comme verrou réversible : corrélation Q17-Q18
 - 5.4.4. Comparaisons par grade hiérarchique
 - 5.4.5. Comparaisons cabinets internationaux et autres
- 5.5. Discussion et entretiens semi-dirigés
 - 5.5.1. Confrontation des résultats quantitatifs et qualitatifs
 - 5.5.2. Discussion des résultats par hypothèse
 - 5.5.3. Apports complémentaires des entretiens
 - 5.5.4. Préconisations opérationnelles

Conclusion

Bibliographie

Revue professionnelle

Revue académique

Annexes

Annexe 1 : Liste des questions du google form

Annexe 2 : Questionnaire entretien semi-dirigé

Annexe 3 : Comptes rendus entretiens semi dirigés (Interviewés A,B,C)

Liste paginée des tableaux et figures

Liste des tableaux

Liste des figures

Glossaire

Table des matières

